ICMC USP SÃO CARLOS

USP Universidade de São Paulo



IA, Otimização e IoT para Indústrias e Negócios
Do Zero ao MLOps

PROFESSOR

Dr. Cláudio Fabiano Motta Toledo

OpAIoT
Optimization • AI • IoT

Módulo 1

Fundamentos de Dados e Aprendizado de Máquina

Aplicado a Operações e Negócios

OpAIoT
Optimization • AI • IoT

Universidade de São Paulo

CRISP-ML(Q)

Sumário

O que é CRISP-ML(Q)?

CRISP-ML(Q) e CRISP-DM

Por que o CRISP-ML(Q) foi proposto?

Estrutura geral do CRISP-ML(Q)

A lógica de garantia da qualidade

Fases do CRISP-ML(Q)

Conclusão

Referências

O que é CRISP-ML(Q)?

CRoss-**I**ndustry **S**tandard **P**rocess model for the development of **M**achine **L**earning applications with **Q**uality assurance methodology

Garantia da qualidade orientada a riscos em todas as fases do ciclo de vida



Do projeto à operação contínua.

1 Escopo e critérios

Objetivos de negócio, objetivos de ML, KPI econômico e teste de viabilidade.

2 QA orientada a riscos

Cada tarefa define requisitos, identifica riscos e escolhe ações de mitigação.

3 Vida útil do modelo

Após o deploy, o modelo precisa ser monitorado, atualizado e reavaliado.

CRISP-ML(Q) e CRISP-DM

Ideia central
O CRISP-ML(Q) amplia o CRISP-DM para o contexto de aplicações de ML em produção e integra garantia da qualidade orientada a riscos em todas as fases do ciclo de vida.

CRISP-DM significa *Cross-Industry Standard Process for Data Mining*, ou seja, Processo Padrão Intersetorial para Mineração de Dados.

- Trata-se de um modelo de processo que orienta projetos de mineração de dados ao organizar o projeto em fases, desde o entendimento do problema de negócio até a implantação da solução.



CRISP-ML(Q) e CRISP-DM

CRISP-DM ponto de partida para CRISP-ML(Q)

- Referência mais difundida para projetos de data mining.
- Considerado um modelo bastante consolidado na indústria para projetos de mineração de dados.

Limitações

1. Aplicações de ML em operação continuam evoluindo após o deploy.
2. Ausência de um método explícito de garantia da qualidade ao longo do processo.

Conclusão

Não basta treinar um modelo; é preciso gerir o ciclo de vida e os riscos técnicos do sistema.

Por que o CRISP-ML(Q) foi proposto?

Preencher duas lacunas do CRISP-DM quando o objetivo é uma aplicação de ML em produção.

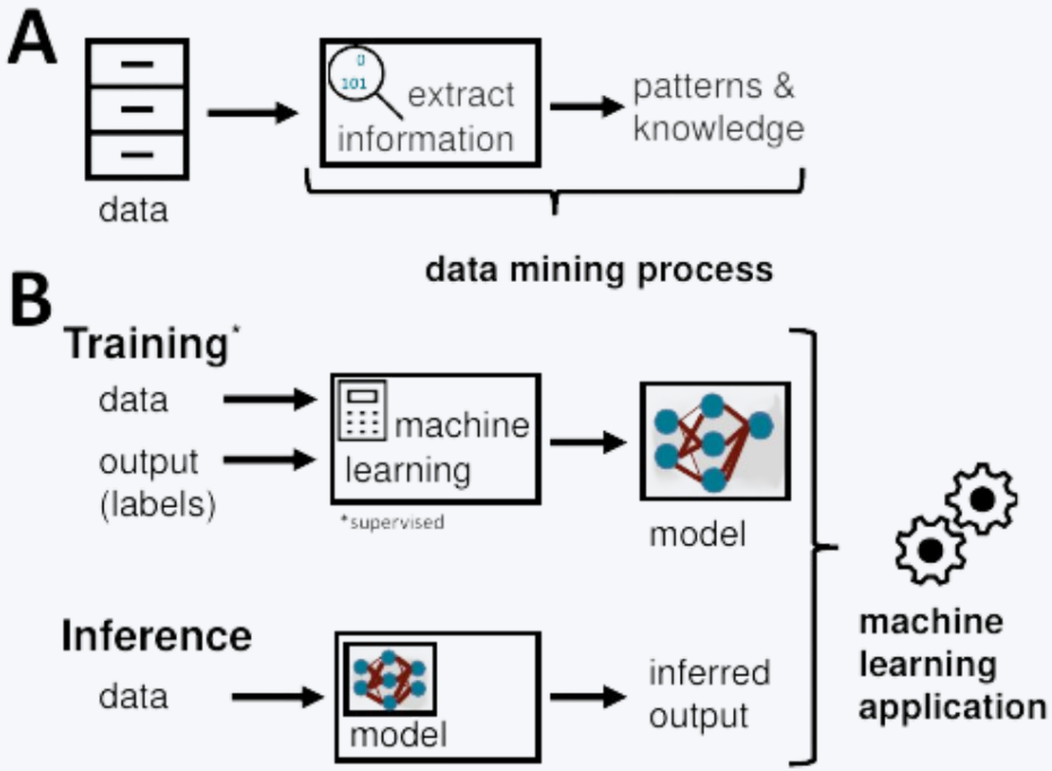
Lacuna 1

O CRISP-DM foca em **descoberta de conhecimento**, mas não cobre bem o **uso prolongado do modelo** para inferir decisões em tempo real.

Lacuna 2

Faltava uma **metodologia de QA integrada ao processo**, com foco em requisitos, metricas, riscos e mitigacao.

Da mineração de dados para a aplicação de ML



A figura do artigo distingue dois cenários: (A) extrair padrões a partir dos dados e (B) treinar um modelo que depois continuará operando em inferência.

Estrutura geral do CRISP-ML(Q)



Backtracking e esperado: se um critério não for atendido, o processo retorna a fases anteriores.

Duas diferenças-chave em relação ao CRISP-DM

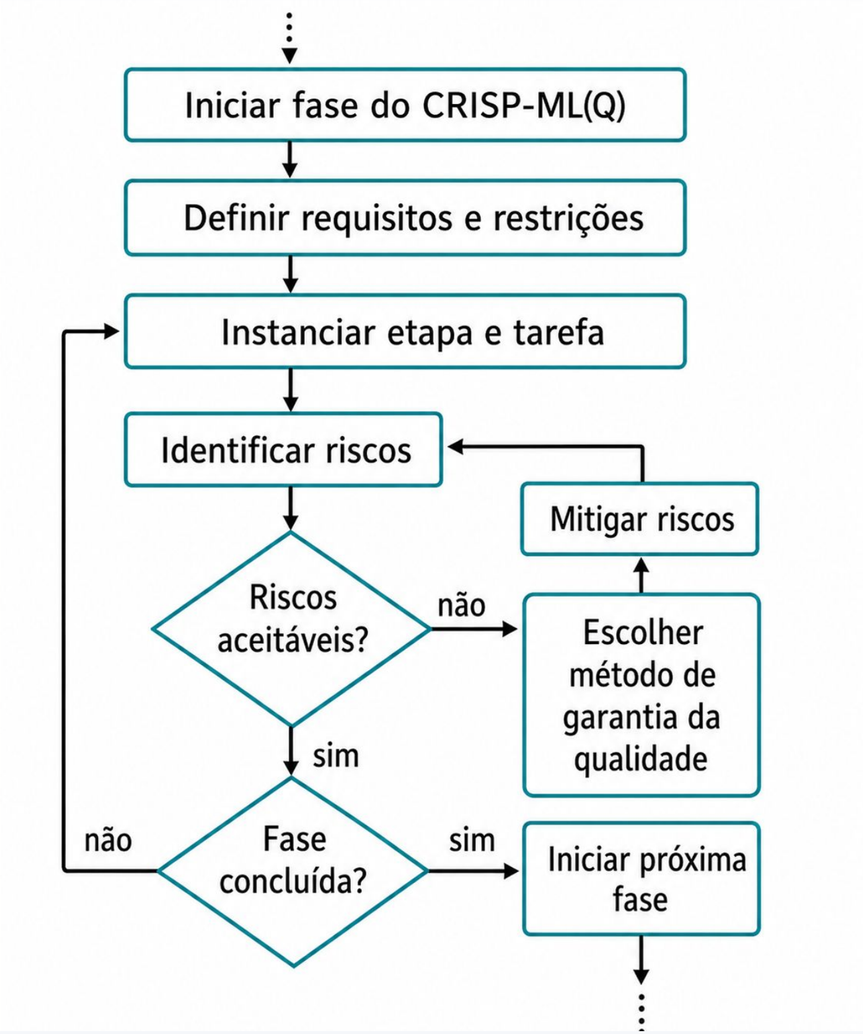
- Entendimento do negócio e dos dados tornam-se uma fase unica.
- Monitoramento e manutenção entram explicitamente no ciclo de vida.

Como ler o modelo

- Cada fase contém tarefas técnicas e critérios de QA.
- Requisitos, métricas e riscos orientam as decisões.

A lógica de garantia da qualidade (QA)

Fluxo de QA em cada fase



Fonte: Adaptada de Studer, Stefan, et al. (2021)

Essencia da proposta

- QA é tratada como confiança razoável de que o produto está adquirindo os atributos esperados durante o desenvolvimento, e não apenas no fim.
- O processo adota ***risk-based thinking***:
  - cada tarefa avaliar riscos, sua gravidade/probabilidade e escolhe limitações técnicas.
- Sempre que possível, os requisitos devem ser mensuráveis e acompanhados por métricas.

CRISP-ML(Q) responde repetidamente a quatro perguntas:

o que precisa ser atendido?

qual é a tarefa?

que risco pode comprometer a tarefa?

qual evidência/ação reduz esse risco?

Fase 1 - Entendimento do negócio e dos dados

Nesta abertura do processo, objetivo de negocio, objetivo de ML, viabilidade e qualidade dos dados são tratados em conjunto.

Escopo da aplicacao

Negócio e ciência de dados não devem atuar isoladamente. **A definição do problema já considera restrições de dados.**

Criterios de sucesso

Tres niveis: sucesso de negócio, sucesso de ML e sucesso econômico (KPI).

Viabilidade

Antes de seguir, avaliam-se disponibilidade, tamanho e qualidade da amostra; PoC e estudo de aplicabilidade podem ser úteis.

Qualidade dos dados

Descrever os dados, definir requisitos/esquema e verificar se amostras não plausíveis estão sendo tratadas corretamente.

Saidas esperadas da fase

- ➔ Escopo do projeto
- ➔ Critérios de sucesso alinhados
- ➔ Avaliação de viabilidade
- ➔ Relatório de verificação da qualidade dos dados

Exemplo

Em uma inspeção de qualidade, o negócio quer reduzir a taxa de falha abaixo de 3%;

- ➔ isso pode virar, por exemplo, um critério mínimo de acurácia > 97% e um KPI de economia por peça.

Foco de QA nesta fase

As principais falhas aqui são: dados insuficientes e requisitos de dados mal definidos. Se isso não for resolvido cedo, o projeto tende a fracassar depois.

Fase 2 - Preparação dos dados

O objetivo é produzir um conjunto de dados adequado para a modelagem, preservando rastreabilidade e evitando vieses ou artefatos

Selecionar

escolher atributos e amostras relevantes; tratar classes desbalanceadas com cuidado

Limpar

reduzir ruído e imputar valores faltantes comparando alternativas para evitar artefatos

Construir

fazer engenharia de atributos sempre comparando com um baseline

Padronizar

fixar formatos, unidades e normalização coerentes entre treino e teste

Riscos típicos

Seleção enviesada, correlações espúrias, filtros que removem sinal útil e imputação inadequada.

Como o QA aparece aqui

Documentar escolhas, **comparar** alternativas com baseline, **consultar** especialistas do domínio e preferir preparações passíveis de automação para o ciclo de vida posterior.

Fase 3 - Modelagem

Modelar, no CRISP-ML(Q), significa equilibrar múltiplos objetivos e garantir reprodutibilidade.

Seis qualidades do modelo

- **Desempenho**
- **Robustez**
- **Escalabilidade**
- **Explicabilidade**
- **Complexidade**
- **Demanda de recursos**

O artigo defende uma visao multiobjetivo: acuracia importa, mas nao so ela.

Fase 4 - Avaliação

A avaliação verifica se o modelo é suficientemente bom para seguir adiante e se os riscos residuais permanecem aceitáveis.

Blind test e dados separados

Evitar vazamento entre treino, validacão e teste; o conjunto final deve representar casos reais.

Analise fatiada de desempenho

Olhar métricas por classe, grupo ou fatia temporal para nao mascarar fragilidades.

Robustez

Testar perturbações, ataques, variações de hiperparâmetros e comportamentos fora do ideal.

Explicabilidade

Entender por que o modelo decide e detectar correlações espúrias ou sinais sem sentido.

Exemplo

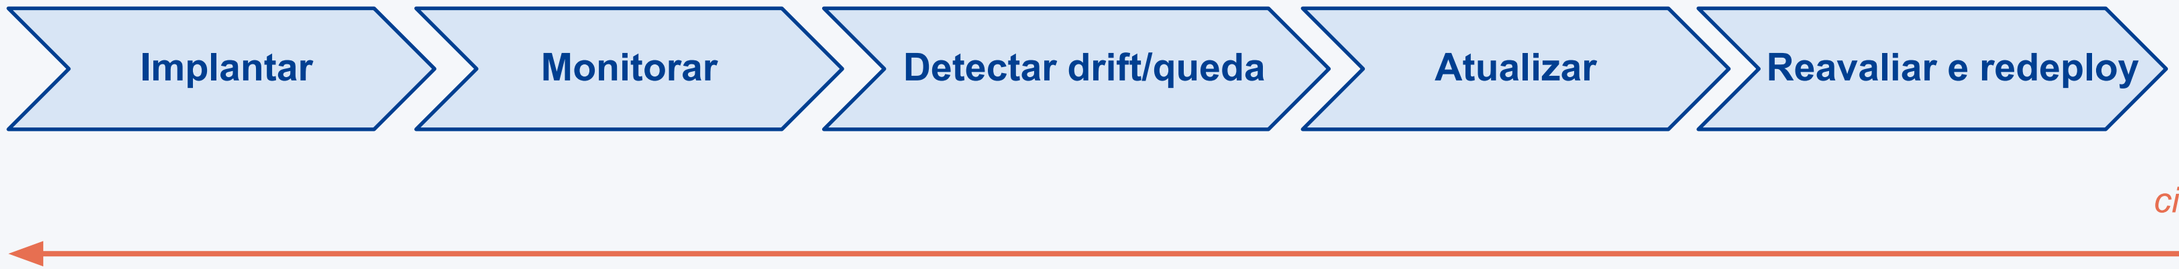
Um modelo de classificação de ruídos sobe de 95% para 96% de acurácia global após tuning. A análise por classe mostra, porém, piora nas classes raras. O resultado: o modelo “melhor” é descartado, e os objetivos da modelagem são revistos.

Decisao ao final da fase

Comparar os resultados com os critérios definidos na Fase 1. Se não atender, volta-se à modelagem ou até aos dados.

Fases 5 e 6 - Implantação, monitoramento e manutenção

O modelo passa a ser tratado como parte de um sistema vivo, sujeito a mudanças de contexto e degradação.



Monitoramento e manutenção: por que são necessários?

- distribuições não estacionárias mudam ao longo do tempo
- hardware e sensores degradam
- atualizações do sistema alteram entradas, unidades ou comportamento
- quando um limiar é excedido, o modelo pode ser ajustado, retreinado e reavaliado

Conclusão

CRISP-ML(Q) não é apenas um roteiro de etapas. Ele é um modo de pensar projetos de ML como sistemas que precisam ser planejados, medidos, auditados, implantados e mantidos ao longo do tempo.

OpAIoT
Optimization • AI • IoT

Universidade de São Paulo

Referências

- Wirth, Rüdiger, and Jochen Hipp. "CRISP-DM: Towards a standard process model for data mining." Proceedings of the 4th international conference on the practical applications of knowledge discovery and data mining. Vol. 1. 2000.
- Studer, Stefan, et al. "Towards CRISP-ML (Q): a machine learning process model with quality assurance methodology." Machine learning and knowledge extraction 3.2 (2021): 392-413.





Obrigado!

opaiot@icmc.usp.br
+55 (16) 99962-7637

PROFESSOR

Dr. Cláudio Fabiano Motta Toledo

OpAIoT
Optimization • AI • IoT