ICMC USP SÃO CARLOS

USP Universidade de São Paulo



IA, Otimização e IoT para Indústrias e Negócios
Do Zero ao MLOps

PROFESSOR

Dr. Cláudio Fabiano Motta Toledo

OpAIoT
Optimization • AI • IoT

ICMC USP SÃO CARLOS

OpAIoT
Optimization • AI • IoT

Módulo 1

Fundamentos de Dados e Aprendizado de Máquina

Aplicado a Operações e Negócios

Universidade de São Paulo
Brasil

OpAIoT
Optimization • AI • IoT

Universidade de São Paulo

Medidas de Espalhamento

Sumário

O que são medidas de espalhamento?

- Intervalo
- Variância
- Desvio Padrão
- Outras Medidas de Dispersão

Referências

O que são medidas de espalhamento?

Dispersão = “o quão próximos ou distantes os valores estão entre si”

Ideia central

Medidas de espalhamento resumem a variabilidade de um conjunto de valores. Elas indicam se os dados estão amplamente espalhados ou relativamente concentrados (por exemplo, ao redor da média).



Principais métricas (clássicas):

- Intervalo (amplitude)
- Variância
- Desvio padrão

Por que isso importa?

- Compara grupos (turmas, máquinas, regiões)
- Detecta instabilidade e outliers
- Informa risco e incerteza
- Apoia decisões (limites, SLAs, controle de qualidade)

Regra prática: sempre reporte uma medida de localidade + uma de espalhamento.

Intervalo (Amplitude)

Métrica simples que indica a dispersão máxima entre os valores do conjunto de dados

Definição

$$Intervalo(X) = \max_{i=1...n}(x_i) - \min_{i=1...n}(x_i)$$

$X=\{x_1, x_2, ..., x_n\}$: conjunto de dados com n objetos, não necessariamente ordenados

Exemplo rápido

X = {4, 6, 8}
min=4, max=8 ⇒ intervalo=4

Vantagens:
- Muito fácil de calcular
- Fácil de explicar

Limitação principal:
- Quando há um reduzido número de valores extremos e alta concentração de valores em torno de um ponto.

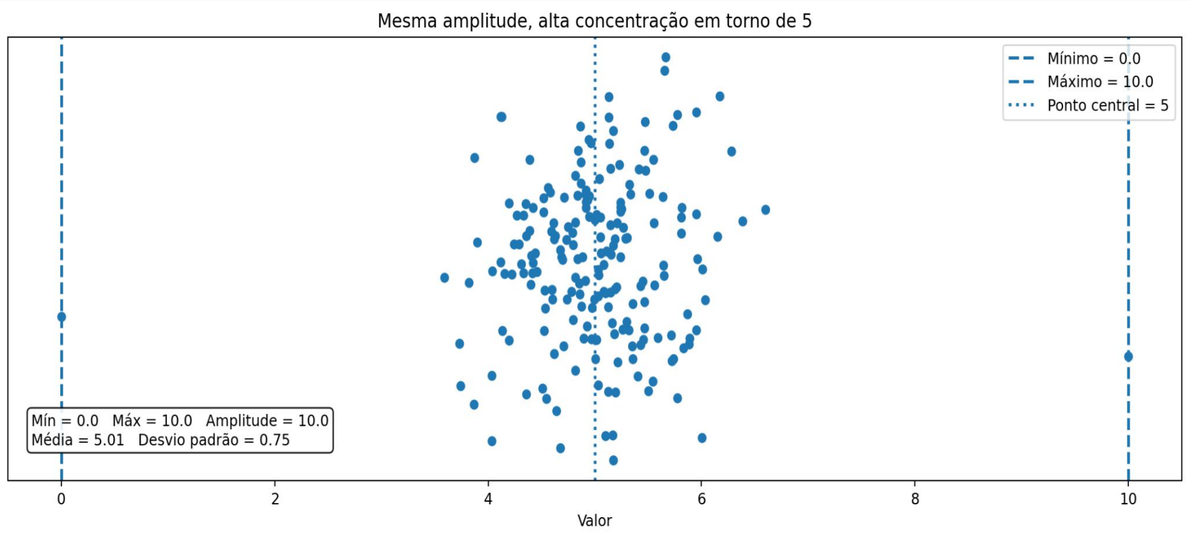
Intervalo (Amplitude)

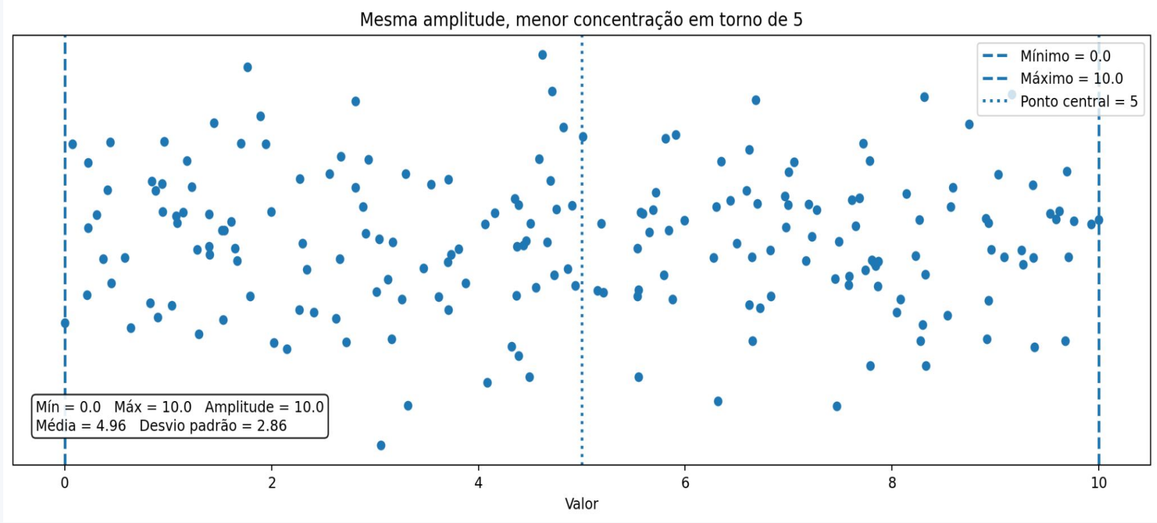
Quando faz sentido?

- Dados sem outliers fortes
- Monitorar limites físicos (capacidade, tolerâncias)
- Complementar — nunca como única medida

Alerta

Dois conjuntos podem ter o mesmo intervalo e dispersões internas muito diferentes.





Variância

Definições (população vs amostra)

População: $\sigma^2 = (1/n) \cdot \Sigma (xi - \mu)^2$

Amostra: $s^2 = (1/(n-1)) \cdot \Sigma (xi - \bar{x})^2$

Intuição:

- Mede o “tamanho” médio dos desvios
- Usa quadrado → penaliza desvios grandes

Pontos importantes:

- Unidade fica ao quadrado
- É sensível a outliers (porque o quadrado cresce rápido)

Observação: variância se conecta a “erro quadrático médio” (MSE), muito usado em regressão.

Dica de interpretação

Se você quer algo “na mesma unidade” do dado, use o desvio padrão

Variância

Definições (população vs amostra)

População: $\sigma^2 = (1/n) \cdot \Sigma (xi - \mu)^2$

Amostra: $s^2 = (1/(n-1)) \cdot \Sigma (xi - \bar{x})^2$

A Variância Amostral é Viciada:

- Quando calculamos a variância de uma amostra (e não da população inteira), usar a fórmula com **divisão por n subestima sistematicamente a verdadeira variância populacional**

Exemplo: População {2,4,6,8,10}

$$\mu = \frac{2+4+6+8+10}{5} = \frac{30}{5} = 6$$

$$\sigma^2 = \frac{(2-6)^2+(4-6)^2+(6-6)^2+(8-6)^2+(10-6)^2}{5}$$

$$\sigma^2 = \frac{16+4+0+4+16}{5} = \frac{40}{5} = 8$$

Variância da população é 8

E se a população não é conhecida e precisamos trabalhar com uma amostra??

Variância

Exemplo: População {2,4,6,8,10}

$$\mu = \frac{2+4+6+8+10}{5} = \frac{30}{5} = 6$$

$$\sigma^2 = \frac{(2-6)^2+(4-6)^2+(6-6)^2+(8-6)^2+(10-6)^2}{5}$$

$$\sigma^2 = \frac{16+4+0+4+16}{5} = \frac{40}{5} = 8$$

Variância da população é 8

E se a população não é conhecida e precisamos trabalhar com uma amostra??

Amostra {2,4,6}

$$\bar{x} = \frac{2+4+6}{3} = 4$$

$$(2-4)^2 + (4-4)^2 + (6-4)^2 =$$

$$= 4 + 0 + 4 = 8$$

$$\sigma_n^2 = \frac{8}{3} \approx 2{,}67$$

$$\sigma_{n-1}^2 = \frac{8}{2} = 4$$

As estimativas ficaram abaixo da variância populacional, mas a que usa n-1 ficou menos subestimada.

Desvio Padrão

- **Desvio Padrão**: considera a raiz quadrada da variância e indica em média o quanto a amostra está distante da média aritmética.

$$\sigma(X) = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

Vantagens:

- Interpretação direta já que tem a mesma unidade dos dados originais, enquanto a variância está ao quadrado.
- Diferente da amplitude, que usa os extremos, o desvio padrão reflete toda a distribuição ao considerar todos os dados da amostra ou população.
- Fundamental em distribuições como a normal, onde a maior parte dos dados está a 1, 2 ou 3 desvios padrão da média.

Desvio Padrão

- **Desvio Padrão**: considera a raiz quadrada da variância e indica em média o quanto a amostra está distante da média aritmética.

$$\sigma(X) = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

Desvantagens:

- Sensível a outliers já que os valores extremos podem aumentar o desvio padrão, tornando-o menos representativo em distribuições assimétricas ou com outliers.
- Supõe simetria, a interpretação de 1, 2 ou 3 desvios está mais adequada para distribuições simétricas, como a normal.

Outras Medidas de Espalhamento

Outras medidas de espalhamento:

- Desvio médio absoluto (AAD - Absolute Average Deviation):

$$AAD(X) = \frac{1}{n} \sum_{i=1}^{n} |x_i - \bar{x}|$$

- Desvio mediano absoluto (MAD - Median Absolute Deviation):

$$MAD(X) = mediana(\{|x_1 - \bar{x}|, \ldots, |x_n - \bar{x}|\})$$

Outras Medidas de Espalhamento

Métrica	Vantagens	Desvantagens	Quando Aplicar
ADD	• Intuitivo • Menos sensível a outliers • Unidade original	• Menos eficiente • Propriedades limitadas	• Comunicação não-técnica • Outliers moderados
MAD	• Altamente robusto • Não afetado por assimetria • Baseado em medianas	• Menos eficiente em normais • Cálculo complexo	• Muitos outliers • Distribuições assimétricas

OpAIoT
Optimization • AI • IoT

Universidade de São Paulo

Referências

- NIST/SEMATECH e-Handbook — Cap. 1 “Exploratory Data Analysis”, https://www.itl.nist.gov/div898/handbook/eda/eda.htm?utm_source=chatgpt.com
- BUSSAB, W. O.; MORETTIN, P. A. Estatística Básica. 7. ed. São Paulo: Saraiva, 2011.
- MAGALHÃES, M. N.; LIMA, A. C. P. Noções de Probabilidade e Estatística. 7. ed. São Paulo: EDUSP, 2015
- Faceli, Katti, et al. "Inteligência artificial: uma abordagem de aprendizado de máquina." (2021).





Obrigado!

opaiot@icmc.usp.br
+55 (16) 99962-7637

PROFESSOR

Dr. Cláudio Fabiano Motta Toledo

OpAIoT
Optimization • AI • IoT