ICMC USP SÃO CARLOS

USP Universidade de São Paulo



IA, Otimização e IoT para Indústrias e Negócios
Do Zero ao MLOps

PROFESSOR

Dr. Cláudio Fabiano Motta Toledo

OpAIoT
Optimization • AI • IoT

ICMC USP SÃO CARLOS

OpAIoT
Optimization • AI • IoT

Módulo 1

Fundamentos de Dados e Aprendizado de Máquina

Aplicado a Operações e Negócios

Universidade de São Paulo
Brasil

OpAIoT
Optimization • AI • IoT

Universidade de São Paulo

Medidas de Distribuição

Sumário

01 O que são medidas de distribuição?

02 Momento

03 Obliquidade (Assimetria)

04 Curtose

05 Referências

Medidas de distribuição

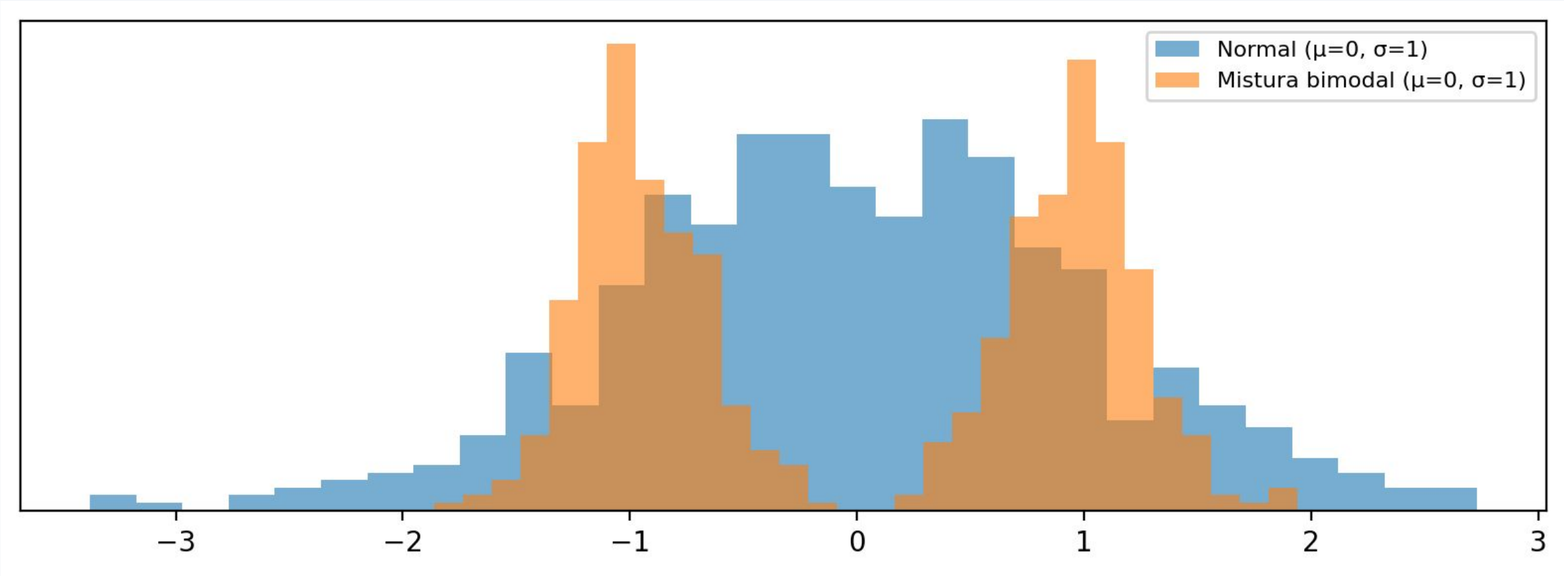
Medidas de distribuição são estatísticas usadas para descrever como os valores de uma variável se organizam ao longo de sua faixa de valores.

Permitem entender o “formato” dos dados: onde eles se concentram, quão espalhados estão, se são simétricos, se possuem caudas longas, valores extremos, multimodalidade etc.

- Unimodalidade: um pico
- Bimodalidade: dois picos
- Multimodalidade: vários picos

Exemplo:

Temperatura de máquinas pode ter dois picos: um para operação normal e outro para regime crítico.



Medidas de distribuição

Caudas indicam a frequência relativa de valores muito altos ou muito baixos. Relevante para:

- detecção de fraudes,
- falhas industriais,
- análise de risco financeiro.



Momento

- **Momento**: métrica definida em torno da média de um conjunto de valores.
- De forma geral, o momento amostral central é definido como: $\mathbb{E}_k(X) = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^k$

- Ideia-chave: a família de momentos organiza essas medidas de forma hierárquica (1º, 2º, 3º, 4º...).
- **Média:** trata-se do primeiro **Momento em Relação à Origem**

$$\mathbb{E}_0(X) = \frac{1}{n}\sum_{i=1}^{n} x_i = \bar{x}$$

- **Primeiro Momento em Relação à Média:** tem valor nulo

$$\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x}) = \frac{1}{n}\sum_{i=1}^{n} x_i - \frac{1}{n}\sum_{i=1}^{n}\bar{x} = \bar{x} - \frac{1}{n}n\bar{x} = \bar{x} - \bar{x} = 0$$

- **Variância:** trata-se do **Segundo Momento**

$$\mathbb{E}_2(X) = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2 = \sigma^2(X)$$

Obliquidade

- **Terceiro Momento** permite calcular o **coeficiente de assimetria ou obliquidade**.

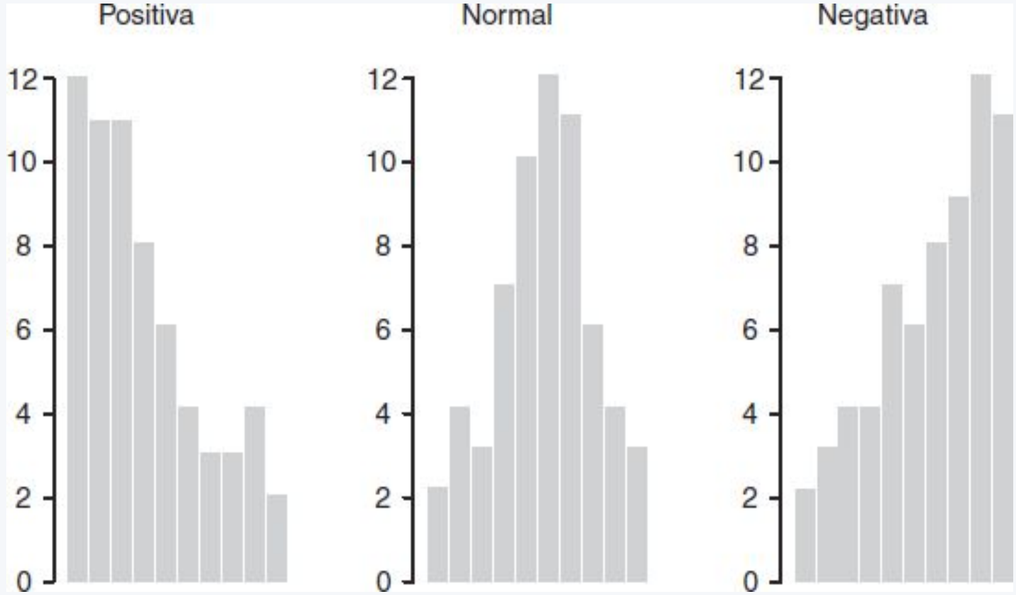
$$\mathbb{E}_3(X) = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^3$$

- **Obliquidade/Assimetria (Skweness)**: mede a simetria da distribuição dos dados em relação à média.
- Divide-se pelo cubo do desvio padrão para deixar a métrica **independente de escala**.

$$v = \frac{\mathbb{E}_3(X)}{\sigma^3}$$

Obliquidade

- Simétrica parar $v = 0$
- Assimétrica à esquerda para v>0
  - cauda à direita
- Assimétrica à direita para v<0
  - cauda à esquerda



Fonte: Faceli, K., Lorena, A. C., Gama, J., Almeida, T. A. D., & Carvalho, A. C. P. D. L. F. D. (2021). Inteligência artificial: uma abordagem de aprendizado de máquina.

Curtose

- **Quarto Momento** permite calcular o coeficiente de curtose.

$$\mathbb{E}_4(X) = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^4$$

- **Curtose**: medida ligada ao formato da distribuição, especialmente à presença de caudas mais pesadas e valores extremos, e secundariamente ao grau de achatamento ou pico.

$$c = \frac{\mathbb{E}_4(X)}{\sigma^4}$$

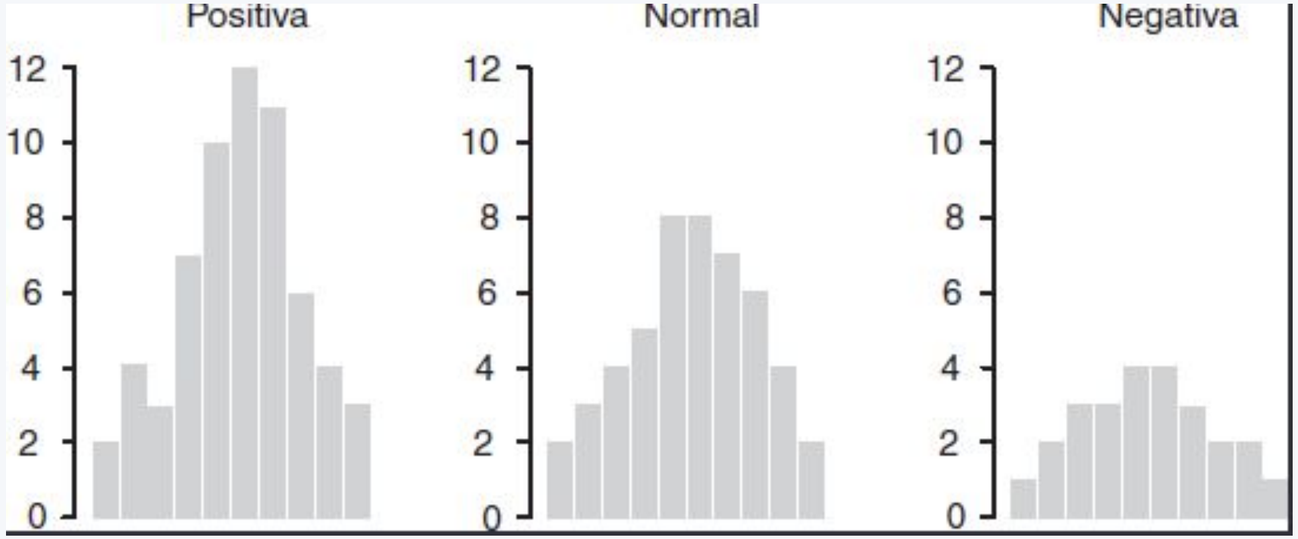
- Divide-se pelo desvio padrão elevado à quarta potência para deixar a métrica independente de escala.

- Temos c = 3 para uma distribuição normal com média 0 e variância 1, levando ao uso da fórmula com uma correção que permite a distribuição normal padrão ter curtose igual a 0.

$$c = \frac{\mathbb{E}_4(X)}{\sigma^4} - 3$$

Curtose

- c=0: histograma da distribuição dos dados com mesmo achatamento que uma distribuição normal.
- c>0: histograma de distribuição mais alto e concentrado do que a distribuição normal.
- c<0: histograma de distribuição mais achatado que a distribuição normal.



Fonte: Faceli, K., Lorena, A. C., Gama, J., Almeida, T. A. D., & Carvalho, A. C. P. D. L. F. D. (2021). Inteligência artificial: uma abordagem de aprendizado de máquina.

Tabela Resumo para Aplicação em ML

Medida	Função	Uso em ML	Impacto
Média	Centro dos dados	• Normalização • Imputação • Centragem	Essencial para algoritmos baseados em distância
Mediana	Centro robusto	• Imputação robusta • Escalonamento robusto	Crítico para dados com outliers
Variância	Dispersão	• PCA • Seleção de features • Regularização	Fundamental para redução de dimensionalidade
Desvio Padrão	Escala	• Normalização • Detecção de outliers	Unifica escalas entre features
IQR	Dispersão robusta	• Boxplots • Outliers robustos	Visualização e diagnóstico
Assimetria	Forma	• Decisão sobre transformações • Escolha de algoritmos	Indica necessidade de transformação
Curtose	Caudas	• Detecção de outliers extremos • Análise de risco	Identifica distribuições com caudas pesadas
Quantis	Posição relativa	• Binning • Thresholds • Ranking	Criação de features não-lineares

OpAIoT
Optimization • AI • IoT

Universidade de São Paulo

05

Referências

- NIST/SEMATECH e-Handbook — Cap. 1 “Exploratory Data Analysis”, https://www.itl.nist.gov/div898/handbook/eda/eda.htm?utm_source=chatgpt.com
- BUSSAB, W. O.; MORETTIN, P. A. Estatística Básica. 7. ed. São Paulo: Saraiva, 2011.
- MAGALHÃES, M. N.; LIMA, A. C. P. Noções de Probabilidade e Estatística. 7. ed. São Paulo: EDUSP, 2015
- Faceli, Katti, et al. "Inteligência artificial: uma abordagem de aprendizado de máquina." (2021).





Obrigado!

opaiot@icmc.usp.br
+55 (16) 99962-7637

PROFESSOR

Dr. Cláudio Fabiano Motta Toledo

OpAIoT
Optimization • AI • IoT