ICMC USP SÃO CARLOS

USP Universidade de São Paulo



IA, Otimização e IoT para Indústrias e Negócios
Do Zero ao MLOps

PROFESSOR

Dr. Cláudio Fabiano Motta Toledo

OpAIoT
Optimization • AI • IoT

ICMC USP SÃO CARLOS

OpAIoT
Optimization • AI • IoT

Módulo 1

Fundamentos de Dados e Aprendizado de Máquina

Aplicado a Operações e Negócios

Universidade de São Paulo
Brasil

OpAIoT
Optimization • AI • IoT

Universidade de São Paulo

Dados Multivariados

Sumário

01 Dados Multivariados

02 Covariância

03 Correlação

04 Visualização de Dados Multivariados

05 Referências

Dados Multivariados: Representação

Dados multivariados apresentam mais de um atributo de entrada. Considere um conjunto de dados com *n* objetos e *d* atributos (dimensionalidade). Representamos os dados por uma matriz:

$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1d} \\ x_{21} & x_{22} & \cdots & x_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nd} \end{bmatrix}$$

n : número de objetos

d : dimensionalidade dos objetos

x_{ij} : valor da j-ésima característica do i-ésimo objeto

Objetos

Cada linha representa um objeto com suas características

Atributos

Cada coluna representa um atributo presente em todos os objetos

Valores

Cada célula contém um valor específico da característica

Dados Multivariados: Análise em Dois Pilares

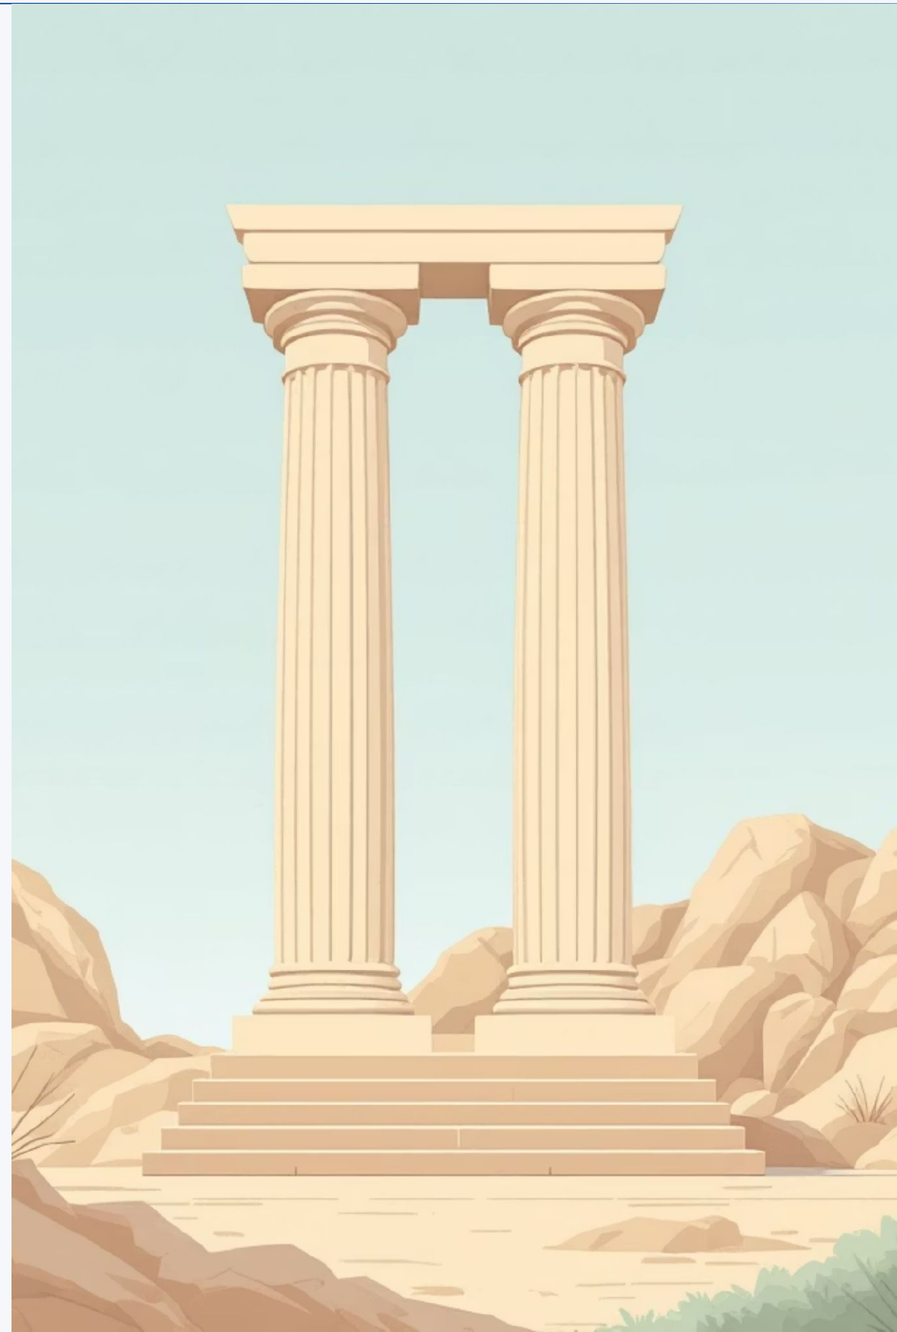
OpAIoT
Optimization • AI • IoT

Análise Marginal

Analisar cada atributo separadamente para obter sumários univariados por coluna

Análise de Relacionamentos

Estabelecer o relacionamento entre atributos, caracterizando a EDA multivariada



Dados Multivariados: Análise em Dois Pilares

Análise Marginal

Analisar cada atributo separadamente para obter sumários univariados

por coluna

$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1d} \\ x_{21} & x_{22} & \cdots & x_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nd} \end{bmatrix} \Rightarrow x^j = \begin{bmatrix} x_{1j} \\ x_{2j} \\ \vdots \\ x_{nj} \end{bmatrix} \Rightarrow X = [x^1, \ldots, x^d]$$

$$X = [x^1, \ldots, x^d] \Rightarrow [\bar{x}^1, \ldots, \bar{x}^d] \text{ ou } [\sigma_1^2, \ldots, \sigma_d^2]$$

Dados Multivariados: Análise em Dois Pilares

Análise de Relacionamentos

Estabelecer o relacionamento entre atributos, caracterizando a EDA multivariada

A análise de dados multivariados busca estabelecer relacionamentos entre atributos. O espalhamento é melhor aferido através da **covariância**, que mede a variância conjunta entre pares de variáveis aleatórias.

$$X = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1d} \\ x_{21} & x_{22} & \dots & x_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \dots & x_{nd} \end{bmatrix} \Rightarrow x^p = \begin{bmatrix} x_{1p} \\ x_{2p} \\ \vdots \\ x_{np} \end{bmatrix} \quad x^q = \begin{bmatrix} x_{1q} \\ x_{2q} \\ \vdots \\ x_{nq} \end{bmatrix}$$

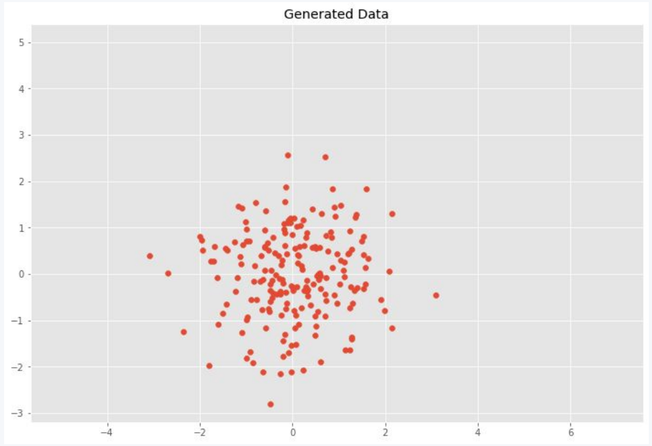
$$\sigma^2_{x^p,y^q} = \frac{1}{n-1} \sum_{i=1}^{n} (x_{ip} - \bar{x}_p)(x_{iq} - \bar{x}_q)$$

Covariância

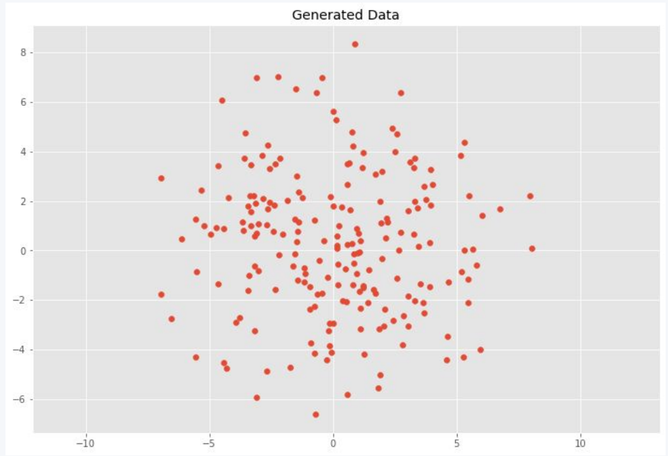
A **covariância** mede o grau com que os atributos variam juntos.

$$X = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1d} \\ x_{21} & x_{22} & \cdots & x_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nd} \end{bmatrix} \Rightarrow x^p = \begin{bmatrix} x_{1p} \\ x_{2p} \\ \vdots \\ x_{np} \end{bmatrix} \qquad x^q = \begin{bmatrix} x_{1q} \\ x_{2q} \\ \vdots \\ x_{nq} \end{bmatrix}$$

$$\sigma^2_{x^p,y^q} = \frac{1}{n-1} \sum_{i=1}^{n} (x_{ip} - \bar{x}_p)(x_{iq} - \bar{x}_q)$$



Baixa Variância



Alta Variância

Importante: A **escala** da variação de valores impacta o valor da covariância. Dois atributos com variações na escala de milhares podem ter covariância maior que atributos mais fortemente relacionados em escala 0-1.

Covariância

Para um conjunto de dados multivariados, avaliamos a **matriz de covariância**, uma matriz quadrada cujas entradas são variâncias e covariâncias associadas às diversas variáveis:

$$\sigma^2_{x^p,y^q} = \frac{1}{n-1}\sum_{i=1}^{n}(x_{ip} - \bar{x}_p)(x_{iq} - \bar{x}_q)$$

$$Cov(X) = \begin{bmatrix} \sigma^2_{11} & \sigma^2_{12} & \cdots & \sigma^2_{1n} \\ \sigma^2_{21} & \sigma^2_{22} & \cdots & \sigma^2_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma^2_{n1} & \sigma^2_{n2} & \cdots & \sigma^2_{nn} \end{bmatrix} \qquad \sigma^2_{ii} = \sigma^2$$

Simétrica $\sigma^2_{ij} = \sigma^2_{j,i}$

Diagonal $\sigma^2_{ii} = \sigma^2$

Positiva $\sigma^2 > 0$

Valores na diagonal são sempre positivos

Correlação

Métrica que retira a influência da variação dos valores, sendo mais aplicada na exploração de dados multivariados.

$$corr(x^p, x^q) = \frac{\sigma^2_{x^p, x^q}}{\sigma_{x^p} \times \sigma_{x^q}}$$

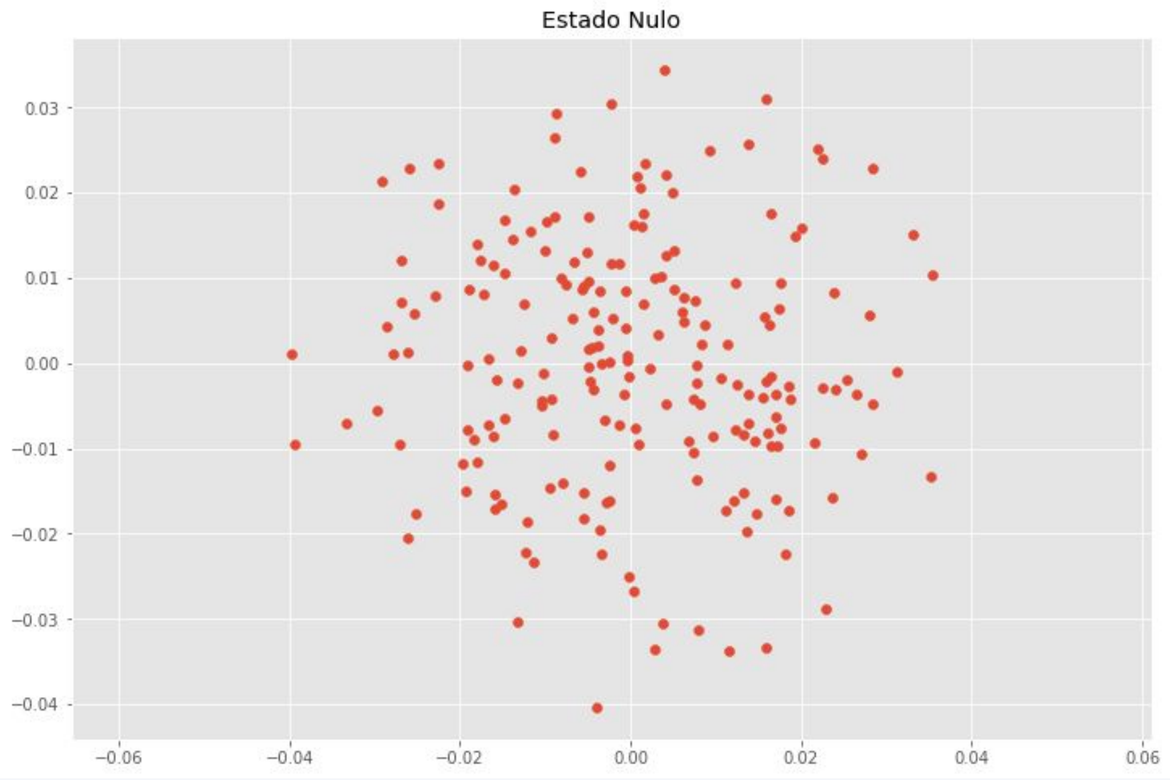
$$Corr(X) = \begin{bmatrix} 1 & corr(x^1, x^2) & \dots & corr(x^1, x^n) \\ corr(x^2, x^1) & 1 & \dots & corr(x^2, x^n) \\ \vdots & \vdots & \ddots & \vdots \\ corr(x^n, x^1) & corr(x^n, x^2) & \dots & 1 \end{bmatrix}$$

$$corr(x^p, x^q) \in [-1, +1]$$
$$corr(x^p, x^p) = 1$$

- A correlação tem valor 1 para elementos na diagonal e valores entre –1 (correlação negativa máxima) e +1 (correlação positiva máxima) nos demais casos.

Correlação

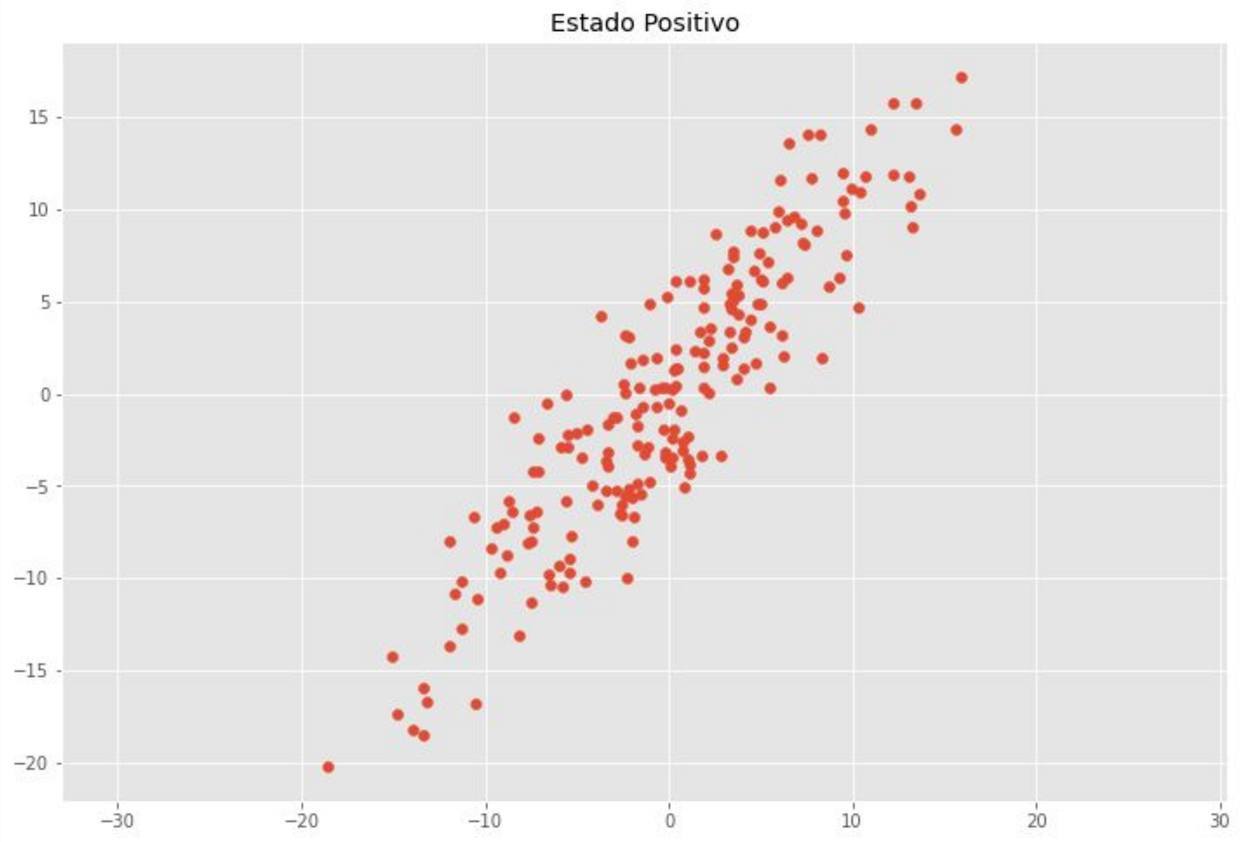
$corr(x^p, x^q) \approx 0$: indica que os atributos não têm um relacionamento linear.



- Nesse caso, não há uma relação entre as variáveis

Correlação

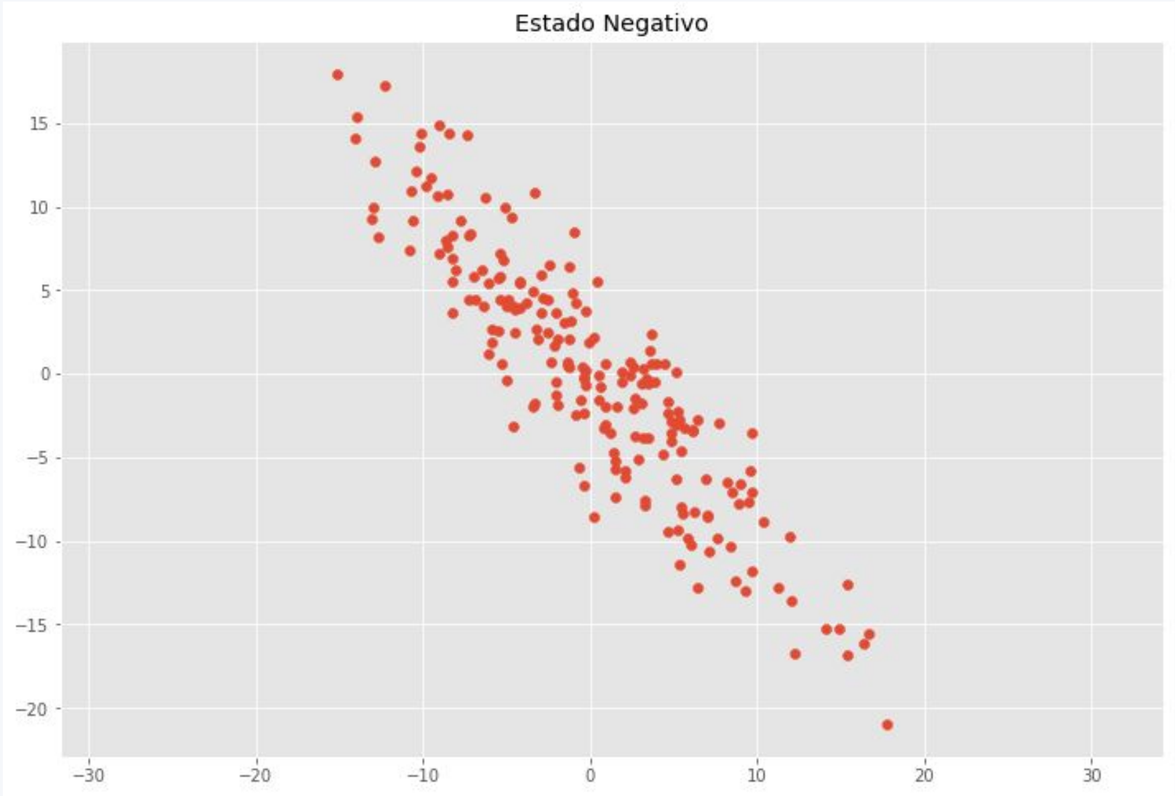
$corr(x^p, y^q) > 0$: indica que os atributos são diretamente relacionados.



- O aumento no valor de um atributo, aumenta o valor no outro.
- Variáveis seguem a mesma direção

Correlação

$corr(x^p, y^q) < 0$: indica que os atributos são inversamente relacionados.



- O aumento no valor de um atributo, reduz o valor no outro.
- Variáveis seguem a direção oposta.

Correlação

Essa interpretação se aplica também a covariância.

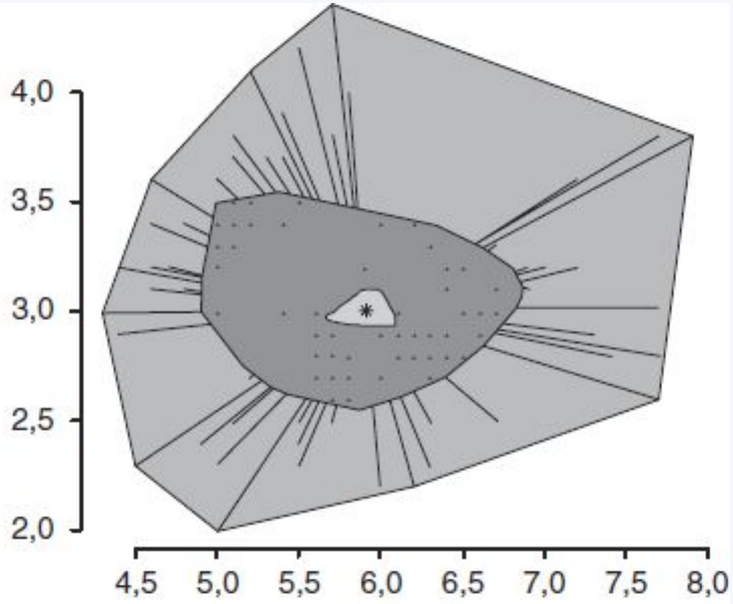
Tanto na covariância quanto na correlação:

- ➔ Quando dois atributos apresentam uma correlação positiva, o aumento do valor de um deles é geralmente acompanhado por um aumento no valor do outro.

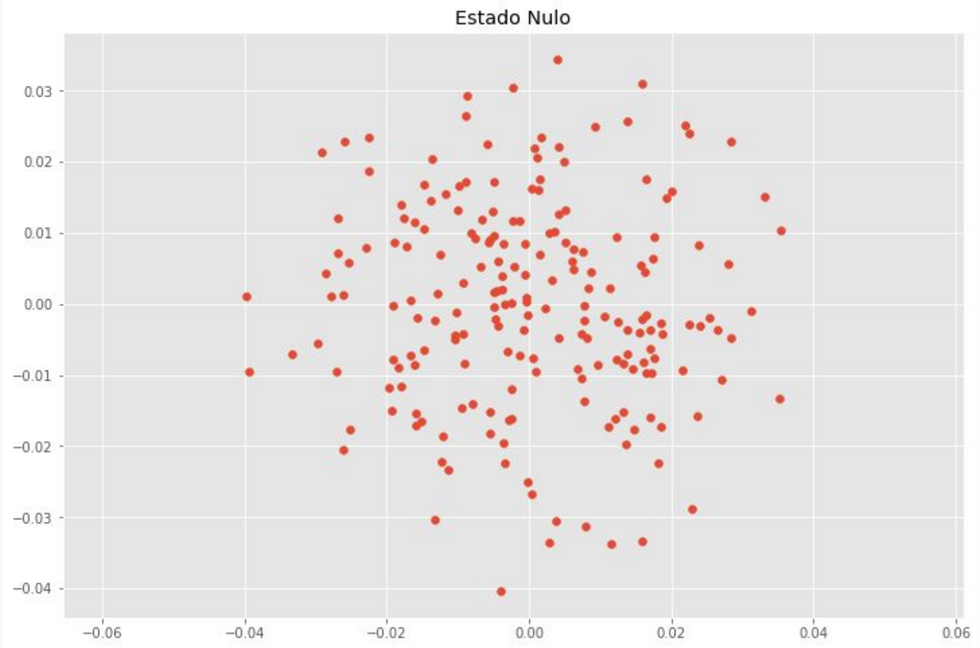
- ➔ Quando dois atributos têm uma correlação negativa, a redução no valor de um deles é geralmente acompanhada do aumento do valor do outro.

Visualização de Dados Multivariados

Recursos de visualização também facilitam a análise dos dados multivariados.
Explorem recursos de visualização como



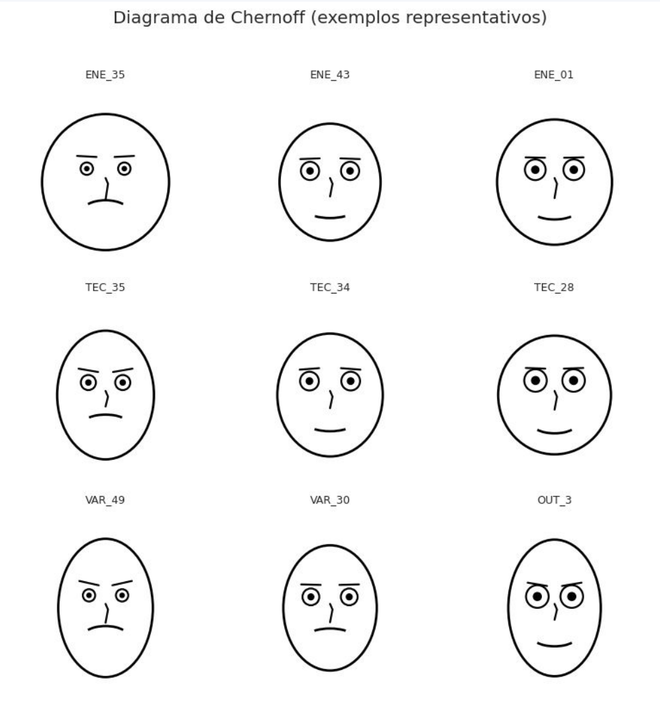
- **bagplot** é uma generalização bivariada do boxplot.



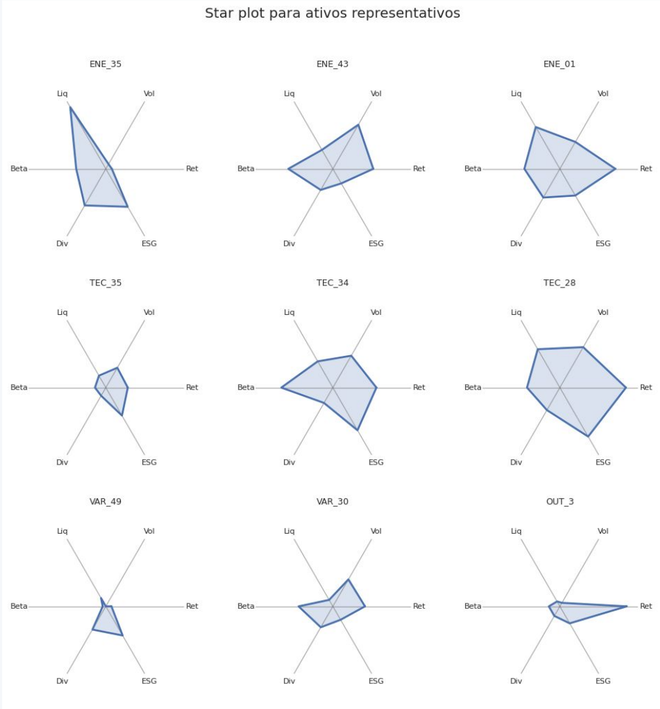
- **scatter** plot que permite visualizar a correlação linear entre dois atributos.

Visualização de Dados Multivariados

Recursos de visualização também facilitam a análise dos dados multivariados. Explorem recursos de visualização como



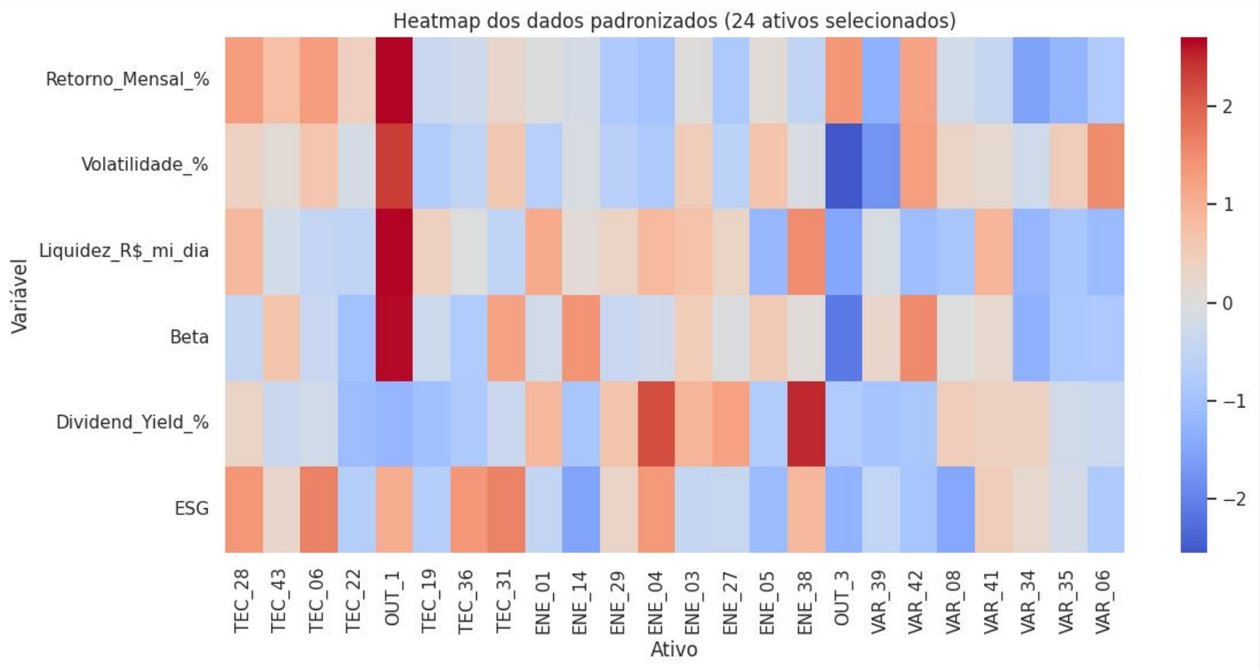
- **Diagrama de Chernoff** representa atributos por características em uma face



- **Star plot** utiliza figuras geométricas onde cada linha corresponde a um atributo e o tamanho da linha é proporcional ao valor do atributo.

Visualização de Dados Multivariados

Recursos de visualização também facilitam a análise dos dados multivariados. Explorem recursos de visualização como



- **Heatmaps** ou mapas de calor são representações gráficas de dados que utilizam sistemas codificados por cores.

OpAIoT
Optimization • AI • IoT

Universidade de São Paulo

Referências

- NIST/SEMATECH e-Handbook — Cap. 1 “Exploratory Data Analysis”, https://www.itl.nist.gov/div898/handbook/eda/eda.htm?utm_source=chatgpt.com
- BUSSAB, W. O.; MORETTIN, P. A. Estatística Básica. 7. ed. São Paulo: Saraiva, 2011.
- MAGALHÃES, M. N.; LIMA, A. C. P. Noções de Probabilidade e Estatística. 7. ed. São Paulo: EDUSP, 2015
- Faceli, Katti, et al. "Inteligência artificial: uma abordagem de aprendizado de máquina." (2021).





Obrigado!

opaiot@icmc.usp.br
+55 (16) 99962-7637

PROFESSOR

Dr. Cláudio Fabiano Motta Toledo

OpAIoT
Optimization • AI • IoT