ICMC USP SÃO CARLOS

USP Universidade de São Paulo



IA, Otimização e IoT para Indústrias e Negócios
Do Zero ao MLOps

PROFESSOR

Dr. Cláudio Fabiano Motta Toledo

OpAIoT
Optimization • AI • IoT

ICMC USP SÃO CARLOS

OpAIoT
Optimization • AI • IoT

Módulo 1

Fundamentos de Dados e Aprendizado de Máquina

Aplicado a Operações e Negócios

Universidade de São Paulo
Brasil

OpAIoT
Optimization • AI • IoT

Universidade de São Paulo

Tratamento de Dados, Metadados e Integração

Sumário

01 O que é Tratamento de Dados?

02 Metadados

03 Integração

04 Referências

O que é Tratamento de Dados

Definição: Conjunto de práticas para transformar dados brutos em dados confiáveis, comparáveis e utilizáveis por modelos e análises.

Fluxo (Pipeline) do tratamento de dados



O fluxo mostra que primeiro, os dados são descritos e contextualizados; depois, são integrados, limpos, transformados e, por fim, validados.

Objetivo final: Produzir um dataset pronto para treino/validação do modelo de AM, com risco mínimo de erro metodológico (ex.: vazamento de dados).

Metadados

Definição: Metadados (do grego meta = "além de" + dados) são literalmente "dados sobre dados".

No contexto do pipeline de tratamento de dados, os metadados constituem a documentação estruturada e as informações descritivas que caracterizam o conjunto de dados que será processado nas etapas subsequentes.



- Metadados são a "identidade" dos seus dados. Eles respondem: O que são estes dados? De onde vieram? Como estão organizados?
- Sem metadados bem definidos, as próximas etapas do pipeline operam às cegas, aumentando o risco de interpretações equivocadas e decisões incorretas no tratamento.

Metadados

Função no Pipeline

- Descoberta e entendimento: Respondem perguntas fundamentais como "O que estes dados representam?", "De onde vieram?", "Como foram coletados?"
- Planejamento do tratamento: Fornecem informações cruciais para decisões nas próximas etapas (limpeza, transformações, validação)
- Governança e rastreabilidade: Estabelecem a procedência (lineage) dos dados, essencial para auditoria e reprodutibilidade



Metadados

No contexto de ciência de dados, os metadados podem ser classificados em três categorias principais:

Tipo	Descrição	Exemplos
Descritivos	Identificam e descrevem o conteúdo	Nome do dataset, fonte (API, banco de dados, arquivo), data de coleta, descrição do problema de negócio
Estruturais	Definem a organização dos dados	Número de linhas/colunas, tipos de dados (int, float, string, datetime), nomes das features, formato (CSV, JSON, Parquet)
Administrativos	Gerenciam o ciclo de vida	Permissões de acesso, versão do dataset, data de última atualização, responsável pela manutenção

2) Exemplo de Metadados

```
# Exemplo conceitual de metadados
metadados = {
    "nome": "dados_vendas_2025",
    "fonte": "API do sistema de vendas",
    "formato": "CSV",
    "dimensoes": {"linhas": 10000, "colunas": 15},
    "colunas": {
        "id_venda": {"tipo": "int", "descricao": "Identificador único da venda"},
        "data_venda": {"tipo": "datetime", "descricao": "Data e hora da transação"},
        "valor": {"tipo": "float", "descricao": "Valor total da venda em R$"},
        "id_cliente": {"tipo": "int", "descricao": "Chave estrangeira para tabela de clientes"}
    },
    "qualidade": {
        "valores_ausentes": {"id_venda": "0%", "data_venda": "2%", ...},
        "valores_unicos": {"id_venda": 10000, "id_cliente": 3500}
    },
    "linhagem": "Extraído em 28/02/2026 do sistema OLTP via ETL diário"
}
```

Metadados

Metadados e AM

- Para um projeto de aprendizado de máquina, temos que identificar:
  - **Atributo Alvo (Variável Alvo, Target):** definição formal do que se deseja prever
  - **Atributos (Variáveis, Features):** descrição de cada atributo, incluindo unidades de medida
  - **Período de coleta:** janela temporal dos dados
  - **Critérios de inclusão/exclusão:** regras que definem a população ou amostra analisada

OpAIoT
Optimization • AI • IoT

⚠ Importância dos Metadados para as Etapas Seguintes

Como o entendimento do dado orienta integração, limpeza, transformações e validação.

(2) Integração



Indicam a origem dos dados e como combiná-los (chaves, relacionamentos)

(3) Limpeza



Fornecem informações sobre valores esperados, domínios válidos e regras de negócio

(4) Transformações



Definem tipos de dados que orientam codificações, normalizações, etc.

(5) Validação



Estabelecem as expectativas contra as quais os dados serão validados

Integração

Definição: processo de combinar dados provenientes de diferentes fontes, formatos e estruturas em um conjunto unificado e coerente que será utilizado nas etapas subsequentes de limpeza, transformação e análise.

Por que isso é tão importante?

- No pipeline de tratamento de dados, a integração representa o segundo passo fundamental, onde os dados são reunidos e consolidados após a identificação de seus metadados.

Objetivos da Integração:

- Unificar fontes distinta ao combinar dados de múltiplos sistemas (bancos de dados, APIs, arquivos, planilhas)
- Lidar com diferentes formatos, granularidades e representações
- Estabelecer uma "única fonte da verdade" (single source of truth) para análise
- Preservar relacionamento mantendo a integridade referencial entre entidades



Integração

Exemplos comuns de integração de dados em projetos de ciência de dados.

Tipo	Descrição	Exemplo
Integração vertical	Combinar dados da mesma entidade em diferentes períodos	Dados de vendas mensais de 2023 + 2024
Integração horizontal	Combinar diferentes atributos da mesma entidade	Dados demográficos + dados de compras do mesmo cliente
Integração estrutural	Unir dados com diferentes esquemas	Tabelas de clientes (SQL) + logs de acesso (JSON)
Integração semântica	Resolver conflitos de significado	Unificar "renda mensal" (R$) e "salário anual" (US$)

Integração

Desafios comuns na integração

- Problemas frequentes ao unir fontes e como mitigá-los na prática

Desafio	Descrição	Estratégia de Solução
Inconsistência de formatos	Data em formato DD/MM/AAAA vs. AAAA-MM-DD	Padronização durante extração
Granularidade diferente	Vendas diárias vs. vendas mensais	Agregação ou desagregação
Chaves conflitantes	Mesmo cliente com IDs diferentes em sistemas distintos	Tabela de mapeamento/ matching
Dados duplicados	Cliente cadastrado múltiplas vezes	Deduplicação baseada em regras
Esquemas evoluídos	Versões diferentes do banco de dados	Versionamento de esquemas

Integração

Exemplo

```python
# Exemplo conceitual - múltiplas fontes a integrar

fontes = {
    "sistema_crm": {
        "formato": "PostgreSQL",
        "tabelas": ["clientes", "enderecos", "contratos"],
        "chave_primaria": "id_cliente"
    },
    "sistema_faturamento": {
        "formato": "CSV mensal",
        "arquivos": ["fatura_jan.csv", "fatura_fev.csv", ...],
        "chave": "cod_cliente_fatura"
    },
    "logs_uso": {
        "formato": "JSON streaming",
        "dados": "eventos de acesso ao portal",
        "chave": "customer_id"
    },
    "dados_externos": {
        "formato": "API",
        "fonte": "IBGE",
        "dados": "indicadores socioeconômicos por CEP"
    }
}

# Etapas de integração:
# 1. Mapear chaves: "id_cliente" = "cod_cliente_fatura" = "customer_id"
# 2. Definir tabela fato (ex: faturas) e dimensões (clientes, tempo)
# 3. Resolver conflitos: cliente pode estar em CRM mas sem faturas?
# 4. Criar visão unificada: dataset final com todas as features
```

OpAIoT
Optimization • AI • IoT

Universidade de São Paulo

04

Referências

- Faceli, Katti, et al. "Inteligência artificial: uma abordagem de aprendizado de máquina." (2021).
- IBM. What are metadata? Definição e importância em ciência de dados
- Google Cloud. Metadata-driven data processing
- Scikit-learn. Dataset loading utilities
- Lenzerini, M. (2002). Data Integration: A Theoretical Perspective. PODS.
- Kimball, R., & Ross, M. (2013). The Data Warehouse Toolkit
- Elmasri, R., & Navathe, S. B. (2016). Fundamentals of Database Systems





Obrigado!

opaiot@icmc.usp.br
+55 (16) 99962-7637

PROFESSOR

Dr. Cláudio Fabiano Motta Toledo

OpAIoT
Optimization • AI • IoT