ICMC USP SÃO CARLOS

USP Universidade de São Paulo



IA, Otimização e IoT para Indústrias e Negócios
Do Zero ao MLOps

PROFESSOR

Dr. Cláudio Fabiano Motta Toledo

OpAIoT
Optimization • AI • IoT

ICMC USP SÃO CARLOS

OpAIoT
Optimization • AI • IoT

Módulo 1

Fundamentos de Dados e Aprendizado de Máquina

Aplicado a Operações e Negócios

Universidade de São Paulo
Brasil

OpAIoT
Optimization • AI • IoT

Universidade de São Paulo

Tratamento de Dados

Sumário

01 Tratamento de Dados

02 Eliminação de Atributos

03 Amostra de Dados

04 Dados Desbalanceados

05 Referências

Tratamento de Dados

Definição: Conjunto de práticas para transformar dados brutos em dados confiáveis, comparáveis e utilizáveis por modelos e análises.

Fluxo (Pipeline) do tratamento de dados



Eliminação de Atributos

Eliminação de Atributos é um processo sistemático e baseado em dados que utiliza métodos estatísticos, matemáticos ou algoritmos para identificar e selecionar um subconjunto de atributos que maximizam o poder preditivo do modelo.

Eliminação Manual

- Baseada no conhecimento do problema, interpretação dos dados e objetivo do projeto.
- O analista decide remover atributos por motivos como, por exemplo:
  - redundância;
  - falta de sentido no contexto;
  - baixa utilidade prática;
- É mais explicável e alinhada ao domínio

Eliminação Automática

- Feita por critérios estatísticos ou algoritmos.
- Usa regras ou métodos como, por exemplo:
  - alta correlação;
  - baixa variância;
  - importância de atributos;
- É mais rápida, escalável e objetiva.

Dica: Combinar as duas abordagens

- Análise manual para incorporar conhecimento do problema.
- Automática para ganhar eficiência e apoiar a decisão com evidências quantitativas.

Eliminação de Atributos

A experiência daqueles que conhecem o domínio de dados costuma ser fundamental na seleção de quais atributos devem formar o conjunto de dados para se conduzir determinada análise.

Exemplo: Em um problema de **previsão de churn**, atributos identificadores como **ID_Cliente** e **Nome** costumam ser removidos, enquanto variáveis comportamentais e contratuais são mantidas para a análise.

Conjunto original

ID_Cliente	Nome	Idade	Plano	Uso_Mensal	Reclam.	Meses	Churn
1001	Ana	24	Básico	18 h	1	3	Sim
1002	Bruno	39	Premium	46 h	0	18	Não
1003	Carla	31	Padrão	12 h	3	6	Sim
1004	Diego	45	Premium	51 h	0	22	Não
1005	Elisa	29	Básico	16 h	2	5	Sim
1006	Felipe	36	Padrão	34 h	1	14	Não
1007	Gabi	27	Básico	11 h	2	4	Sim

seleção de atributos

Conjunto após a remoção

Idade	Plano	Uso_Mensal	Reclam.	Meses	Churn
24	Básico	18 h	1	3	Sim
39	Premium	46 h	0	18	Não
31	Padrão	12 h	3	6	Sim
45	Premium	51 h	0	22	Não
29	Básico	16 h	2	5	Sim
36	Padrão	34 h	1	14	Não
27	Básico	11 h	2	4	Sim

Amostra de Dados

Amostra de dados é um subconjunto representativo da população total de dados, selecionado para análise, desenvolvimento e teste quando o conjunto completo é muito grande, de difícil acesso ou quando os recursos computacionais são limitados.

Uma boa amostra deve:

- ➔ Preservar as características estatísticas da população original (distribuição, correlações, proporções de classes)
- ➔ Ser suficientemente grande para garantir significância estatística
- ➔ Ser representativa dos diferentes segmentos e padrões presentes nos dados

Tipo	Descrição	Quando usar
Amostragem aleatória simples	Cada elemento tem igual probabilidade de ser selecionado	População homogênea
Amostragem estratificada	População dividida em estratos; amostra mantém proporções	Classes desbalanceadas, dados com grupos naturais
Amostragem progressiva	aumenta progressivamente a amostra, enquanto a acurácia continuar a melhorar.	Bases muito grande, custo computacional elevado do modelo.

Amostra de Dados

Amostragem aleatória simples:

- sem reposição dos objetos selecionados do conjunto original de dados para compor a amostra;
- com reposição dos objetos selecionados, ou seja, uma cópia do objeto da conjunto original de dados é incluída na amostra.

Bootstrap é uma técnica de reamostragem com reposição usada, por exemplo, no Bagging e no Random Forest.

Amostragem estratificada:

- aplica-se quando há classes com propriedades diferentes como, por exemplo, quantidade de objetos em cada classe, onde podemos:
  - amostrar a mesma quantidade de objetos para cada classe;
  - amostrar a quantidade de objetos para cada classe proporcionalmente ao conjunto original

Amostra de Dados

Exemplo: Uma escola tem 600 alunos, divididos por série:

1ª série: 200 alunos - 2ª série: 250 alunos - 3ª série: 150 alunos

Queremos uma amostra de 60 alunos, proporcional por série.

Amostra Estratificada

- 1ª série: (200/600) × 60 = 20 alunos (33.3%)
- 2ª série: (250/600) × 60 = 25 alunos (41,7%)
- 3ª série: (150/600) × 60 = 15 alunos (25%)

Vantagens

- Garante representação de todos os grupos.
- Reduz viés amostral.
- Mais precisão comparada à amostragem aleatória simples.

Amostra de Dados

Exemplo: Uma escola tem ~~600~~ 900 alunos, divididos por série:

~~1ª série: 200 alunos~~ 1ª série: 500 alunos - 2ª série: 250 alunos - 3ª série: 150 alunos

Queremos uma amostra de 60 alunos, proporcional por série.

Amostra Estratificada

- 1ª série: (500/900) × 60 = 33 alunos (55%)
- 2ª série: (250/900) × 60 = 17 alunos (28,3%)
- 3ª série: (150/900) × 60 = 10 alunos (16,7%)

Desvantagem

- Classes majoritárias da amostra podem levar a modelos de classificação tendenciosos.
- Temos o problema de **dados desbalanceados**.

Dados Desbalanceados

Dados desbalanceados (em inglês, imbalanced data) ocorrem quando classes de um problema de classificação não estão representadas na mesma proporção, apresentando disparidade significativa no número de instâncias entre as classes

Nível de Desbalanceamento	Proporção da Classe Minoritária
Leve	20-40% do dataset
Moderado	1-20% do dataset
Extremo	Menos de 1% do dataset

- **Detecção de fraudes**: Transações fraudulentas podem representar menos de **0,1%** do total de transações
- **Detecção de spam:** E-mails legítimos geralmente superam em muito os spams
- **Manutenção preditiva:** Falhas de equipamentos são eventos raros comparados à operação normal

Dados Desbalanceados

Problemas

Modelos de AM tendem a apresentar problemas ao lidar com dados desbalanceados.

- **Classificar todas os objetos como classe majoritária para obter alta acurácia.**
  - Dataset com 95% de transações legítimas e 5% fraudulentas → modelo acerta transação "legítima" com 95% de acurácia, não detectando fraudes.

Como resolver?

- **Possível solução:** gerar novos dados seguindo a mesma distribuição estatística ou procedimento que gerou o conjunto de dados atual.
  - **Inviável na prática!!**
- Técnicas seguem em geral três abordagens:
  - Redefinir o tamanho do conjunto de dados.
  - Utilizar diferentes custos de classificação para as diferentes classes.
  - Induzir um modelo para uma classe.

Dados Desbalanceados

Redefinir o tamanho do conjunto de dados pela remoção de objetos da classe majoritária ou acréscimo de objetos à classe minoritária

- **Acréscimo de novos objetos não pode:**
  - levar a cenários ou situações que **nunca ocorrerão na prática**, prejudicando o aprendizado do modelo;
  - levar ao o**verfitting**, ou seja, modelo extremamente ajustado aos dados de treinamento.

- **Eliminação de objetos pode:**
  - levar a retirada de **dados relevantes** para o aprendizado do modelo;
  - ocasionar o **underfitting**, onde o modelo não se ajusta aos dados do treinamento.

Dados Desbalanceados

Algoritmo SMOTE

Entrada: base $S = \{(z_t, r_t), t = 1, ..., m\}$, com $r_t \in \{0,1\}$ e $r_t = 1$ para a classe minoritária.
Saída: base expandida S^+ com observações sintéticas.

1. Inicialize $S^+ \leftarrow S$.
2. Para cada observação **a** $\in S$ tal que $r_a = 1$, faça
3. Determine o conjunto $V_k(a)$ dos k vizinhos mais próximos de **a** dentro da classe minoritária.
4. Para g = 1 até a quantidade desejada de exemplos sintéticos, faça
5. Selecione aleatoriamente um vizinho $b \in V_k(\mathbf{a})$.
6. Calcule o deslocamento $d \leftarrow (b - \mathbf{a})$.
7. Sorteie $\alpha \in [0,1]$.
8. Construa a observação sintética $s \leftarrow \mathbf{a} + \alpha \cdot d$.
9. Adicione s a S^+ com $r_s = 1$.
10. Fim para
11. Fim para
12. Retorne S^+.

Dados Desbalanceados

Utilizar diferentes custos de classificação para as diferentes classes apresenta como desafio a definição adequada de tais custos.

- Por exemplo, se a **classe majoritária tem o dobro de objetos da classe minoritária**, quando o modelo classifica incorretamente um objeto da classe minoritária, isso equivale à ocorrência de **dois erros de classificação para um objeto da classe majoritária**.

A definição dos diferentes custos não é tão direta:

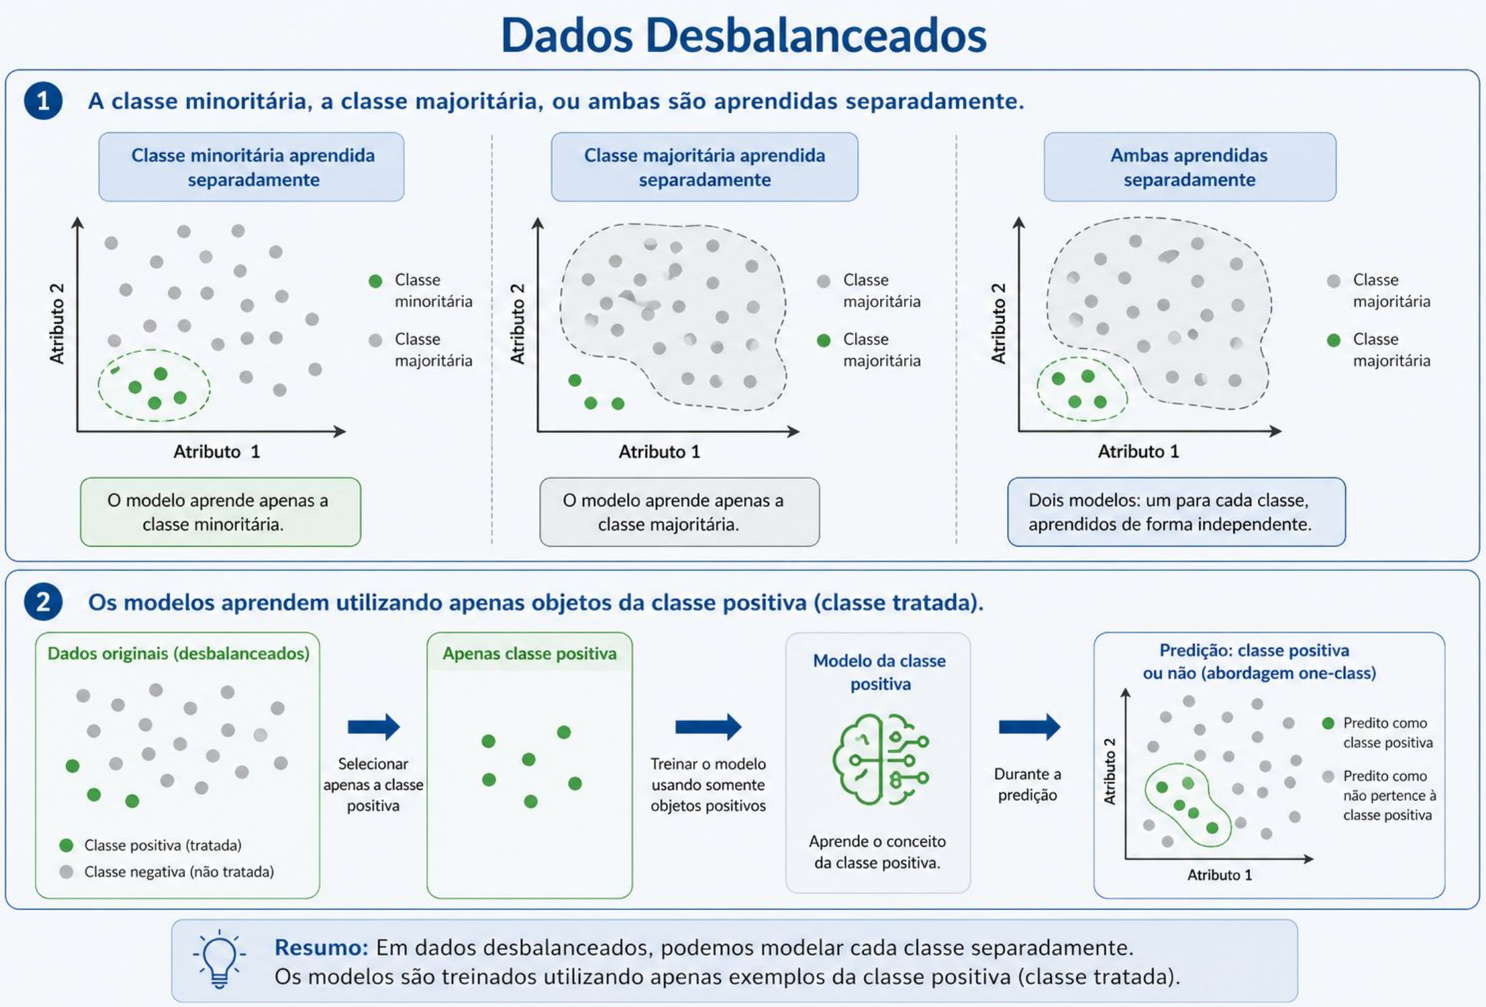
- A grande quantidade de objetos semelhantes na classe majoritária pode tornar sua distribuição próxima à da classe minoritária, fazendo com que diferentes custos favoreçam a classificação da classe minoritária

Dados Desbalanceados

OpAIoT
Optimization • AI • IoT

Induzir um modelo para uma classe, onde se utiliza um modelo de classificação para cada classe.

- A classe minoritária, a classe majoritária, ou ambas são aprendidas separadamente.
- Os modelos aprendem utilizando apenas objetos da classe positiva (classe tratada).



OpAIoT
Optimization • AI • IoT

Universidade de São Paulo

Referências

- Faceli, Katti, et al. "Inteligência artificial: uma abordagem de aprendizado de máquina." (2021).
- Ruslan, R. A., & Arbaiy, N. (2024). Handling Imbalanced Datasets in Machine Learning: Challenges, Approaches, and Best Practices. Journal of Applied Science, Technology and Computing.
- Google Developers. Dados desbalanceados - Guia de ML





Obrigado!

opaiot@icmc.usp.br
+55 (16) 99962-7637

PROFESSOR

Dr. Cláudio Fabiano Motta Toledo

OpAIoT
Optimization • AI • IoT