ICMC USP SÃO CARLOS

USP Universidade de São Paulo



IA, Otimização e IoT para Indústrias e Negócios
Do Zero ao MLOps

PROFESSOR

Dr. Cláudio Fabiano Motta Toledo

OpAIoT
Optimization • AI • IoT

ICMC USP SÃO CARLOS

OpAIoT
Optimization • AI • IoT

Módulo 1

Fundamentos de Dados e Aprendizado de Máquina

Aplicado a Operações e Negócios

Universidade de São Paulo
Brasil

OpAIoT
Optimization • AI • IoT

Universidade de São Paulo

Limpeza de Dados

Sumário

01 .O que é Limpeza de Dados?

02 Dados Incompletos

03 Dados Inconsistentes

04 Dados Redundantes

Definição: Processo de identificar e corrigir (ou remover) registros imprecisos, incompletos, inconsistentes ou irrelevantes de um banco de dados, planilha ou conjunto de dados.

Fluxo (Pipeline) do tratamento de dados



Ignorar essa etapa pode levar a conclusões erradas e prejuízos financeiros significativos.

Objetivo final: melhorar a qualidade dos dados, garantindo que estejam precisos, consistentes e prontos para análise, modelagem ou tomada de decisão.

- Dados limpos são a base para uma boa Inteligência de Negócios (BI) e modelos de Aprendizado de Máquina (AM).
- Estima-se que cientistas de dados gastem de 60% a 80% do seu tempo em atividades de preparação e limpeza de dados, justamente porque essa etapa é crucial para garantir a confiabilidade dos resultados.

Problema	Descrição	Exemplo Comum
Dados Incompletos	Campos que estão vazios ou nulos (null).	Cliente sem informação de idade ou CPF.
Dados Inconsistentes	Formatos ou unidades diferentes para a mesma informação.	Datas no formato DD/MM/AAAA e AAAA-MM-DD no mesmo arquivo.
Dados Redundantes	Registros repetidos sobre a mesma entidade.	O mesmo cliente cadastrado duas vezes com pequenas variações no nome.

Dados incompleto se referem à ausência de valores para alguns dos atributos em parte dos dados.

Eliminar os objetos com valores ausente.

➔ Não recomendada quando

- Há poucos atributos do objeto.
- O número de atributos com valores ausentes varia muito entre os objetos.
- O número de objetos que restarem for pequeno.

Definir e preencher manualmente valores para os atributos com valores ausentes.

➔ Não pode ser utilizada quando o número de objetos ou atributos com valores ausentes for muito grande.

Aplicar um método ou heurística para automaticamente definir valores ausente para atributos.

➔ Alternativa mais utilizada.

Utilizar técnicas de aprendizado de máquina que lidam com valores ausentes.

➔ Por exemplo, usa a distância entre os vizinhos mais próximos para estimar valores ausentes.

Definição automática de valores ausentes

1ª Abordagem

Utilizar um novo valor para indicar que aquele atributo tinha um valor ausente.

- ➔ O novo valor pode ser o mesmo para todos os atributos, ou um valor diferente para cada atributo.
- ➔ O algoritmo aplicado pode entender que tal valor indica algo relevante para o problema.

2ª Abordagem

Utilizar o valor de uma métrica

- ➔ Média, moda ou mediana dos valores conhecidos para um atributo.
- ➔ Valor mais frequente nos k objetos semelhantes ao objeto com valor faltante.
- ➔ Se os objetos apresentam relação no tempo, calcular considerando o valor dos objetos nos instantes imediatamente anterior e posterior

3ª Abordagem

Utilizar um indutor para estimar o valor do atributo.

- ➔ Aplica-se quando o atributo alvo está ausente.
- ➔ Os demais atributos são utilizados como atributos de entrada para inferir o valor do atributo ausente.
- ➔ Toma-se como base o valor empregado em objetos semelhantes.

Dados inconsistentes apresentam valores conflitantes em seus atributos.

- ➔ Inconsistência entre valores de atributos de entrada
- ➔ Inconsistência entre os valores dos atributos de entrada e o valor do atributo alvo
- ➔ Inconsistências nas relações conhecidas entre os atributos.

Registro	Idade	Peso (kg)	Glicose (mg/dL)	Diagnóstico
R1	35	72	95	Sem risco
R2	**3**	**450**	88	Sem risco
R3	42	80	**92**	**Diabetes grave**
R4	29	68	97	Sem risco
R5	55	90	160	Alto risco

glicose normal e “diabetes grave”

Dados redundantes apresentam tanto objetos quanto atributos redundantes

Objeto redundante apresenta valores de atributos muito semelhante a outro objeto.

➔ A técnica de aprendizado de máquina pode dar ao objeto repetido uma relevância maior.

Exceção: Boosting é uma técnica de aprendizado de máquina que duplica a quantidade de objetos difíceis de ser classificada.

Registro	Idade	Peso (kg)	Glicose (mg/dL)	Diagnóstico
R1	35	72	95	Sem risco
R2	55	90	160	Alto risco
R3	42	80	92	Sem risco
R4	29	68	97	Sem risco
R5	55	90	160	Alto risco

Dados redundantes apresentam tanto objetos quanto atributos redundantes

Atributo redundante contém valores que podem ser obtidos de outros atributos.

➔ Idade e Data de Nascimento no mesmo conjunto de dados.

Registro	Nasc	Idade	Peso (kg)	Glicose (mg/dL)	Diagnóstico
R1	11/02/1991	35	72	95	Sem risco
R2	21/03/1971	55	90	160	Alto risco
R3	18/12/1984	42	80	92	Sem risco
R4	10/08/1997	29	68	97	Sem risco
R5	27/05/1971	55	90	160	Alto risco

Também ocorrem pela correlação com outros atributos do conjunto de dados.

Atenção: Se tal correlação aparece entre um atributo de entrada e um atributo alvo, isso significa uma grande influência do atributo de entrada na predição do valor do atributo alvo.

OpAIoT
Optimization • AI • IoT

Universidade de São Paulo

Referências

- Faceli, Katti, et al. "Inteligência artificial: uma abordagem de aprendizado de máquina." (2021).
- Han, J., Kamber, M., & Pei, J. (2011). Data Mining: Concepts and Techniques (3rd ed.). Morgan Kaufmann.





Obrigado!

opaiot@icmc.usp.br
+55 (16) 99962-7637

PROFESSOR

Dr. Cláudio Fabiano Motta Toledo

OpAIoT
Optimization • AI • IoT