ICMC USP SÃO CARLOS

USP Universidade de São Paulo



IA, Otimização e IoT para Indústrias e Negócios
Do Zero ao MLOps

PROFESSOR

Dr. Cláudio Fabiano Motta Toledo

OpAIoT
Optimization • AI • IoT

ICMC USP SÃO CARLOS

OpAIoT
Optimization • AI • IoT

Módulo 1

Fundamentos de Dados e Aprendizado de Máquina

Aplicado a Operações e Negócios

Universidade de São Paulo
Brasil

OpAIoT
Optimization • AI • IoT

Universidade de São Paulo

Limpeza de Dados: Ruído e Outlier

Sumário

01 Ruído

02 Outliers

03 Técnicas de Remoção

04 Referências

Ruído

Definição: variância ou erro aleatório no valor gerado ou medido para um atributo

Dados com ruídos apresentam objetos que parecem **não pertencer à distribuição** que gerou os dados analisados.

Matematicamente, podemos representar o processo de geração de dados ruidosos como:

$$y = f(\mathbf{X}) + \epsilon$$

y : *variável alvo*, $f(\mathbf{X})$: *função que desejamos aprender*, ϵ : *ruído*

Formulação conhecida como modelo de ruído aditivo, pois assume que o ruído é independente das features e possui distribuição simétrica em torno de zero.

Ruído

Tipos de Ruído: Muito Além de "Dados Sujos"

A literatura e a prática classificam o ruído de formas mais sofisticadas. Compreender essas diferentes categorias é fundamental para escolher as estratégias de mitigação adequadas.

Ruído nos Rótulos

O rótulo da classe está incorreto. Exemplo: Uma imagem de um gato rotulada como "cachorro". É um dos tipos mais prejudiciais.

Ruído nas Features

Os valores dos atributos estão corrompidos. Exemplo: Um sensor de temperatura com leitura de 40°C em um dia de inverno.

Ruído de Sensor

Variações inerentes à coleta de dados por hardware. Exemplo: Ruído em imagens com pouca luz, ou leituras instáveis de um GPS.

Ruído Adversarial

Ruído **intencionalmente** inserido para enganar o modelo. Exemplo: Pequenas alterações em uma imagem que fazem um carro autônomo confundir uma placa de "PARE" com outra.

Ruído Determinístico

Surge quando o fenômeno é inherentemente complexo. O modelo vê essa complexidade não-modelada como ruído.

Outliers

- **Definição:** Outliers (ou valores atípicos, pontos fora da curva) são observações que se diferenciam significativamente das demais, ou seja, que não seguem a tendência geral do restante do conjunto de dados . São valores que parecem ser inconsistentes em relação à distribuição da amostra.

Causas:

- **Erro ou Falha:** Pode ser fruto de um erro de digitação, mau funcionamento de um sensor, ou uma falha no processo de coleta de dados.
- **Evento Genuíno e Raro:** Pode representar um evento real, porém incomum, que é justamente o objeto de interesse da análise, como uma transação fraudulenta, uma falha crítica em um equipamento ou um comportamento excepcional de cliente

Outliers

O ruído é uma contaminação difusa, enquanto o outlier é uma exceção pontual.

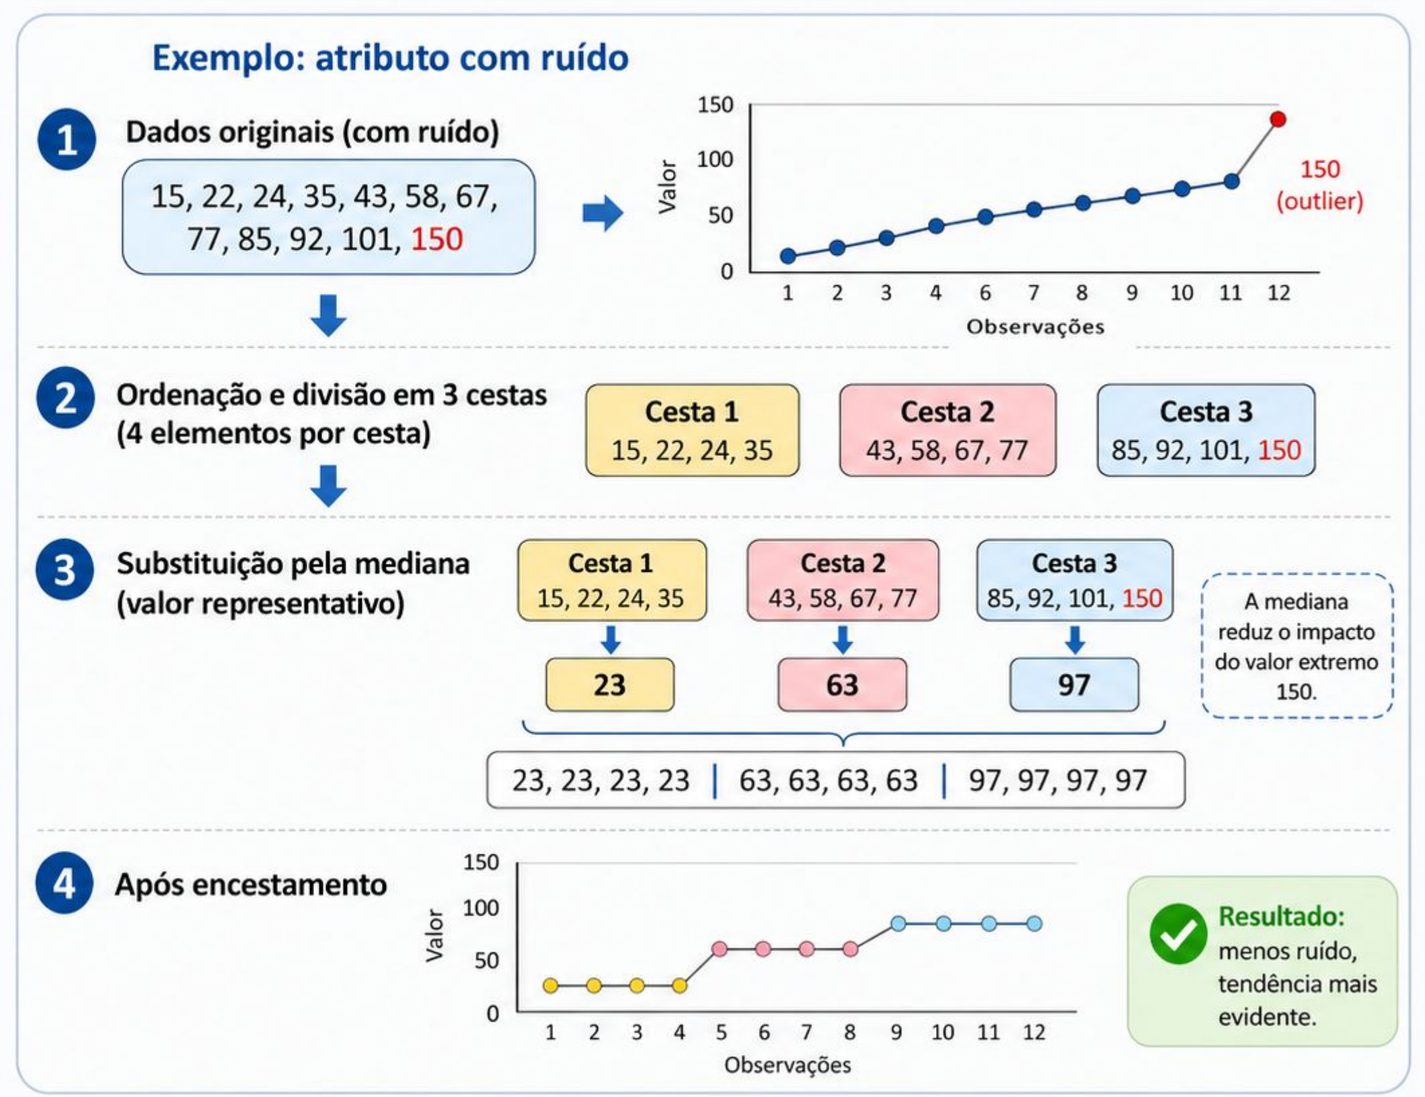
Diferenças Cruciais: Ruído vs. Outlier

Característica	Ruído	Outlier
Natureza	**Variação aleatória** e **inerente** ao processo.	**Desvio pontual** e significativo do padrão .
Ocorrência	**Presente** em (quase) todas as observações, em maior ou menor grau.	Ocorre **raramente**, em observações isoladas.
Causa	Erros de medição não-sistemáticos, fatores não observados, aleatoriedade natural .	Erros grosseiros, eventos raros, fraudes, anomalias .
Valor da Informação	**Nenhum**. É uma interferência que esconde o sinal.	**Potencialmente alto**. Pode ser a descoberta mais importante (ex: fraude) ou um erro a ser corrigido .
Impacto no Modelo	Degrada a performance geral, tornando as previsões menos precisas e contribuindo para o erro irredutível .	Pode distorcer completamente o modelo, enviesando parâmetros e levando a conclusões erradas, especialmente em modelos lineares .
Tratamento Típico	Técnicas de suavização, filtragem (e.g., Filtro de Kalman), ou uso de modelos robustos.	Investigação, análise de causa raiz, e então decisão: remover, corrigir ou manter (se for o foco da análise)

Técnicas de Remoção

Técnicas de encestamento

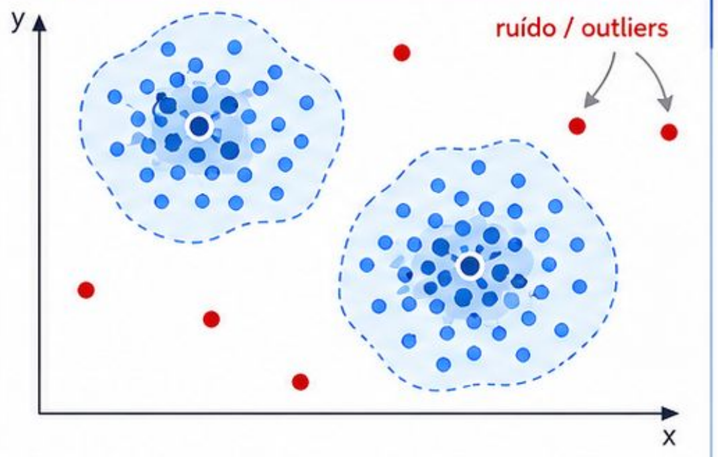
- Os valores encontrados para esse atributo em todos os objetos são ordenados.
- Os valores ordenados são divididos em faixas ou cestas com o mesmo número de valores.
- Os valores em uma mesma cesta são substituídos, por exemplo, pela média dos valores presentes na cesta.



Técnicas de Remoção

Técnicas baseadas em agrupamento dos dados: aplicadas tanto para objetos quanto para atributos, onde valores fora dos grupos são considerados ruídos ou outliers.

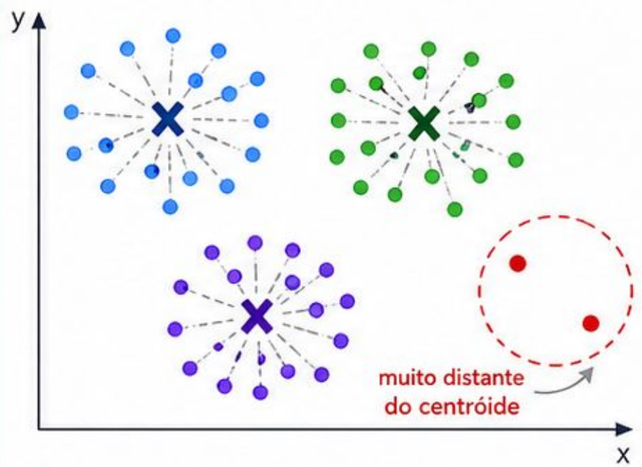
1) DBSCAN
(Density-Based Spatial Clustering)



- Identifica ruídos como pontos fora de regiões densas.
- Ideal para detectar outliers automaticamente.

Resultado:
pontos isolados marcados como ruído.

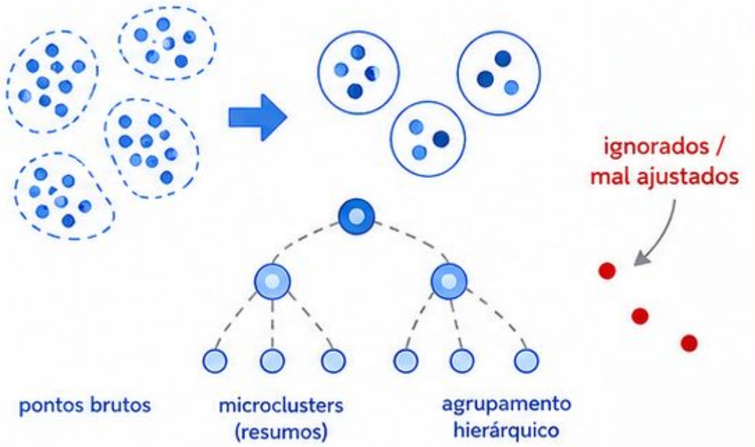
2) K-Means
com detecção de outliers



- Usa a distância ao centróide para excluir pontos distantes.
- Simples, mas sensível à forma do cluster.

Resultado:
pontos muito distantes são tratados como outliers.

3) BIRCH



- Agrupa de forma hierárquica e ignora pontos mal ajustados.
- Muito eficiente para grandes volumes de dados.

Resultado:
resume grupos densos e reduz a influência de pontos anômalos.

Técnicas de Remoção

Técnicas baseadas em distância

- Em contextos supervisionados, podem analisar os vizinhos mais próximos de um objeto para verificar se eles pertencem majoritariamente à mesma classe desse objeto.
- Quando a maioria dos vizinhos pertence a outra classe, o objeto pode ser um candidato a ruído, a erro de rotulação ou simplesmente um ponto próximo à fronteira entre classes

Local Outlier Factor (LOF)

- Compara a densidade local de um ponto com a de seus vizinhos.
- Pontos com densidade significativamente menores são considerados outliers.
- Considera contexto local; mais robusto que métodos globais.

Z-Score (Distância Estatística) $z = \frac{x-\mu}{\sigma}$

- Usa média e desvio padrão para detectar valores que se afastam do centro da distribuição.
- Se |z| > 3, por exemplo, pode ser considerado ruído.
- Simples e eficiente para dados normalmente distribuídos.

Técnicas de Remoção

Técnicas baseadas em regressão/classificação: identificam objeto com grande erro ou rótulo suspeito.

- Aplicam uma função de regressão para, dado um possível outlier ou ruído, estimar seu valor verdadeiro.
- Se o valor a ser estimado for simbólico, uma técnica de classificação pode ser utilizada.

- Regressão com Análise de Resíduos
- Classificação com Rótulos Corrompidos (Noisy Labels)
- Modelos Ensembles para Detecção de Inconsistências

Técnicas de Remoção

Regressão com Análise de Resíduos

- Ajusta-se um modelo de regressão (ex: Linear Regression).
- Observa-se a diferença entre o valor previsto e o real (resíduo).
- Valores com resíduos extremos (ex: |erro| > 3×desvio padrão) são marcados como ruído.
- Ideal para remoção de ruído em dados numéricos.

Classificação com Rótulos Corrompidos (Noisy Labels)

- Treina-se um classificador (ex: Decision Tree, SVM).
- Identifica-se instâncias sistematicamente mal classificadas.
- Possível ação: remover ou reavaliar o rótulo.
- Muito usado em tarefas de limpeza de datasets rotulados.

Técnicas de Remoção

Modelos Ensembles para Detecção de Inconsistências

- Usa múltiplos modelos para verificar consistência nas previsões.
- Instâncias com alta variabilidade de predição entre modelos = possível ruído.
- Estratégia robusta e adaptável a diferentes tipos de dados.

OpAIoT
Optimization • AI • IoT

Universidade de São Paulo

04

Referências

- Faceli, Katti, et al. "Inteligência artificial: uma abordagem de aprendizado de máquina." (2021).
- Han, J., Kamber, M., & Pei, J. (2011). Data Mining: Concepts and Techniques (3rd ed.). Morgan Kaufmann.





Obrigado!

opaiot@icmc.usp.br
+55 (16) 99962-7637

PROFESSOR

Dr. Cláudio Fabiano Motta Toledo

OpAIoT
Optimization • AI • IoT