ICMC USP SÃO CARLOS

USP Universidade de São Paulo



IA, Otimização e IoT para Indústrias e Negócios
Do Zero ao MLOps

PROFESSOR

Dr. Cláudio Fabiano Motta Toledo

OpAIoT
Optimization • AI • IoT

ICMC USP SÃO CARLOS

OpAIoT
Optimization • AI • IoT

Módulo 1

Fundamentos de Dados e Aprendizado de Máquina

Aplicado a Operações e Negócios

Universidade de São Paulo
Brasil

OpAIoT
Optimization • AI • IoT

Universidade de São Paulo

Transformação de Dados

Sumário

O que é Transformação de Dados?

Tipos de Atributo

Conversão Simbólico-Numérico

Referências

Definição: processo de modificar, converter ou mapear dados brutos de seu formato original para um formato mais adequado para análise e modelagem.

Por que isso é tão importante?

- Técnicas de aprendizado de máquinas podem estar limitadas à manipulação de valores de determinados tipos, por exemplo, apenas valores numéricos ou apenas valores simbólicos.
- Por isso, a transformação dos dados em uma base se torna necessária e pode ser feita de diversas formas.
  - Simbólico-Numérico
  - Numérico-Simbólico
  - Numérico-Numérico

Atributos Qualitativos

- Também chamados de atributos simbólicos ou categóricos.
  - x∈ {alerta, normal} ou x ∈ {manhã, tarde, noite}
- Não se consegue aplicar operações aritméticas aos seus valores.
- **Nominal:** valores são categorias sem qualquer ordenação natural ou hierarquia. Categorias são "nomes" ou rótulos para distinguir grupos.
- **Ordinal**: valores são categorias que possuem uma ordem ou hierarquia

index	Num_partidas_dia	temperatura_media	vibracao_rms	tipo_operacao	turno	nivel_desgaste	classe_falha
0	6	65.7	2.14	moderada	manha	alto	alerta
1	7	75.89	2.69	moderada	noite	baixo	normal
2	6	72.3	2.47	moderada	noite	alto	alerta
3	7	71.23	3.83	leve	tarde	baixo	normal
4	7	62.46	2.82	moderada	noite	baixo	normal
5	6	89.44	3.6	leve	manha	baixo	alerta
6	11	65.2	3.11	leve	noite	baixo	normal
7	4	69.7	1.18	moderada	manha	critico	normal
8	8	68.13	1.94	moderada	manha	medio	normal
9	6	89.55	2.45	pesada	manha	baixo	alerta

Atributos Quantitativos

- Os atributos quantitativos possuem valores numéricos.
  - Discretos: $x \in Z$
  - Contínuos: $x \in R$.
- Podem ser ordenados e as operações aritméticas podem ser aplicadas.
- Um caso especial são os atributos booleanos ou binários com $x \in \{0, 1\}$, representando falso ou verdadeiro, não ou sim, ausência ou presença, falha ou sucesso, etc.

index	Num_partidas_dia	temperatura_media	vibracao_rms	tipo_operacao	turno	nivel_desgaste	classe_falha
0	6	65.7	2.14	moderada	manha	alto	alerta
1	7	75.89	2.69	moderada	noite	baixo	normal
2	6	72.3	2.47	moderada	noite	alto	alerta
3	7	71.23	3.83	leve	tarde	baixo	normal
4	7	62.46	2.82	moderada	noite	baixo	normal
5	6	89.44	3.6	leve	manha	baixo	alerta
6	11	65.2	3.11	leve	noite	baixo	normal
7	4	69.7	1.18	moderada	manha	critico	normal
8	8	68.13	1.94	moderada	manha	medio	normal
9	6	89.55	2.45	pesada	manha	baixo	alerta

Transforma dados qualitativos como texto ou categorias em representações numéricas que possam ser processadas por algoritmos de aprendizado de máquina

Por que isso é tão importante?

- Selecionar a técnica de codificação adequada é uma decisão crítica de engenharia de atributos (feature engineering), pois impacta a capacidade do modelo de interpretar corretamente as relações entre os dados.

Também chamado **Encoding** (codificação), onde a técnica utilizada depende do atributo ser nominal ou ordinal.

- Se não há relação de ordem entre os valores do atributo, isso deve ser preservado para os valores numéricos gerados.

Tipos de Encoding

- Label Encoding
- One-Hot Encoding
- Binary Encoding
- Frequency Encoding
- Target Encoding
- Ordinal Encoding
- Embedding

Codificação de rótulos (Label Encoding): Atribui um número inteiro único para cada categoria distinta.

```
# Exemplo: Algoritmo não entende "azul", "vermelho", "verde"
cores = ["azul", "vermelho", "verde", "azul", "verde"]

# Precisamos converter para números:
cores_codificadas = [0, 1, 2, 0, 2]  # azul=0, vermelho=1, verde=2
```

Vantagem:

- Simples e eficiente
- Não aumenta dimensionalidade

Desvantagem:

- Introduz ordenação artificial (azul < vermelho < verde)
- Pode enganar modelos que interpretam ordem

One-Hot Encoding:: cria colunas binárias (0/1) para cada categoria.

Para cada observação, apenas uma entrada da coluna terá valor 1 (hot), as demais ficam com 0 (cold).

- A diferença entre dois valores pode utilizar a distância de Hamming que indica o número de posições em que as sequências apresentam valores diferentes.
- A distância de Hamming entre qualquer par de valores é igual a 2, ou seja, apenas duas posições do string binário têm valores diferentes.

Exemplo de One-Hot Encoding

Cor	Azul	Vermelho	Verde
Azul	1	0	0
Vermelho	0	1	0
Verde	0	0	1

Vantagem:

- Não impõe ordem artificial
- Matematicamente correto para categorias nominais

Desvantagem:

- Aumenta dimensionalidade
- Pode causar multicolinearidade

Quando usar: Variáveis nominais sem ordem, com poucas categorias (< 10-20)

Binary Encoding: combina características de one-hot e label encoding, convertendo categorias para números e depois para representação binária.

Passos:

1. Cada categoria é convertida para um número inteiro;
2. Cada número é convertido para binário.

Cor	Categoria
Azul	1
Verde	2
Vermelho	3
Amarelo	4



Cor	B1	B2	B3
Azul	0	0	1
Verde	0	1	0
Vermelho	0	1	1
Amarelo	1	0	0

Vantagem:

- reduz a quantidade de colunas;
- útil para atributos com alta cardinalidade;
- costuma ser mais eficiente que one-hot em memória e dimensionalidade.

Binary Encoding: combina características de one-hot e label encoding, convertendo categorias para números e depois para representação binária.

Passos:

1. Cada categoria é convertida para um número inteiro;
2. Cada número é convertido para binário.

Cor	Categoria
Azul	1
Verde	2
Vermelho	3
Amarelo	4



Cor	B1	B2	B3
Azul	0	0	1
Verde	0	1	0
Vermelho	0	1	1
Amarelo	1	0	0

Desvantagem:

- representação menos intuitiva, interpretável;
- modelos podem interpretar padrões binários de forma menos natural do que com one-hot;
- não preserva ordem semântica entre categorias, ou seja, a proximidade entre códigos binários não quer dizer proximidade conceitual.

Quando usar:

- Variável categórica com muitas categorias,pois ocupa menos colunas do que one-hot
- Para variável nominal

Quando não usar:

- Para variável ordinal: geralmente faz mais sentido usar uma codificação que respeite a ordem, como baixo=1, médio=2, alto=3.

Ordinal Encoding: Similar ao label encoding, mas com ordenação significativa, onde cada categoria é substituída por um número inteiro que respeita a ordem natural entre as categorias

index	nivel_desgaste
0	alto
1	baixo
2	alto
6	baixo
7	critico
8	medio
9	baixo



index	nivel_desgaste
0	3
1	1
2	3
6	1
7	4
8	2
9	1

Baixo = 1, médio = 2, alto = 3, crítico = 4.

Quando usar:

- A variável categórica apresenta ordem natural, por exemplo:
  - risco: baixo, médio, alto
  - prioridade: baixa, média, alta.

Vantagem:

- simples de entender e implementar;
- cria apenas uma coluna por variável;
- preserva a ordem entre as categorias;
- útil para muitos modelos e bases pequenas ou médias.

Desvantagem:

- pode sugerir que a distância entre categorias é uniforme, o que nem sempre é verdade.
  - a diferença entre desgaste crítico e alto não necessariamente é a mesma que entre alto e médio

Frequency Encoding: técnica de codificação de variáveis categóricas em que cada categoria é substituída pela sua frequência de ocorrência no conjunto de dados.

index	nivel_desgaste
0	alto
1	baixo
2	alto
6	baixo
7	critico
8	medio
9	baixo

Baixo = 3/7=0.43,
médio = 1/7=0.14,
alto = 2/7=0.29,
crítico = 1/7=0.14.

index	Freq nivel_desgaste
0	0.29
1	0.43
2	0.29
6	0.43
7	0.14
8	0.14
9	0.43

index	Contagem nivel_desgaste
0	2
1	3
2	2
6	3
7	1
8	1
9	3

Quando usar:

- variável categórica tem muitas categorias e você quer uma representação compacta.

Vantagem:

- gera só uma coluna por variável;
- bom para muitas categorias;
- simples de implementar;
- evita explosão de dimensionalidade como ocorre no one-hot encoding.

Desvantagem:

- Perda de identidade entre categorias diferentes
- Não representa significado nem ordem
- Forte dependência da distribuição dos dados

Resumo

Encoding é a ponte entre os dados do mundo real (textos e categorias) e a representação numérica usada pelos algoritmos de AM. A escolha do método depende de:

- Natureza da variável (nominal ou ordinal)
- Número de categorias (poucas ou muitas)
- Modelo utilizado (árvores, redes neurais, regressão etc.)
- Custo computacional (one-hot pode ser oneroso)

A regra de ouro: entenda seus dados antes de codificá-los. Uma escolha inadequada de encoding pode introduzir vieses artificiais e reduzir o desempenho do modelo.

OpAIoT
Optimization • AI • IoT

Universidade de São Paulo

Referências

- Faceli, Katti, et al. "Inteligência artificial: uma abordagem de aprendizado de máquina." (2021).
- Ruslan, R. A., & Arbaiy, N. (2024). Handling Imbalanced Datasets in Machine Learning: Challenges, Approaches, and Best Practices. Journal of Applied Science, Technology and Computing.
- Google Developers. Dados desbalanceados - Guia de ML





Obrigado!

opaiot@icmc.usp.br
+55 (16) 99962-7637

PROFESSOR

Dr. Cláudio Fabiano Motta Toledo

OpAIoT
Optimization • AI • IoT