ICMC USP SÃO CARLOS

USP Universidade de São Paulo



IA, Otimização e IoT para Indústrias e Negócios
Do Zero ao MLOps

PROFESSOR

Dr. Cláudio Fabiano Motta Toledo

OpAIoT
Optimization • AI • IoT

ICMC USP SÃO CARLOS

OpAIoT
Optimization • AI • IoT

Módulo 1

Fundamentos de Dados e Aprendizado de Máquina

Aplicado a Operações e Negócios

USP Universidade de São Paulo
Brasil

OpAIoT
Optimization • AI • IoT

Universidade de São Paulo

Engenharia de Atributos: Criação de Atributos e Redução de Dimensionalidade

Sumário

01 O que é Engenharia de Atributos (Features Engineering)?

02 Criação de Atributos

03 Redução de Dimensionalidade

O que é Engenharia de Atributos (Features Engineering)?

Definição: criação, transformação, seleção e redução de atributos para aproximar os dados da estrutura que o modelo realmente precisa enxergar.

Não Confundir

- **Feature engineering** é criar ou transformar atributos.
- **Feature selection** é escolher quais atributos ficarão no modelo.
- **Feature extraction** costuma significar transformar dados brutos em atributos numéricos utilizáveis, como texto em vetores.

coluna original: data_compra

feature engineering:

criar *dia_da_semana, mês, fim_de_semana*

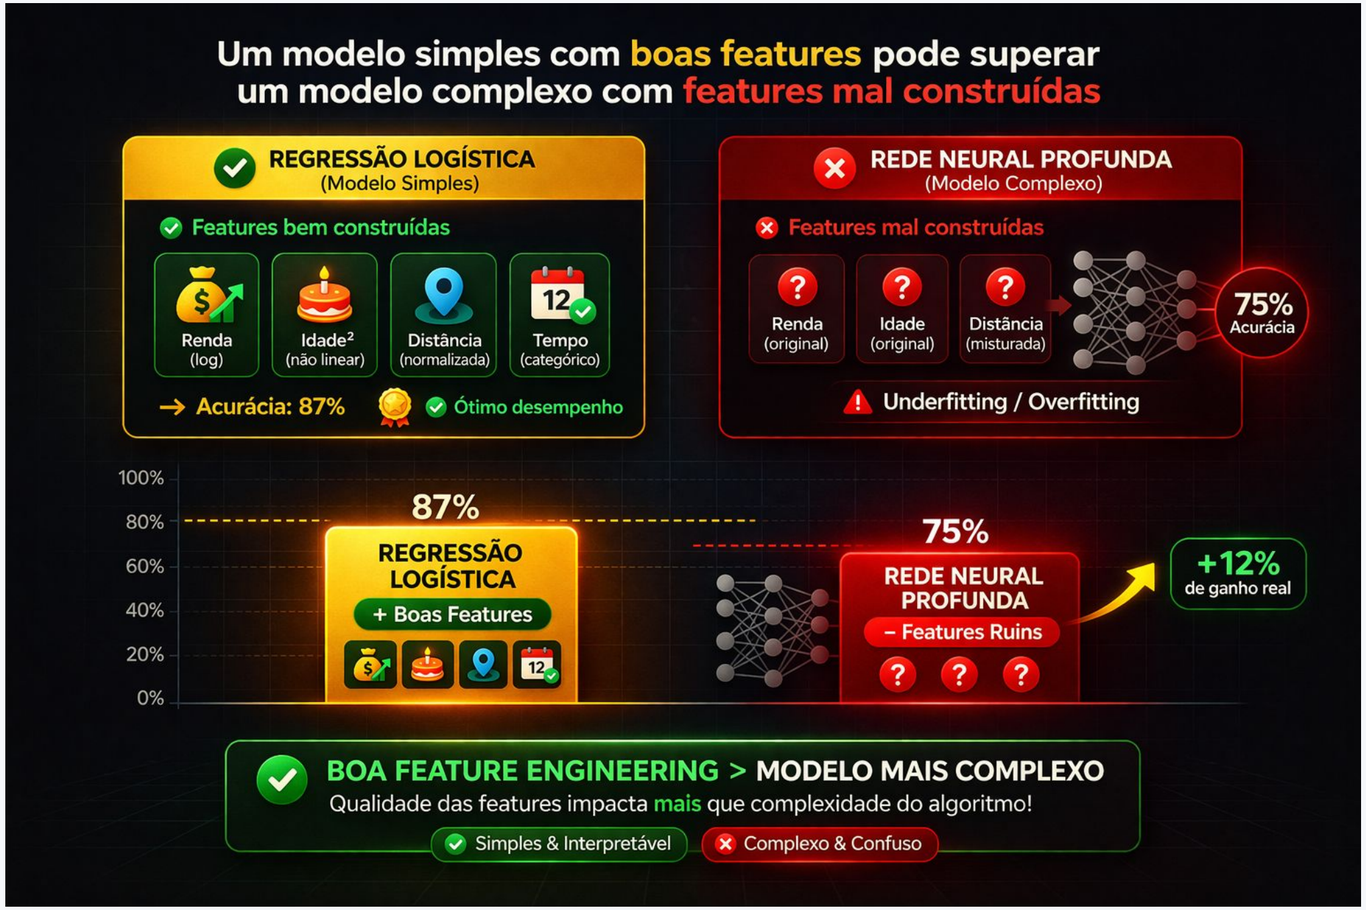
feature selection:

decidir se *mês* e *fim_de_semana* entram no modelo, mas *dia_da_semana* não

Um modelo pode ter um desempenho fraco não porque “o modelo é ruim”, mas porque os atributos estão representados de um jeito que dificulta a descoberta dos padrões ou relações.

Por que isso é tão importante?

- A EDA formula a hipótese; a engenharia de atributos a transforma em atributo.
- A informação útil pode já estar no conjunto de dados, mas escondida em uma forma que o modelo usa mal.
- Construção das variáveis/atributos é, muitas vezes, o fator mais determinante para o sucesso de um projeto preditivo



Consiste em derivar novas variáveis a partir dos dados brutos, com o objetivo de:

- Capturar relações não lineares
- Incorporar conhecimento de domínio
- Facilitar que o modelo aprenda padrões relevantes

Transformação

Situação observada	Feature criada	Por que ajuda?
faturamento muito assimétrico	**log(faturamento)**	comprime a cauda e reduz o peso de extremos
saldo e limite isolados	**saldo/limite**	condensa o risco em “uso do crédito”
idade exata pouco estável	**faixa etária**	preserva padrão geral e reduz ruído local
escalas muito diferentes	**padronização**	evita que uma coluna domine o ajuste
Canal de contato (loja, app, site)	**one-hot encoding**	categorias precisam virar números

A pergunta prática é: “qual transformação faz esta coluna representar melhor o fenômeno?”.

- **Transformações Numéricas** ajudam a aproximar relações não lineares e estabilizar variâncias.
- **Codificação de Variáveis Categóricas (Encoding)** se torna fundamental para modelos lineares.
- **Dados faltantes** também podem ser informativos.
  - Se **saldo** não foi preenchido, isso pode significar perfil incompleto ou falha de coleta. Por isso, combina-se **imputação** com um **indicador de ausência**.

Atributos Temporais e Cíclicos

- Muitas informações úteis não estão na data bruta, mas em atributos derivados.
  - Padrões mudam por hora do dia, dia da semana, mês e sazonalidade anual.
  - Se houver ciclicidade, pode ser melhor representar hora usando seno e cosseno, porque 23h e 0h são próximas no ciclo, embora numericamente 23 e 0 pareçam distantes.

2026-03-21 08:00 →

- **hora = 8**
- **sábado**
- **mês = 3**
- **fim de semana = 1**

$$\text{hora}_{sin} \qquad \text{hora}_{cos}$$

$$\sin\left(2\pi\frac{hora}{24}\right), \quad \cos\left(2\pi\frac{hora}{24}\right)$$

Hora
0
6
12
18
23

⇨

$(\text{hora}_{sin}, \text{hora}_{cos})$ aproximado
(0.00, 1.00)
(1.00, 0.00)
(0.00, -1.00)
(-1.00, 0.00)
(-0.26, 0.97)

Atributos de Interação

- Capturam efeitos conjuntos entre variáveis
- Interações são especialmente importantes em modelos lineares, onde não há captura automática desses efeitos.
- Em árvores, interações podem emergir naturalmente, mas ainda assim a criação explícita pode ajudar.

Exemplo: Prever as vendas de sorvete usando temperatura e fim de semana.

temperatura **fim_de_semana**

temperatura× fim_de_semana

$$y = \beta_1 \text{temperatura} + \beta_2 \text{fim_de_semana} + \beta_3 \text{temperaturaxfim_de_semana}$$

Atributos agregados ou de razão

- O atributo relevante não é bruto, mas uma razão, média, desvio ou contagem.
- Esse tipo de feature é exatamente o tipo de “functional relationship among predictors” citado por Kuhn e Johnson. (Bookdown)

Exemplo: Ao invés de avaliar isoladamente energia_kwh e pecas_produzidas, mede-se a eficiência operacional pela razão dos atributos.

energia_kwh **pecas_produzidas**

eficiência_operacional = energia_kwh / pecas_produzidas

Exemplo: Suponha 12 leituras de temperatura ao longo de 1 hora. Ao invés de usar todas separadamente, podemos criar: media_temperatura_1h e desvio_temperatura_1h

Útil quando há muitas colunas correlacionadas e queremos compactar informação





Maldição da dimensionalidade

- O aumento na dimensão dos dados (número de atributos) gera um aumento exponencial na demanda por dados para treinar modelos de aprendizado de máquina gerais e precisos o suficiente.
- Duas abordagens para redução de dimensionalidade:
  - Agregação
  - Seleção de Atributos

Agregação

- Substitui os atributos originais por novos atributos formados pela combinação de grupos de atributos, através de funções lineares ou não lineares.
- **Análise de Componentes Principais** é um exemplo de método que avalia a correlação dos atributos, reduzindo a dimensionalidade do conjunto de dados original pela eliminação de redundâncias.

Desvantagem

- A combinação de atributos em técnicas de agregação pode levar à perda dos valores originais.
- A preservação de valores pode ser relevante em áreas como biologia, finanças, medicina e monitoramento ambiental.

Maldição da dimensionalidade

- O aumento na dimensão dos dados (número de atributos) gera um aumento exponencial na demanda por dados para treinar modelos de aprendizado de máquina gerais e precisos o suficiente.
- Duas abordagens para redução de dimensionalidade:
  - Agregação
  - Seleção de Atributos

Seleção de Atributos

- Mantém uma parte dos atributos originais e descarta os demais atributos.
- As técnicas de seleção de atributos buscam em geral um subconjunto ótimo de atributos de acordo com um dado critério como as abordagens:
  - Embutida;
  - Baseada em filtro;
  - Baseada em wrapper.

Desvantagem

- Perda de informação: risco de remover atributos relevantes.
- Viés do método: os atributos selecionados funcionam bem para um modelo, mas podem ser ruins para outro.
- Custo computacional elevado: métodos wrapper treinam vários modelos, explorando combinações de atributos.

OpAIoT
Optimization • AI • IoT

Universidade de São Paulo

Referências

- Faceli, Katti, et al. "Inteligência artificial: uma abordagem de aprendizado de máquina." (2021).
- Kuhn, M., & Johnson, K. (2019). Feature Engineering and Selection: A Practical Approach for Predictive Models. CRC Press.





Obrigado!

opaiot@icmc.usp.br
+55 (16) 99962-7637

PROFESSOR

Dr. Cláudio Fabiano Motta Toledo

OpAIoT
Optimization • AI • IoT