ICMC USP SÃO CARLOS

USP Universidade de São Paulo



IA, Otimização e IoT para Indústrias e Negócios
Do Zero ao MLOps

PROFESSOR

Dr. Cláudio Fabiano Motta Toledo

OpAIoT
Optimization • AI • IoT

Módulo 1

Fundamentos de Dados e Aprendizado de Máquina

Aplicado a Operações e Negócios

OpAIoT
Optimization • AI • IoT

Universidade de São Paulo

Engenharia de Atributos: Seleção de Atributos

Sumário

01 O que é Seleção de Atributos?

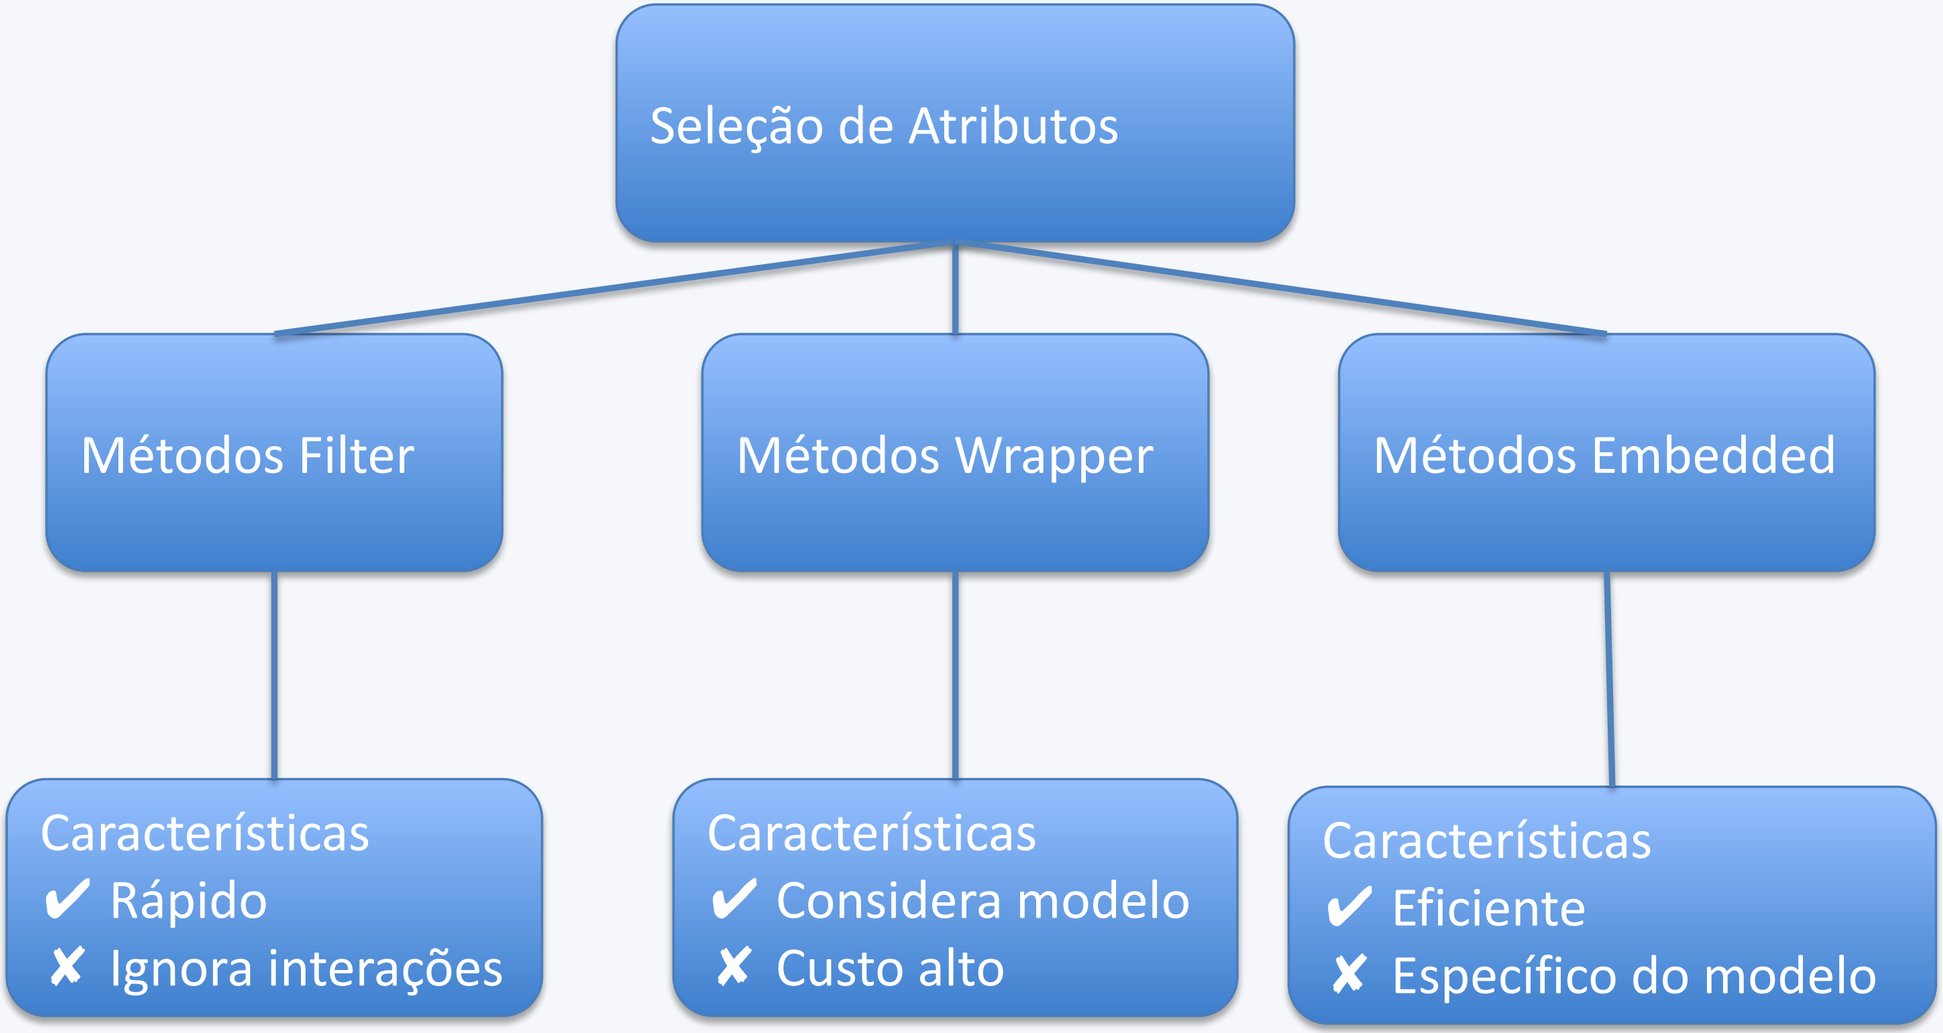
02 Métodos Filter (Filtro)

03 Métodos Wrapper

04 Métodos Embedded (Embarcados)

05 Resumo

Definição: processo de escolher um subconjunto das variáveis mais relevantes para o modelo, removendo atributos irrelevantes ou redundantes para melhorar desempenho e interpretabilidade.



Avaliam cada atributo por algum critério estatístico ou heurístico antes do treinamento do modelo final.

Eles são chamados de filtro porque “filtram” as variáveis menos promissoras sem envolver diretamente um algoritmo preditivo completo.

Exemplo 1: Problema de previsão de preço de casas com uma coluna tem_heliponto_no_bairro. Se 99,8% dos imóveis têm valor 0 nessa coluna, ela quase não varia.

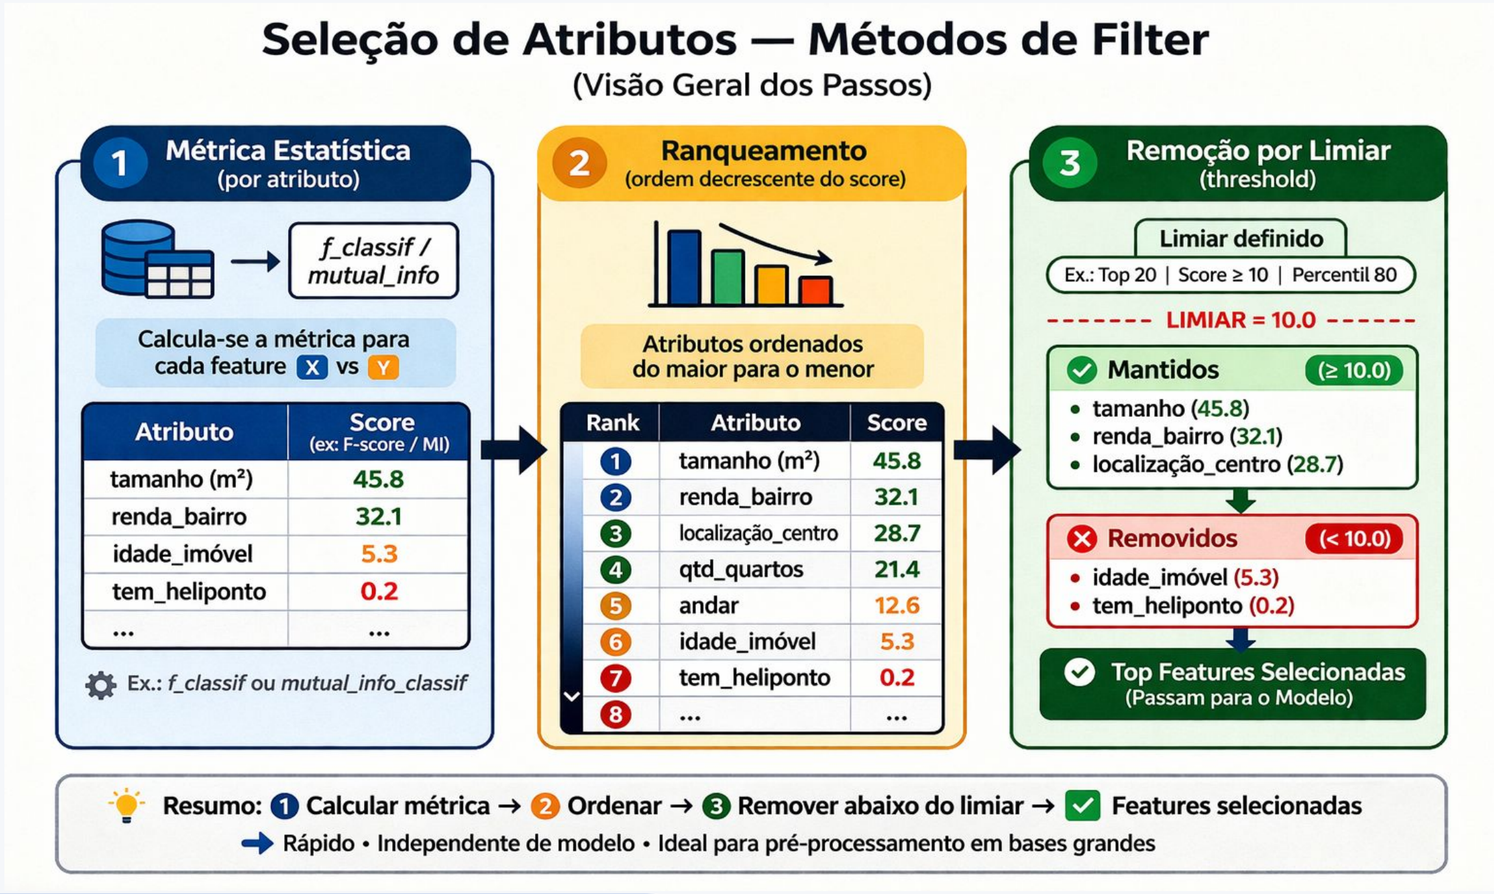


Um filtro por baixa variância pode removê-la sem sequer treinar modelo. Isso é rápido e faz sentido sobretudo como etapa inicial de limpeza em bases muito largas.

- O **scikit-learn** implementa testes univariados com SelectKBest, SelectPercentile, SelectFpr, SelectFdr e SelectFwe.
- Para regressão, f_regression, r_regression e mutual_info_regression
- Para classificação, chi2, f_classif e mutual_info_classif

Funcionamento

1. Uma métrica estatística é calculada para cada feature individualmente.
2. Os atributos são então ranqueadas
3. Aqueles que ficam abaixo de um certo limiar são removidos.



Vantagem

Extremamente rápidos e escaláveis, servindo como um ótimo pré-processamento inicial.

Desvantagem

A principal é que eles avaliam atributos individualmente, ignorando completamente interações ou efeitos conjuntos.

Utiliza alguma técnica de aprendizado como caixa-preta na seleção dos atributos.

- A seleção passa a depender de um modelo preditivo específico.
- Ao invés de calcular uma estatística por coluna, o algoritmo testa subconjuntos de atributos e escolhe os que dão melhor desempenho ao preditor.
- O critério de seleção é o próprio desempenho do preditor, que fica “embrulhado” em um algoritmo de busca.

Vantagens

- Técnicas baseadas em wrapper representam uma alternativa simples e poderosa para selecionar atributos.
- Por incorporar o viés do classificador, essas técnicas conseguem obter um conjunto de atributos que melhora o desempenho do modelo.

Desvantagem

- O número de subconjuntos possíveis é 2^d, o que torna a busca exaustiva impraticável em geral; por isso, buscas heurísticas e gulosas são aplicadas.

Recursive Feature Elimination (RFE)

Wrapper clássico

1. Treina um estimador que forneça importância de atributos (coef_ ou feature_importances_),
2. Há um ranqueamento da importância dos atributos, removendo o menos importante.
3. Repete 1 e 2 até chegar ao número desejado de atributos.

Sequential Feature Selection (SFS)

Modo forward

1. Começa sem atributo.
2. Adiciona, a cada passo, o melhor novo atributo segundo um score com validação cruzada.

Modo backward

1. Começa com todos os atributos.
2. Remove aquele atributo cuja falta menos prejudica o desempenho do modelo a cada rodada.

- **Overfitting da própria seleção:** cuidado para não superajustar!!
- Na presença de correlação entre preditores, pode não existir um único “melhor” subconjunto; ao remover uma variável, outra correlacionada pode compensar sua ausência.

A seleção de atributos ocorre durante o processo de treinamento do modelo.

- Funcionam como se o modelo tivesse um "botão" interno para escolher as features mais importantes enquanto aprende.
- Tentam ser um meio-termo entre a eficiência dos filters e a precisão dos wrappers.
- A motivação é reduzir o custo dos wrappers, incorporando a seleção ao processo de aprendizado.

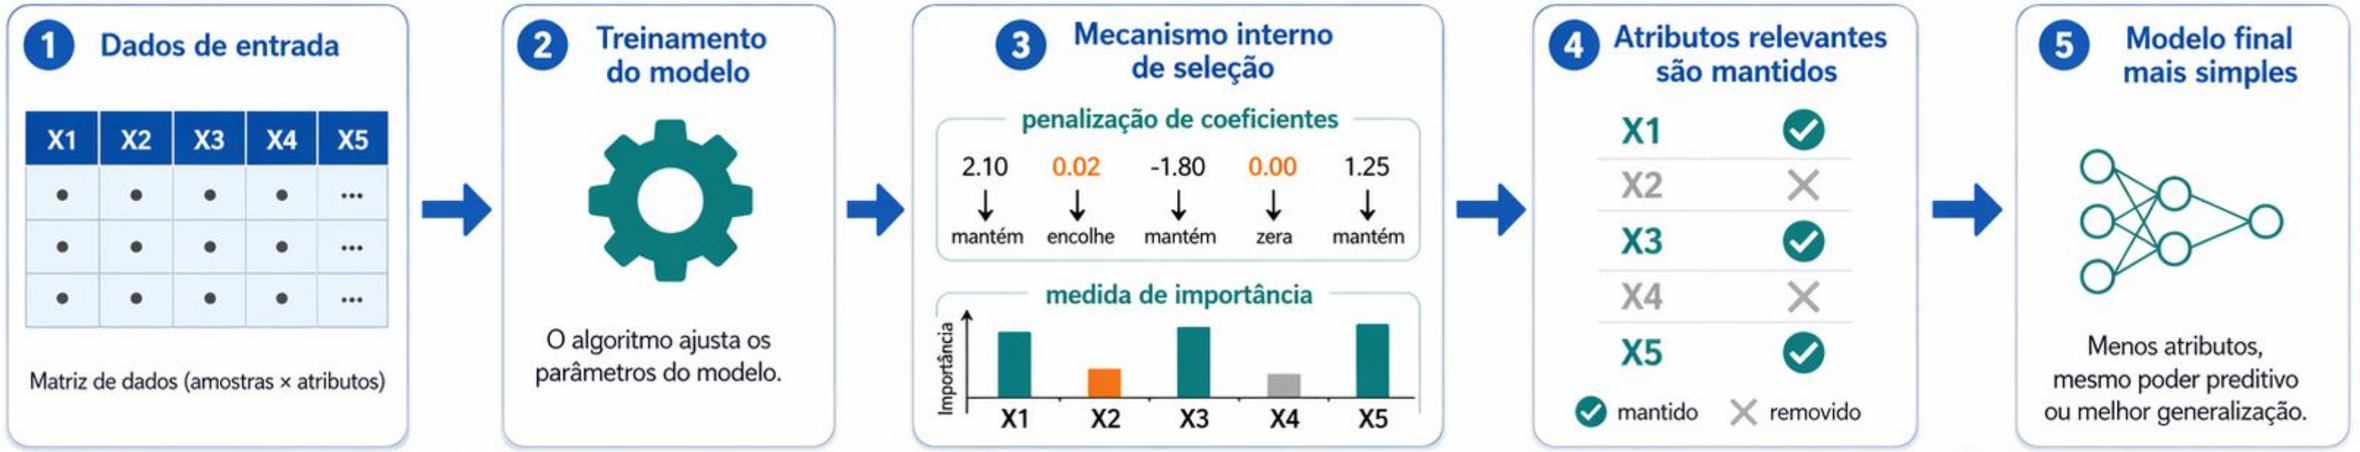
Vantagens

- Mais rápidos que os wrappers.
- Ao contrário dos filters, consideram a interação dos atributos dentro do contexto do modelo.

Desvantagem

- A seleção é acoplada ao modelo, logo, a importância dos atributos pode mudar se você trocar o modelo
  - Exemplo a importância dada por uma árvore é diferente da dada por uma regressão Lasso.

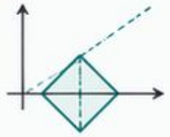
O próprio algoritmo aprende quais variáveis são mais relevantes, combinando ajuste do modelo e seleção em uma única etapa.



Ideia central: a escolha das variáveis acontece enquanto o modelo é ajustado.

Exemplos

A Lasso (L1)



Zera coeficientes menos importantes.

B Elastic Net



Combina regularizações L1 e L2.

C Árvores e ensembles



Usam importância das variáveis.

Árvore de decisão, Random Forest, Gradient Boosting

Vantagens

- Integra seleção e treinamento
- Reduz dimensionalidade
- Pode diminuir *overfitting*
- Gera modelos mais interpretáveis

Comparação rápida

- **Filter:** seleciona antes do modelo
- **Wrapper:** testa subconjuntos com o modelo
- **Embedded:** seleciona durante o treinamento

Exemplo conceitual — seleção univariada **NÃO** é embedded; embedded depende do algoritmo do modelo.

Métodos Filter	Métodos Wrapper	Métodos Embedded
Propriedades estatísticas intrínsecas (ex: correlação, variância)	Desempenho do modelo preditivo (ex: acurácia, RMSE)	Mecanismo de aprendizado do próprio modelo (ex: coeficientes Lasso)
Muito Rápido	Muito Lento	Moderado/Rápido
Ignora interações	Considera interações	Considera interações dentro do escopo do modelo
Custo Baixo	Custo Alto (se não usar validação cruzada)	Custo Moderado (controlado pelo modelo)
Perfeito para explorar e remover ruído óbvio rapidamente.	Útil quando se tem um modelo específico em mente e recursos computacionais.	Ideal para encontrar o equilíbrio entre poder preditivo e simplicidade de forma automatizada.

OpAIoT
Optimization • AI • IoT

Universidade de São Paulo

Referências

- Faceli, Katti, et al. "Inteligência artificial: uma abordagem de aprendizado de máquina." (2021).
- Kuhn, M., & Johnson, K. (2019). Feature Engineering and Selection: A Practical Approach for Predictive Models. CRC Press.
- Chandrashekar, G.; Sahin, F. A Survey on Feature Selection Methods (Computers & Electrical Engineering, 2014). (RomiSatriaWahono.Net)
- sklearn.preprocessing https://scikit-learn.org/stable/api/sklearn.preprocessing.html#





Obrigado!

opaiot@icmc.usp.br
+55 (16) 99962-7637

PROFESSOR

Dr. Cláudio Fabiano Motta Toledo

OpAIoT
Optimization • AI • IoT