ICMC USP SÃO CARLOS

USP Universidade de São Paulo



IA, Otimização e IoT para Indústrias e Negócios
Do Zero ao MLOps

PROFESSOR

Dr. Cláudio Fabiano Motta Toledo

OpAIoT
Optimization • AI • IoT

Módulo 1

Fundamentos de Dados e Aprendizado de Máquina

Aplicado a Operações e Negócios

OpAIoT
Optimization • AI • IoT

Universidade de São Paulo

Métricas de Avaliação e Seleção de Modelos: Regressão

Sumário

01 O que é Métrica de Avaliação?

02 Métricas para Regressão

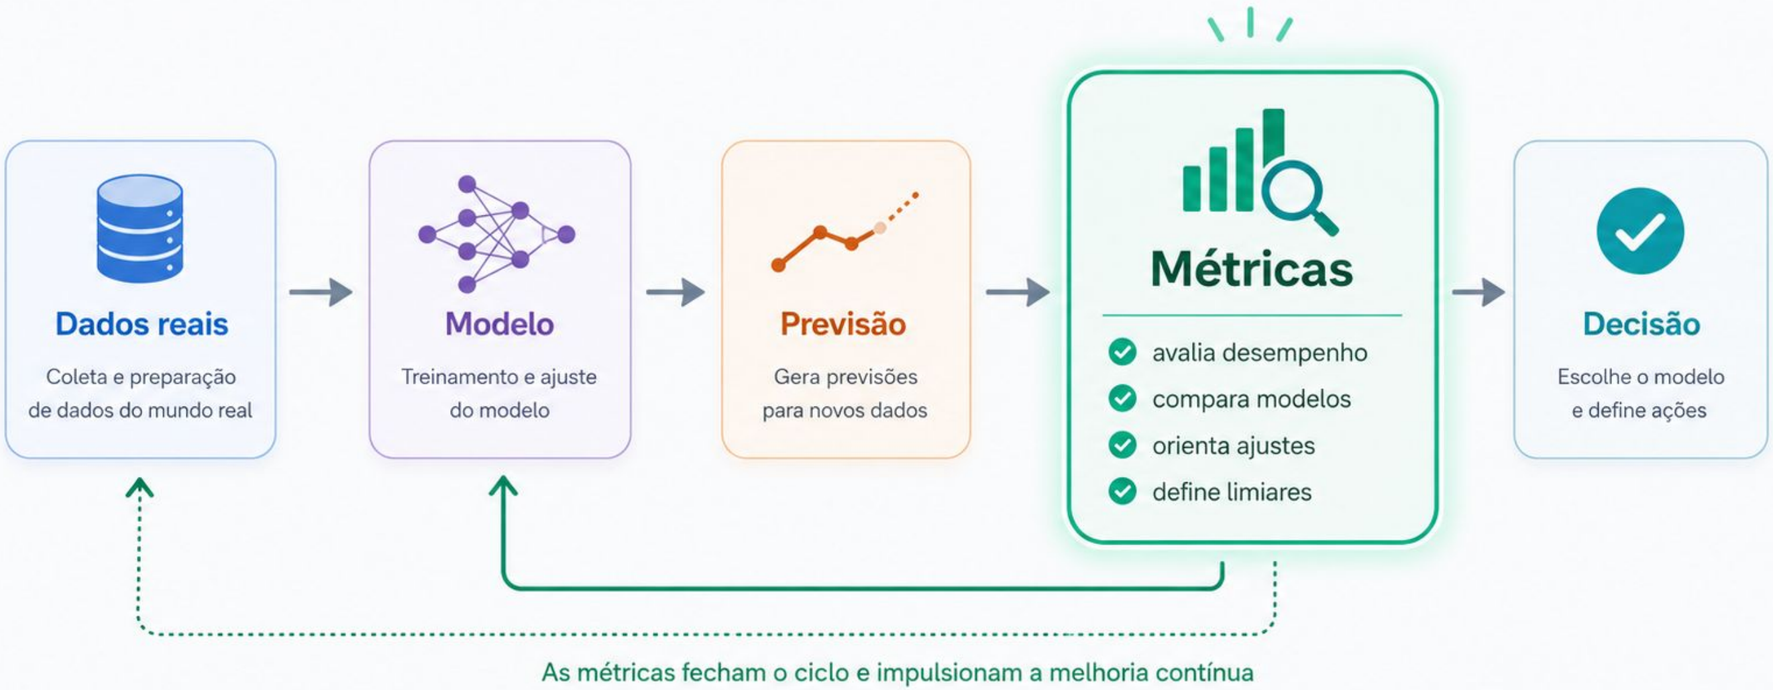
03 Como Selecionar Modelos de Regressão

04 Resumo

Métrica é uma regra numérica que resume erros individuais em uma medida interpretável

A métrica não é neutra: escolher MAE, RMSE, recall ou precisão muda o tipo de erro que o modelo será incentivado a reduzir.

As métricas avaliam, comparam e orientam decisões em todas as etapas do ciclo de desenvolvimento



Métricas no centro do processo: medem o que importam, guiam iterações e garantem decisões mais confiáveis.

Problemas de Regressão e classificação usam métricas diferentes porque produzem respostas diferentes.

REGRESSÃO

Prevê um número contínuo.



- **Ex.:** Consumo de energia.
- **Objetivo:** Estimar valores reais.
- **Erro** = real – previsto.

MÉTRICAS COMUNS

MAE
(Erro Médio Absoluto)

Menor é melhor.

$$\frac{1}{n}\sum_{i=1}^{n}|y_i-\hat{y}_i|$$

RMSE
(Raiz do Erro Quadrático Médio)

Menor é melhor.

$$\sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i-\hat{y}_i)^2}$$

R^2
(Coeficiente de Determinação)

Maior é melhor.

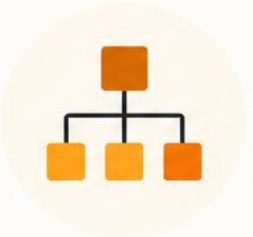
$$1-\frac{\sum(y_i-\hat{y}_i)^2}{\sum(y_i-\bar{y})^2}$$

EXEMPLO VISUAL



CLASSIFICAÇÃO

Prevê uma classe.



- **Ex.:** Peça normal ou defeituosa.
- **Objetivo:** Atribuir a classe correta.
- **Erro** = classe prevista errada.

MÉTRICAS COMUNS

Acurácia
(Accuracy)

Maior é melhor.

$$\frac{\text{Acertos}}{\text{Total}}$$

Precisão
(Precision)

Maior é melhor.

$$\frac{TP}{TP+FP}$$

Revocação
(Recall)

Maior é melhor.

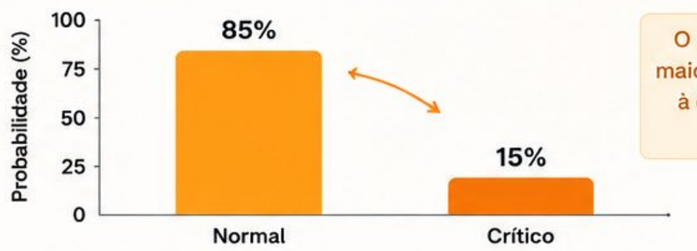
$$\frac{TP}{TP+FN}$$

F1-Score

Maior é melhor.

$$\frac{2\cdot P\cdot R}{P+R}$$

EXEMPLO VISUAL



Use a **matriz de confusão** para analisar os tipos de erro (FP e FN).

Exemplo industrial para regressão: Prever a taxa de defeitos (%) a partir de sensores de processo.

Cada linha representa um período de produção. O modelo recebe temperatura, pressão e vibração, e estima a taxa de defeitos.

Temp.	Pressão	Vibração	Real	Previsto
181,2	5,8	3,4	6,1%	5,7%
176,5	6,2	2,8	4,8%	5,2%
184,0	5,4	4,7	9,6%	8,1%
180,4	6,0	3,0	5,3%	5,5%

erro = valor real − valor previsto

As métricas resumem todos esses erros em um ou poucos números.

O erro médio é aceitável para apoiar decisões na linha industrial?

MÉTRICAS COMUNS

MAE
(Erro Médio Absoluto)

Menor é melhor.

$$\frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

RMSE
(Raiz do Erro Quadrático Médio)

Menor é melhor.

$$\sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

R^2
(Coeficiente de Determinação)

Maior é melhor.

$$1 - \frac{\sum(y_i - \hat{y}_i)^2}{\sum(y_i - \bar{y})^2}$$

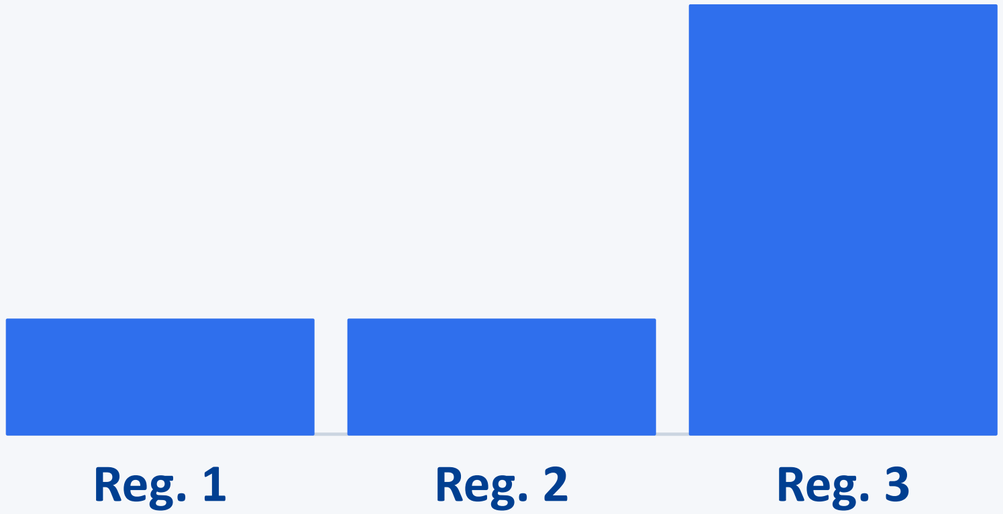
EXEMPLO VISUAL



MAE: Mean Absolute Error ou Erro Absoluto Médio $\frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$

- MAE calcula a média das distâncias absolutas entre valores reais e previstos.
- Simples de interpretar porque fica na **mesma unidade da variável alvo.**

Real	Previsto	Erro absoluto
6,1	5,7	0,4
4,8	5,2	0,4
9,6	8,1	1,5



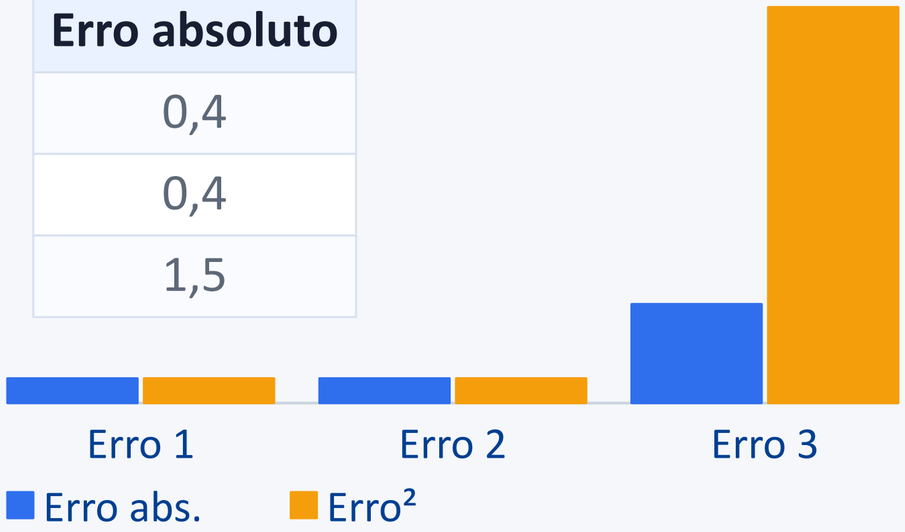
Interpretação: MAE = 2,4 significa que, em média, o modelo erra 2,4 unidades da variável prevista.

Quanto menor, melhor; o mínimo é 0.

MSE: $\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$ **RMSE:** $\sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$

- MSE (Mean Squared Error ou Erro Quadrático Médio): eleva os erros ao quadrado; por isso, erros grandes influenciam mais.
- RMSE (Root Mean Squared Error ou Raiz do Erro Quadrático Médio): tira a raiz e volta para a unidade do alvo.
  - RMSE= 5 kWh indica que o erro médio típico do modelo está em torno de 5 kWh, com maior peso para erros grandes.

Erro absoluto
0,4
0,4
1,5



MSE: útil na otimização, mas fica em unidade ao quadrado.

RMSE: mais interpretável e sensível a grandes erros.

Use RMSE quando um erro grande isolado for operacionalmente caro.

RMSE: $\sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$ **MAE:** $\frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$

- Se o RMSE é muito maior que o MAE, isso indica que alguns erros grandes estão influenciando fortemente o resultado.

$$MAE = \frac{2+2+2+2+2+2+2+2+2+50}{10}$$

$$= \frac{68}{10} = 6{,}8 \text{ kWh}$$

$$RMSE = \sqrt{\frac{2^2+2^2+2^2+2^2+2^2+2^2+2^2+2^2+2^2+50^2}{10}}$$

$$RMSE = \sqrt{\frac{36+2500}{10}} = \sqrt{253{,}6} \approx 15{,}9 \text{ kWh}$$

R^2: $$1 - \frac{\sum_{i=1}^{n} (y_i - \hat{y}_i)^2}{\sum_{i=1}^{n} (y_i - \bar{y})^2}$$

$\hat{y}_i$: atributo alvo

$\bar{y}$: média

R^2 ou **coeficiente de determinação** mede quanto da variação do alvo é explicada pelo modelo.

- Ele é útil, mas não substitui olhar os erros e resíduos.





Interpretação: R^2 = 0,92, o modelo explica aproximadamente 92% da variação observada na variável-alvo.

➔ Os valores previstos pelo modelo acompanham bem os valores reais.

R^2 próximo de 1 é desejável, mas ainda é preciso verificar erros grandes em casos críticos.

MAE: Mean Absolute Percentage Error, ou Erro Percentual Absoluto Médio.

$$\frac{100}{n}\sum_{i=1}^{n}\left|\frac{y_i-\hat{y}_i}{y_i}\right|$$

- MAPE expressa o erro como percentual do valor real.
  - MAPE = 8% significa erro percentual absoluto médio de 8%.

- Cuidado com valores reais próximos de zero
- Em taxa de defeitos, se o real for muito baixo, o MAPE pode parecer enorme mesmo com erro absoluto pequeno.

Valor real	Valor previsto	Erro absoluto	Erro percentual
100	110	10	10%
2	4	2	100%
0,5	1,5	1	200%

Escolher o modelo com menor erro exige comparar no conjunto correto e considerar a consequência prática dos erros.

Usamos treino, validação e teste para compara modelos e tomar a melhor decisão final



Modelo	MAE	RMSE	R^2	Leitura
Ridge	1,25	1,70	0,78	erro estável
Árvore de Decisão	1,10	2,40	0,74	erros altos em alguns casos
★ **Random Forest**	**0,95**	**1,45**	**0,84**	**melhor equilíbrio**

Leitura das métricas: menores MAE e RMSE indicam menos erro; maior R^2 indica melhor ajuste.

- **MAE**

- Pequeno: o modelo erra pouco, em média.
- Grande: o modelo apresenta erros maiores nas previsões.
- O MAE está na mesma unidade da variável prevista.
- Todos os erros têm peso proporcional; erros grandes não são penalizados tão fortemente quanto no RMSE.

Exemplo: MAE=4 kWh

➔ O modelo erra em média cerca de 4 kWh em suas previsões..

- **RMSE**

- Pequeno: o modelo tem bom desempenho, com erros geralmente baixos.
- Grande: o modelo apresenta erros importantes.
- O RMSE está na mesma unidade da variável prevista.
- Se o RMSE é muito maior que o MAE, isso indica que existem alguns erros grandes influenciando bastante o resultado.

Exemplo: RMSE=5 kWh

➔ O erro típico do modelo está em torno de 5 kWh, com maior influência de erros grandes.

R^2

- Próximo de 1: o modelo explica bem os dados.
- Próximo de 0: o modelo não melhora muito em relação a prever sempre a média.
- Negativo: o modelo pode estar pior do que simplesmente usar a média como previsão.

Exemplo: R^2=0,85

➔ O modelo explica aproximadamente 85% da variação observada na variável alvo.

MAPE

- Pequeno: o modelo erra pouco em termos percentuais.
- Grande: o modelo apresenta erros percentuais elevados.
- É fácil de interpretar porque o resultado vem em porcentagem.
- Deve ser usado com cuidado quando y_i é zero ou muito próximo de zero, pois a divisão pode distorcer o resultado.

Exemplo: MAPE=8%

➔ As previsões do modelo erram em média cerca de 8% em relação aos valores reais.

OpAIoT
Optimization • AI • IoT

Universidade de São Paulo

Referências

- Faceli, Katti, et al. "Inteligência artificial: uma abordagem de aprendizado de máquina." (2021).
- Hyndman, R. J.; Koehler, A. B. (2006), Another look at measures of forecast accuracy.
- ames, G. et al. (2013), An Introduction to Statistical Learning.
- Scikit-learn Documentation, Regression Metrics.





Obrigado!

opaiot@icmc.usp.br
+55 (16) 99962-7637

PROFESSOR

Dr. Cláudio Fabiano Motta Toledo

OpAIoT
Optimization • AI • IoT