ICMC USP SÃO CARLOS

USP Universidade de São Paulo



IA, Otimização e IoT para Indústrias e Negócios
Do Zero ao MLOps

PROFESSOR

Dr. Cláudio Fabiano Motta Toledo

OpAIoT
Optimization • AI • IoT

Módulo 1

Fundamentos de Dados e Aprendizado de Máquina

Aplicado a Operações e Negócios

OpAIoT
Optimization • AI • IoT

Universidade de São Paulo

Métricas de Avaliação e Seleção de Modelos: Classificação

Sumário

01 O que é Métrica de Avaliação?

02 Métricas para Classificação

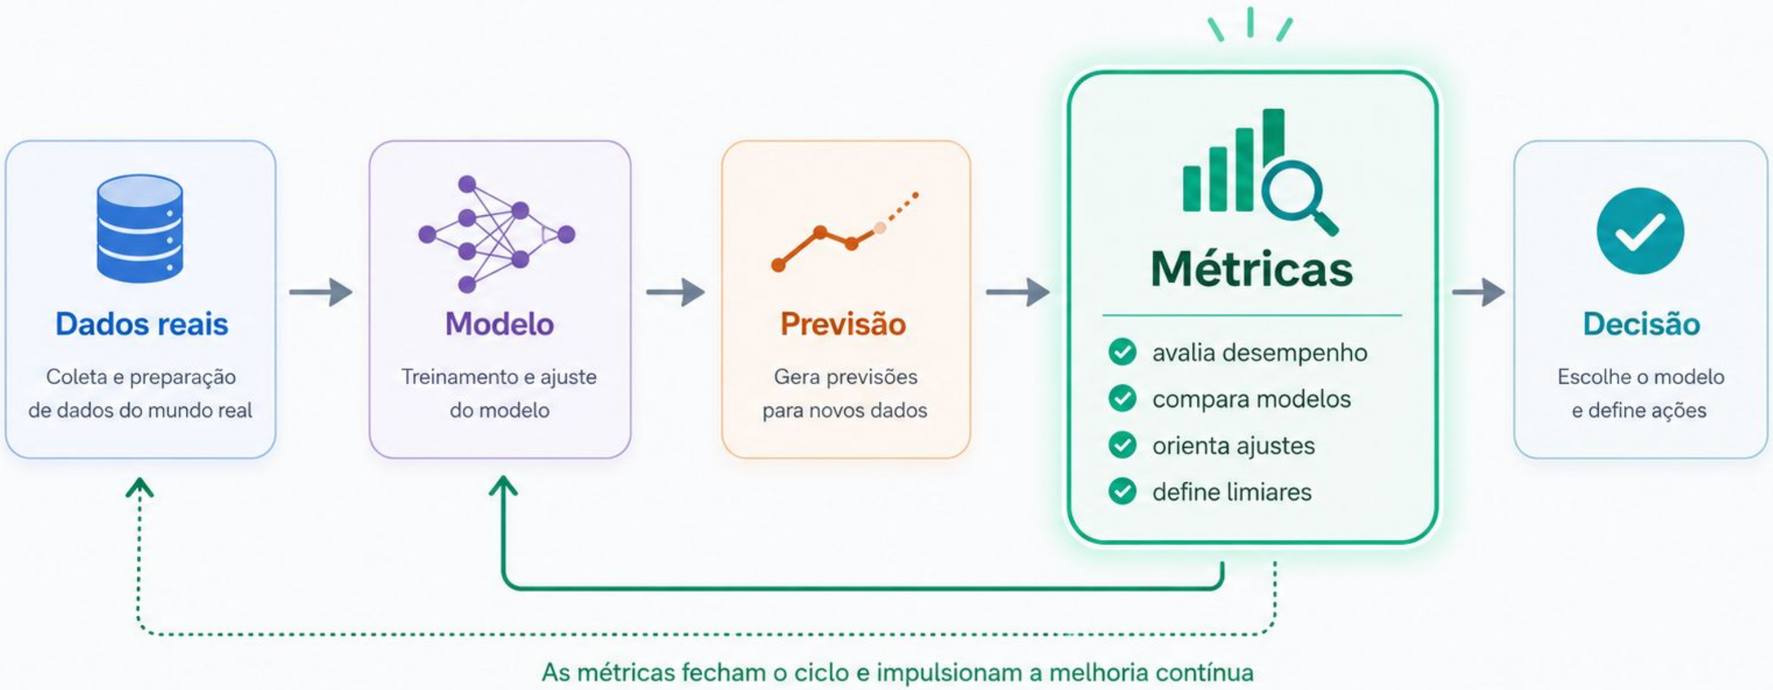
03 Como Selecionar Modelos de Classificação

04 Resumo

Métrica é uma regra numérica que resume erros individuais em uma medida interpretável

A métrica não é neutra: escolher MAE, RMSE, recall ou precisão muda o tipo de erro que o modelo será incentivado a reduzir.

As métricas avaliam, comparam e orientam decisões em todas as etapas do ciclo de desenvolvimento



Métricas no centro do processo: medem o que importam, guiam iterações e garantem decisões mais confiáveis.

Exemplo industrial para classificação: classificar períodos de produção como “Normal” ou “Crítico”.

Um período crítico pode representar alto risco de defeitos, vibração elevada ou operação fora do padrão.



Na classificação, o erro não é “quanto errou”, mas “qual tipo de confusão o modelo cometeu”.

MÉTRICAS COMUNS

Acurácia (Accuracy)

Maior é melhor.

$$\frac{\text{Acertos}}{\text{Total}}$$

Precisão (Precision)

Maior é melhor.

$$\frac{TP}{TP + FP}$$

Revocação (Recall)

Maior é melhor.

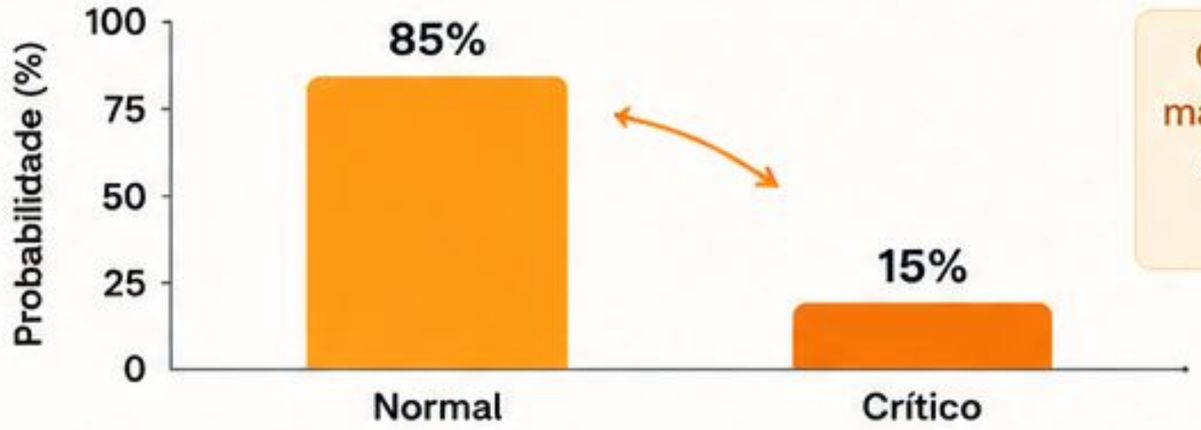
$$\frac{TP}{TP + FN}$$

F1-Score

Maior é melhor.

$$\frac{2 \cdot P \cdot R}{P + R}$$

EXEMPLO VISUAL



O modelo atribui maior probabilidade à classe correta (Normal).

Matriz de confusão: compara a classe real com a classe prevista e separa acertos e tipos de erro.

		Previsto: Normal	Previsto: Crítico
Real	Normal	TN 72	FP 8
Real	Crítico	FN 5	TP 15

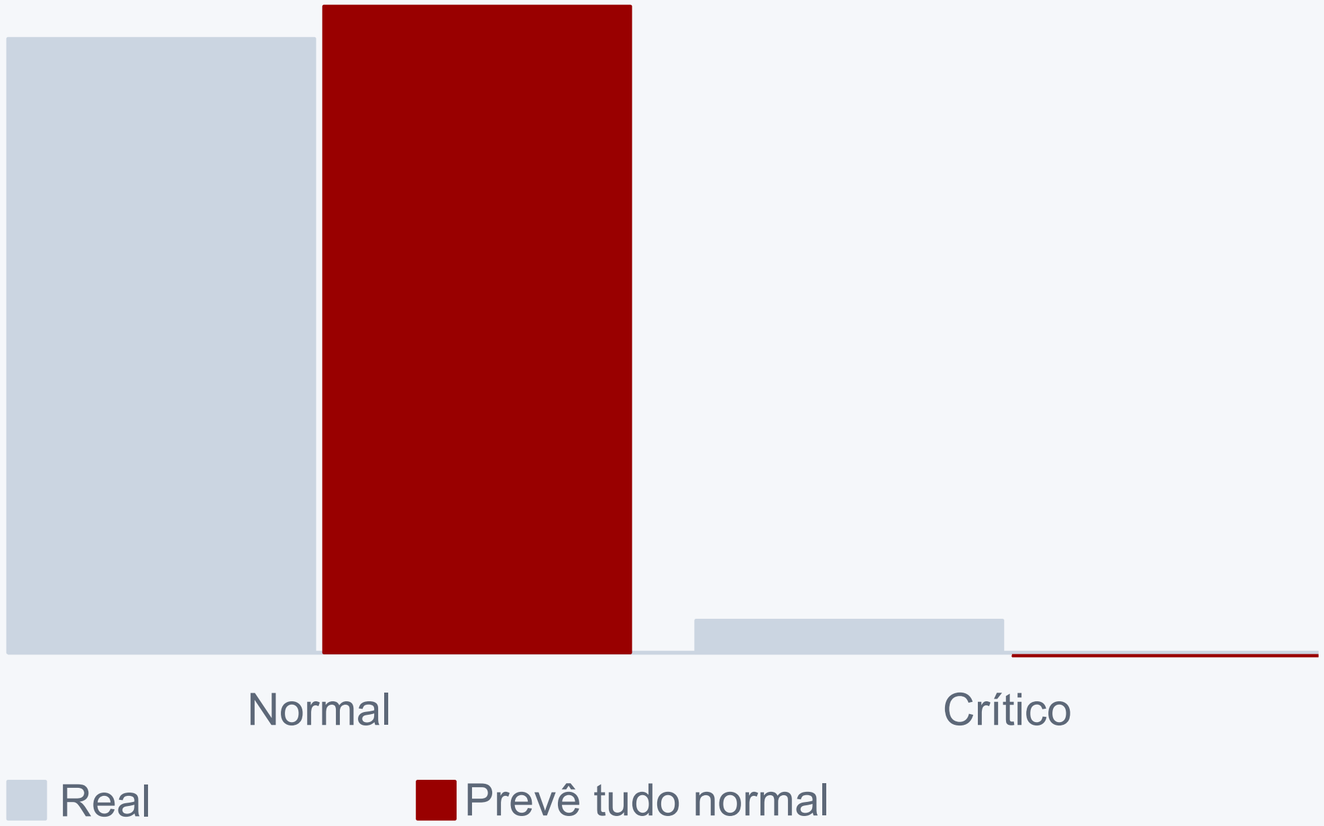
Sigla	Nome em inglês	Nome em português	Significado
TP	True Positive	Verdadeiro Positivo	O caso era **Crítico** e o modelo previu **Crítico**.
TN	True Negative	Verdadeiro Negativo	O caso era **Normal** e o modelo previu **Normal**.
FP	False Positive	Falso Positivo	O caso era **Normal**, mas o modelo previu **Crítico**.
FN	False Negative	Falso Negativo	O caso era **Crítico**, mas o modelo previu **Normal**.

Acurácia: $\frac{Acertos}{Total} = \frac{TP+TN}{TP+TN+FP+FN}$

- Acurácia é a proporção de acertos.
- Funciona bem quando as classes são equilibradas e os erros têm custos semelhantes.

Acurácia = 0,95 significa que 95% das amostras foram classificadas corretamente. Pode enganar em bases desbalanceadas.

Se apenas 5% dos casos são críticos, um modelo que sempre prevê “Normal” pode ter 95% de acurácia — mas não detecta nenhum caso crítico.



Quando a classe positiva é importante, como “Crítico”, acurácia não basta.

Precisão (Precision)

$$\frac{TP}{TP+FP}$$

- Use quando falso positivo é caro

Exemplo

Dos alertas emitidos, quantos estavam corretos?

Revocação (Recall)

$$\frac{TP}{TP+FN}$$

- Use quando falso negativo é perigoso.

Exemplo

Dos casos críticos reais, quantos foram encontrados?

F1-score

$$\frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

- Use quando ambos importam.

Exemplo

O modelo encontrou muitos casos críticos sem gerar muitos alertas falsos?

Precisão (Precision)

$$\frac{TP}{TP+FP}$$

- **Responde:** posso confiar quando o modelo prevê positivo?
- Interpretação:Precisão = 0,80 significa que 80% dos alertas positivos estavam corretos. Alta precisão reduz falsos alarmes.

Revocação (Recall)

$$\frac{TP}{TP+FN}$$

Especificidade (Specificity)

$$\frac{TN}{TN+FP}$$

- Use especificidade quando falsos positivos também importam.

F1-score

$$\frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

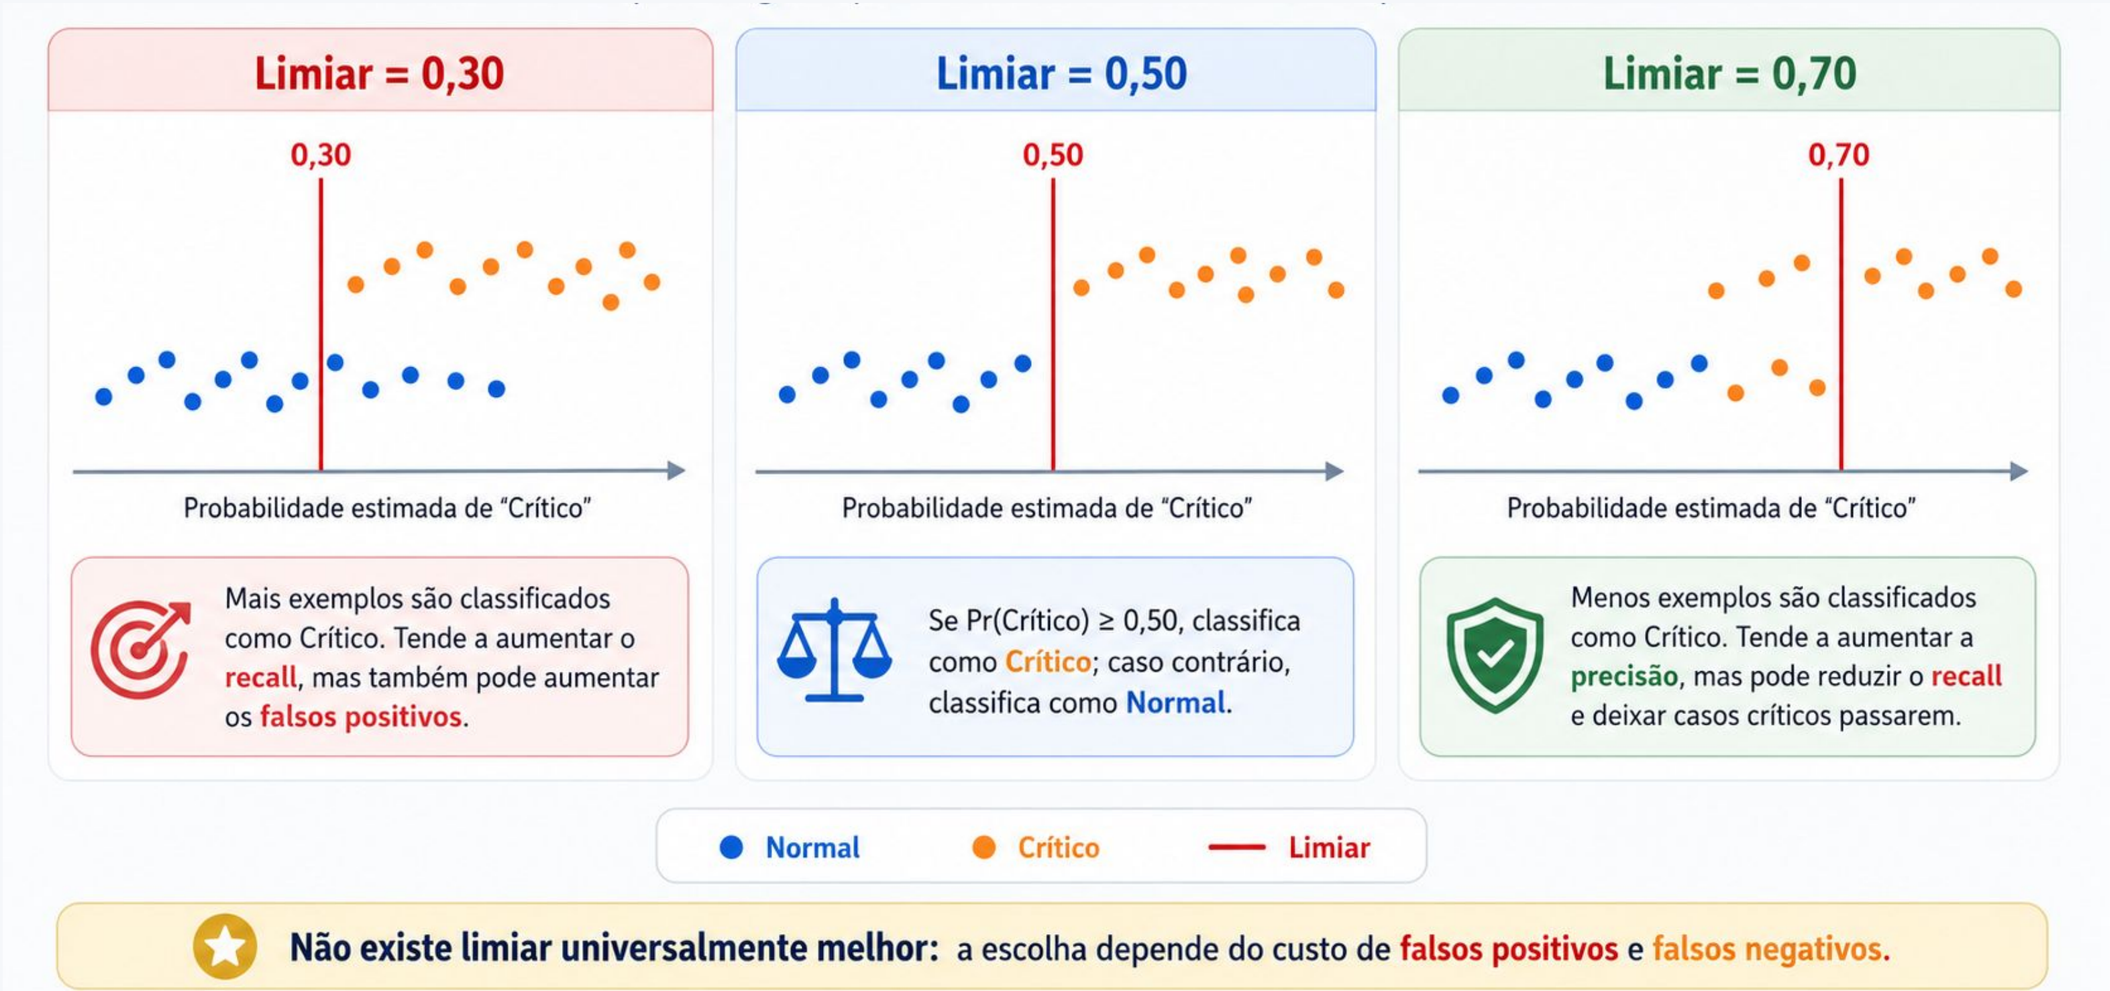
Fβ-score

$$\frac{(1+\beta^2) \cdot \text{Precision} \cdot \text{Recall}}{\beta^2 \cdot \text{Precision} + \text{Recall}}$$

- Se β=1, temos o **F1-score**, que dá o **mesmo peso** para precisão e recall.
- Se β>1, o modelo dá mais peso à **revocação**.
- Se β<1, o modelo dá mais peso à **precisão**.

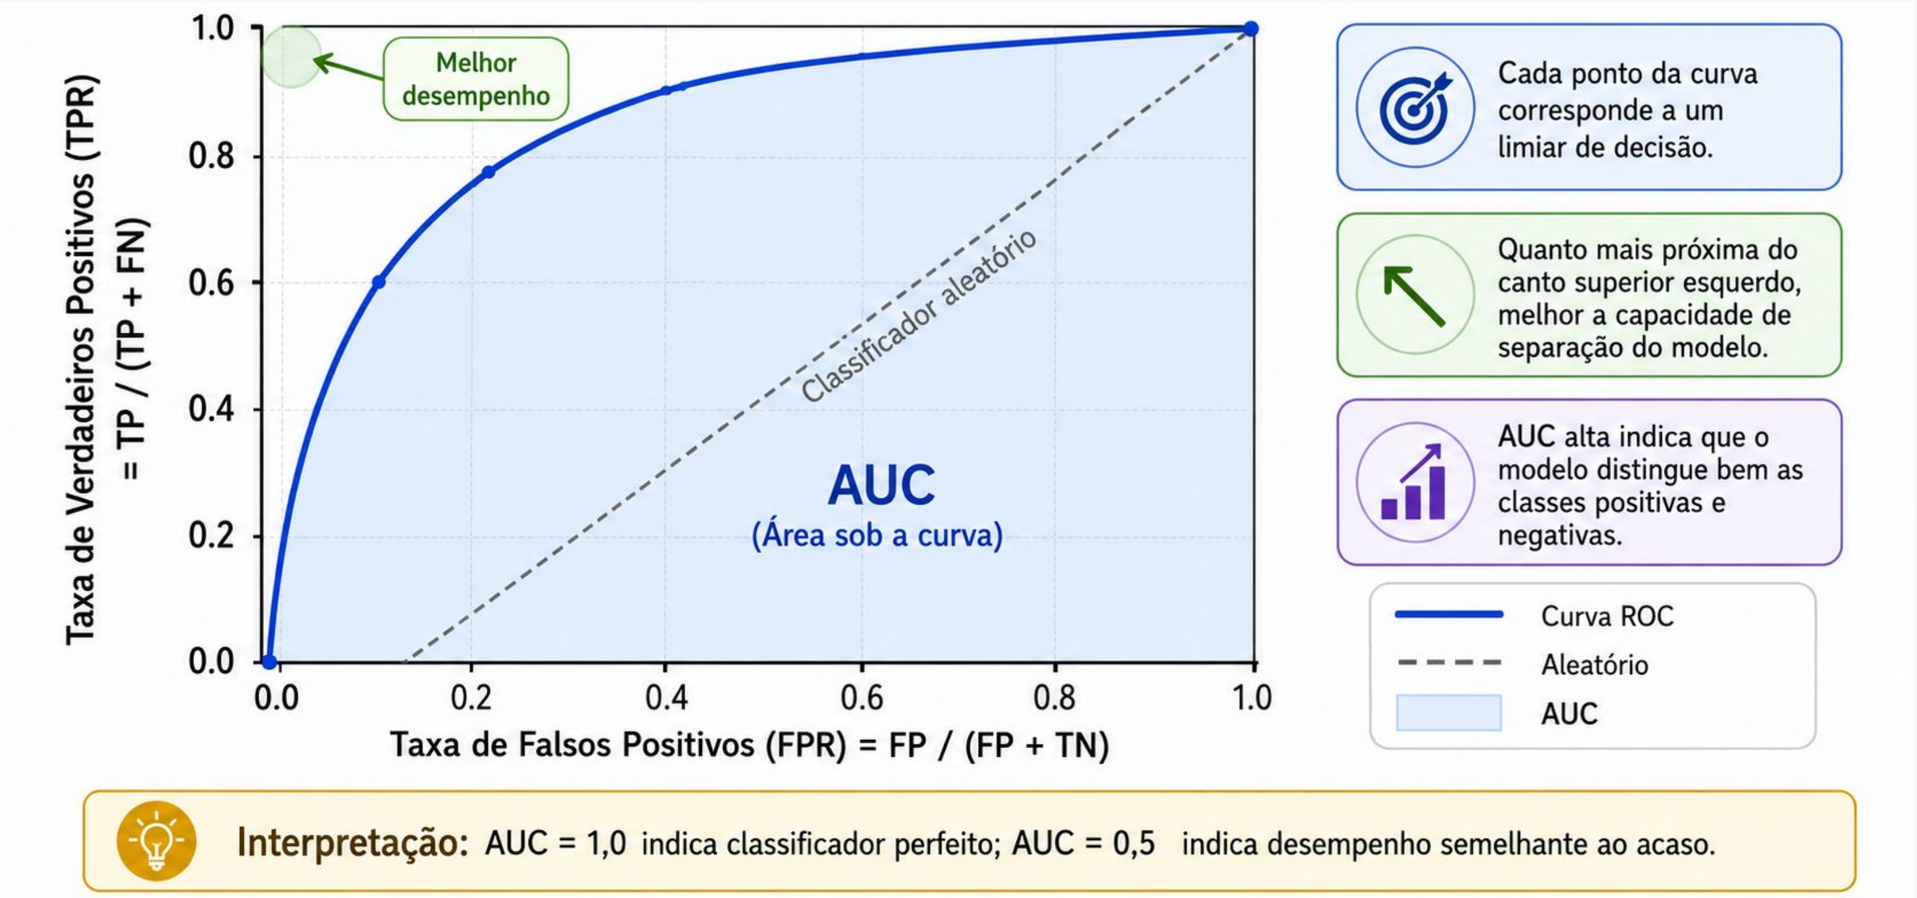
Muitos classificadores geram probabilidade. A classe final depende de um limiar.

- Se Pr(Crítico) ≥ 0,50, classifica como Crítico.
- Se Pr(Crítico) < 0,50, classifica como Normal.



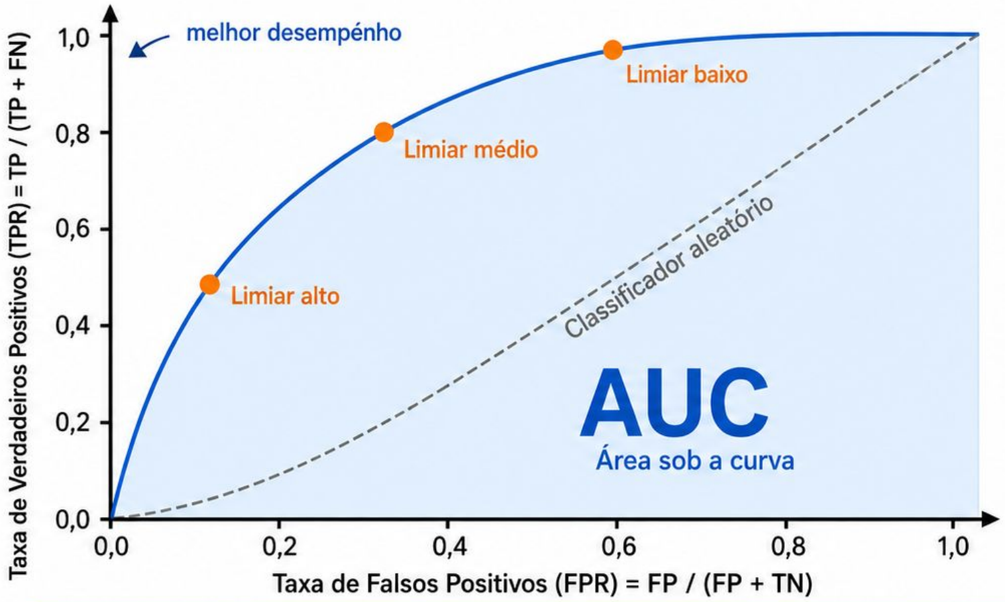
ROC (Receiver Operating Characteristic) é uma curva usada para avaliar modelos de classificação binária que retornam probabilidades ou scores.

- Compromisso entre detectar corretamente os positivos e gerar falsos alarmes.
- Mostra o desempenho do classificador para diferentes limiares de decisão. quando variamos o limiar de decisão.



AUC (Area Under the Curve) é a área sob a curva ROC.

- Resume a curva em um único número entre 0 e 1.
  - AUC = 1,0: classificador perfeito;
  - AUC = 0,5: desempenho parecido com escolha aleatório;
  - AUC < 0,5: pior que aleatório, indicando possível inversão das classes ou problema no modelo.



Como interpretar

Cada ponto da curva representa um limiar de decisão.

Quanto mais próxima do canto superior esquerdo, melhor a separação entre as classes.

AUC = probabilidade de o modelo atribuir score maior a um positivo do que a um negativo.

AUC = 1,0: excelente | **AUC = 0,5:** aleatório

Quanto maior a AUC, maior a capacidade do modelo de distinguir exemplos positivos de negativos.

Exemplo: Problema de detecção de falhas.

AUC alta significa que o modelo consegue, em geral, ranquear equipamentos com falha acima dos equipamentos normais.

1 Seleção de modelos de classificação deve refletir o custo do erro no problema real

A métrica principal deve ser escolhida conforme o impacto do erro na aplicação real.

Qual erro custa mais?

Perder um caso crítico
Falso negativo (FN)

→ **Priorize Recall e ajuste o limiar**

Use quando deixar positivos passarem é perigoso.

Gerar muitos alarmes
Falso positivo (FP)

→ **Priorize Precisão e monitore Recall**

Use quando alarmes falsos têm alto custo.

2 Exemplo de comparação entre modelos de classificação

Modelo	Precisão	Recall	F1-score	ROC-AUC	Leitura
Regressão Logística	0,91	0,74	0,82	0,88	mais conservador; alta precisão
Árvore de Decisão	0,79	0,86	0,82	0,83	captura mais positivos, mas erra mais alertas
★ **Random Forest**	**0,88**	**0,85**	**0,86**	**0,92**	**melhor equilíbrio geral**

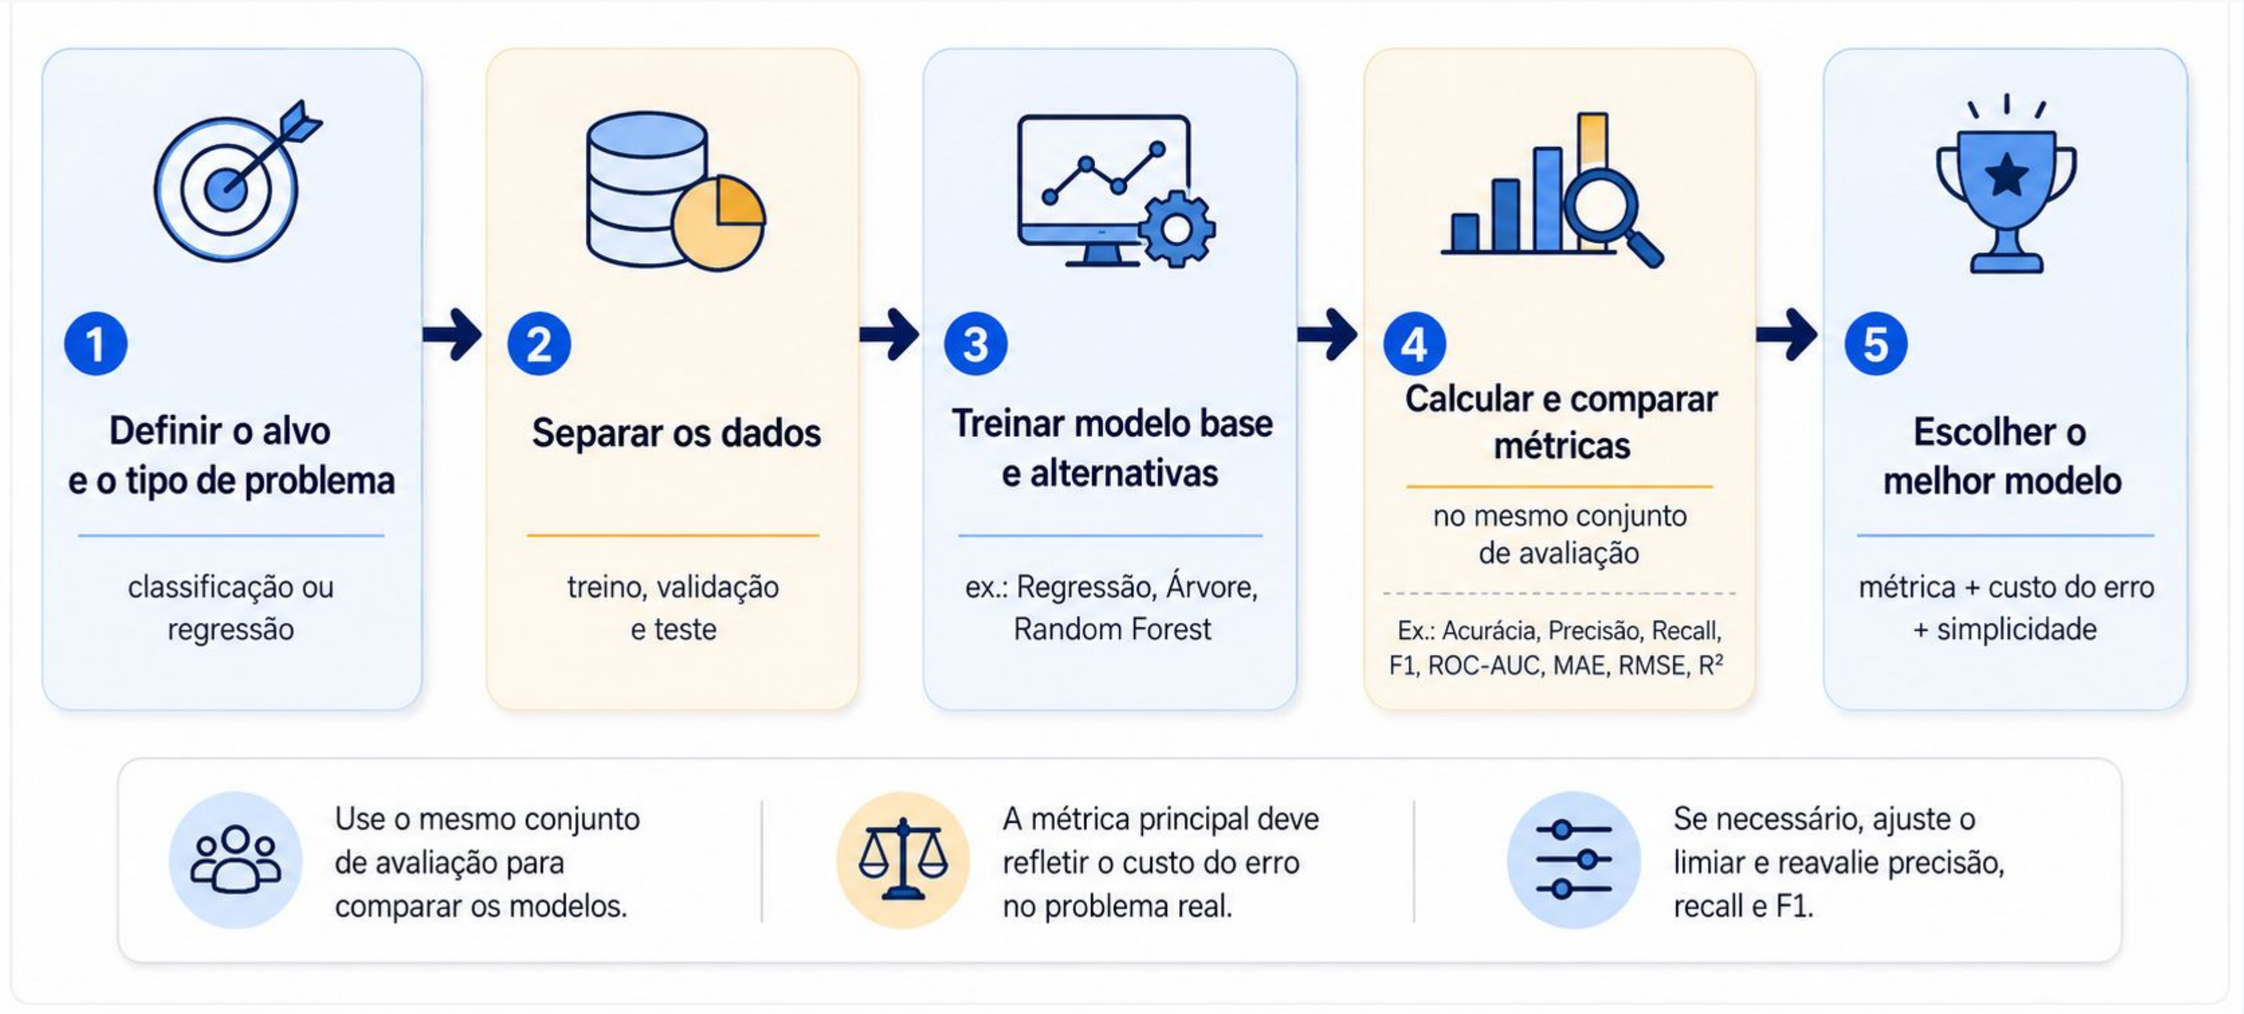
Leitura das métricas: maior Precisão reduz falsos positivos; maior Recall reduz falsos negativos; maior F1-score indica melhor equilíbrio; maior ROC-AUC indica melhor capacidade de separação entre as classes.

A métrica principal deve refletir o custo do erro no problema real.

Cenário	Métrica candidata
Classes equilibradas e erros parecidos	Acurácia
Classe positiva rara	F1, PR-AUC
Não perder falhas	Recall
Evitar alarmes falsos	Precisão

Leitura: a escolha da métrica depende do balanceamento das classes e do custo relativo de falsos positivos e falsos negativos.

Fluxo prático para avaliação e seleção de modelos



A métrica correta depende do tipo de problema, dos dados e do custo dos erros.

Regressão

- MAE: erro médio fácil de explicar.
- RMSE: pune erros grandes.
- R^2: explica variação do alvo.
- MAPE: comunica erro percentual.

Classificação

- Acurácia: boa com classes equilibradas.
- Precisão: confiabilidade dos alertas.
- Recall: encontra positivos.
- F1, ROC-AUC: úteis em comparações.

Seleção de Modelos

- Nunca escolha modelo olhando apenas desempenho no treino.
  - O modelo deve generalizar para dados novos.
- Compare modelos usando a mesma divisão de dados e as mesmas métricas.

Modelo bom é o que reduz os erros mais importantes para o problema.

OpAIoT
Optimization • AI • IoT

Universidade de São Paulo

Referências

- Faceli, Katti, et al. "Inteligência artificial: uma abordagem de aprendizado de máquina." (2021).
- Hyndman, R. J.; Koehler, A. B. (2006), Another look at measures of forecast accuracy.
- James, G. et al. (2013), An Introduction to Statistical Learning.
- Scikit-learn Documentation, Regression Metrics.





Obrigado!

opaiot@icmc.usp.br
+55 (16) 99962-7637

PROFESSOR

Dr. Cláudio Fabiano Motta Toledo

OpAIoT
Optimization • AI • IoT