ICMC USP SÃO CARLOS

USP Universidade de São Paulo



IA, Otimização e IoT para Indústrias e Negócios
Do Zero ao MLOps

PROFESSOR

Dr. Cláudio Fabiano Motta Toledo

OpAIoT
Optimization • AI • IoT

Módulo 1

Fundamentos de Dados e Aprendizado de Máquina

Aplicado a Operações e Negócios

OpAIoT
Optimization • AI • IoT

Universidade de São Paulo

Gradiente Boosting

Sumário

01 O que é Gradient Boosting?

02 Funcionamento do Gradiente Boosting

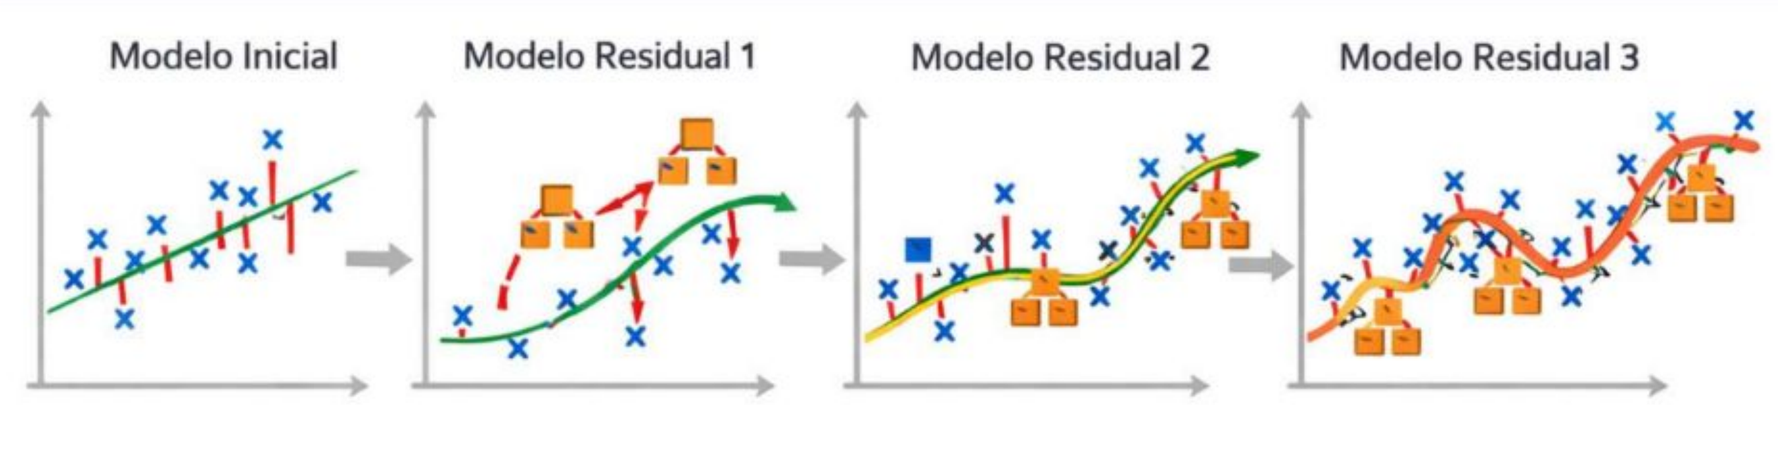
03 O que é XGBoost?

04 Vantagens e Desvantagens

O que é Gradient Boosting?

Tipo específico de boosting em que cada novo modelo é treinado para corrigir o erro do modelo anterior seguindo a direção do gradiente negativo da função de perda.

- **Boosting** é uma família de métodos ensemble em que vários modelos são treinados sequencialmente. Cada novo modelo tenta melhorar o desempenho do conjunto anterior.
- **Gradient Boosting** vem da ideia de usar o gradiente da função de perda para orientar a correção do modelo. Em cada etapa, **o algoritmo procura a direção em que a perda diminui mais rapidamente**.
  - Em regressão com erro quadrático, aprende os resíduos.
  - Em problemas de classificação, o modelo aprende uma correção associada à função de perda usada.



Constrói o modelo final como uma soma de vários modelos simples

$$F_M(x) = \sum_{m=0}^{M} \beta_m \, h(x; a_m)$$

Essa expressão mostra que o modelo final é construído como um modelo aditivo, isto é, como a soma de vários aprendizes fracos.

$F_M(x)$: modelo após M etapas de boosting (adicionar M+1 componentes).

β_m : peso associado ao m-ésimo aprendiz fraco.

$h(x; a_m)$: m-ésimo aprendiz fraco; h geralmente é uma árvore de decisão pequena.

x : vetor de atributos usado como entrada do modelo.

a_m : conjunto de parâmetros do aprendiz fraco h na iteração m.

O Gradient Boosting tenta minimizar uma função de perda.

$$F^*(x) = \arg\min_F \; \mathbb{E}_{y,x}\left[L(y, F(x))\right]$$

Essa fórmula diz que aprender um modelo consiste em encontrar uma função F(x) que produza previsões com a menor perda média possível.

x : o conjunto de atributos do objeto/observação

y : variável resposta ou alvo

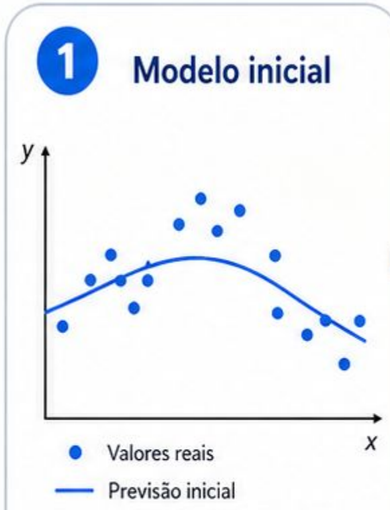
F^* : função ótima que minimiza a perda esperada.

$\mathbb{E}_{y,x}[.]$: mede a perda média esperada sobre os dados.

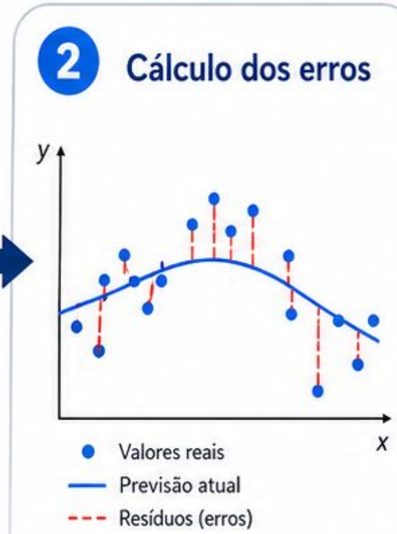
$L(y, F(x))$: função de perda que quantifica o erro entre y e F(x)

Funcionamento do Gradiente Boosting

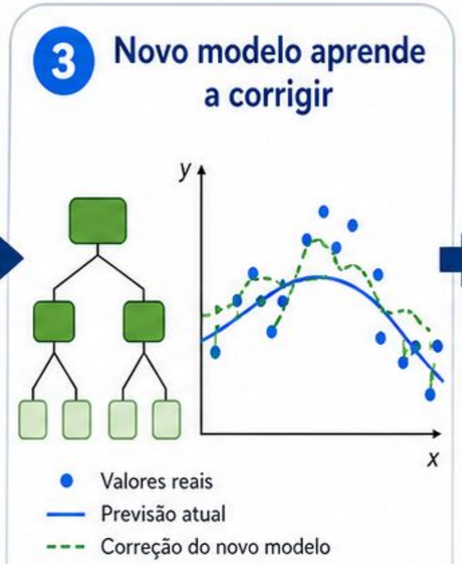
OpAIoT
Optimization • AI • IoT



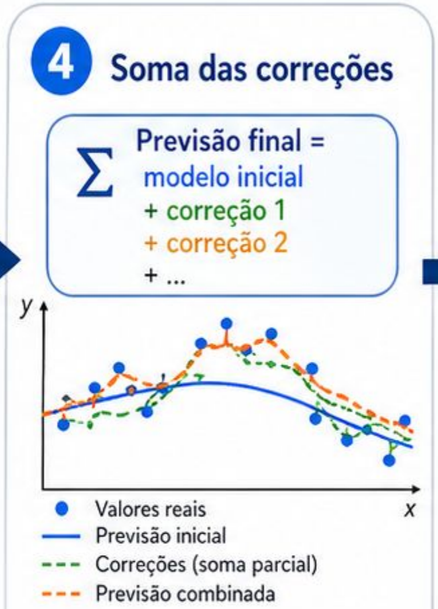
Primeiro modelo faz uma previsão inicial



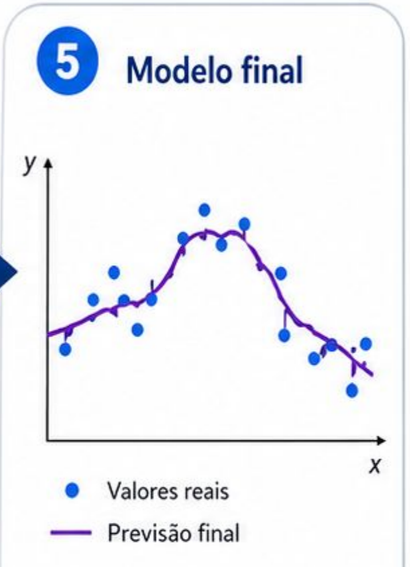
Calculam-se os erros (resíduos) do modelo atual



O próximo modelo é treinado para aprender uma correção



Cada novo modelo é somado ao conjunto



A previsão melhora gradualmente a cada etapa

Treinamento sequencial

Correção progressiva dos erros

Modelo aditivo

Alta capacidade preditiva

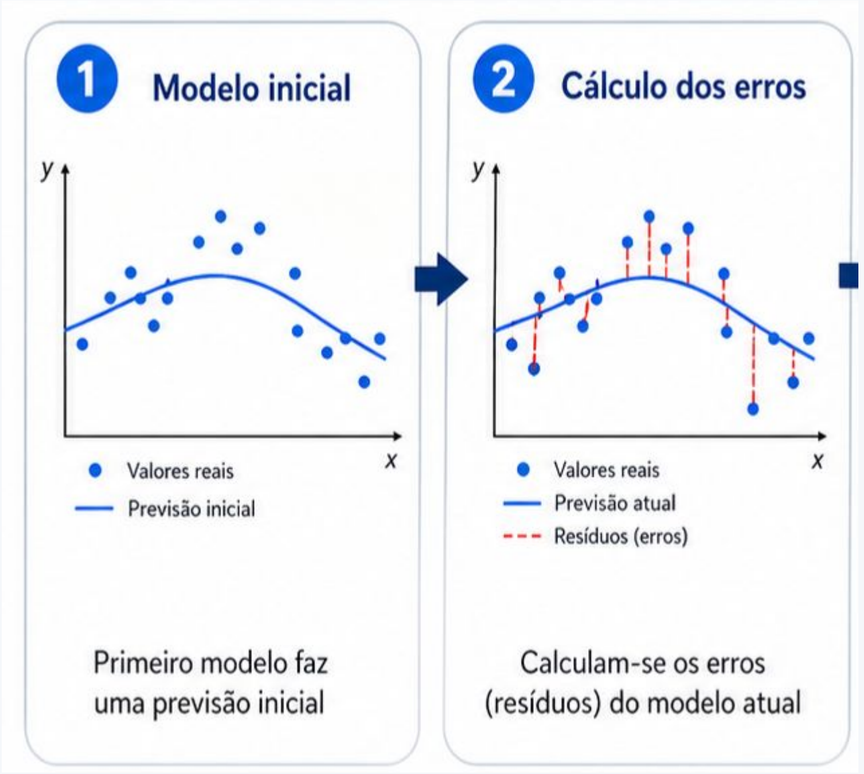
Em regressão com erro quadrático, a correção pode ser entendida como o aprendizado dos resíduos.

Funcionamento do Gradiente Boosting

1. O Gradient Boosting começa com um **modelo inicial** simples.

- Em regressão, esse modelo pode ser algo bem básico, como prever sempre a média dos valores reais.

Observação	Valor real	Previsão inicial
1	100	90
2	80	90
3	120	90



2. Calculamos o quanto o modelo errou.

- Em regressão com erro quadrático, temos o resíduo=real-previsto

Observação	Valor real	Previsão atual	Resíduo
1	100	90	10
2	80	90	-10
3	120	90	30

Esses resíduos indicam a direção da correção:

- resíduo positivo: o modelo previu abaixo do valor real;
- resíduo negativo: o modelo previu acima do valor real.

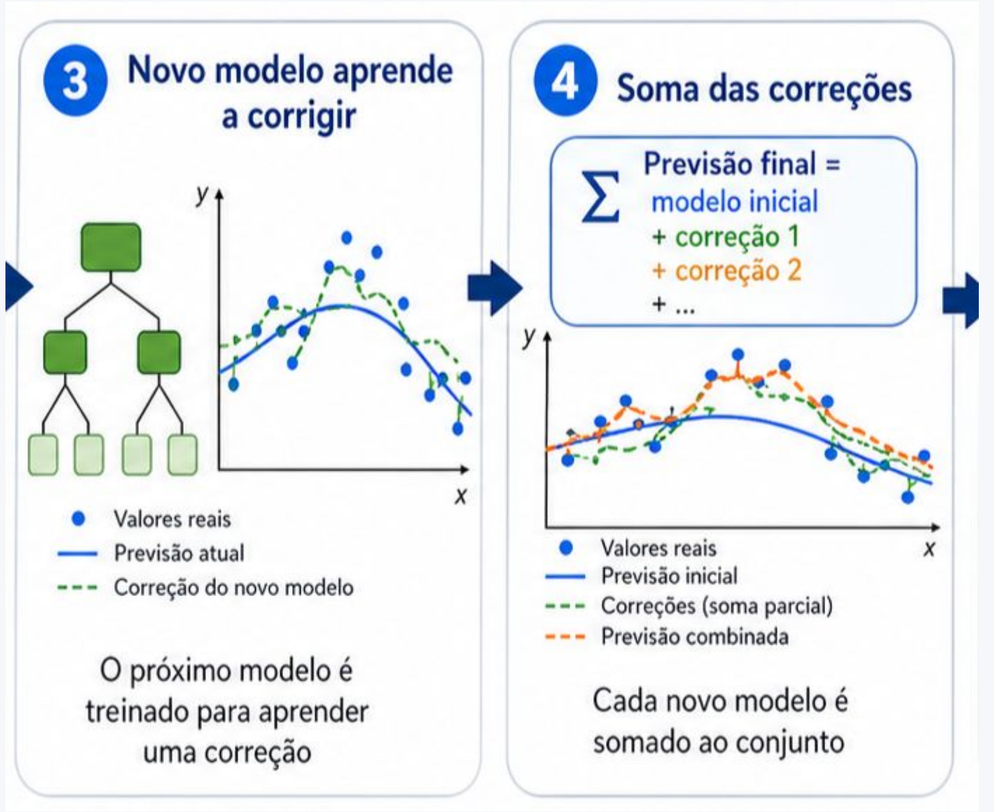
3. Treina-se agora o novo modelo para prever os erros do modelo atual, ou seja, o novo modelo tenta responder: **Para uma observação com essas características, quanto o modelo anterior errou?**

Observação	Atributos da máquina	Resíduo
1	alta temperatura, alta vibração	10
2	baixa temperatura, baixa vibração	-10
3	alta temperatura, baixa pressão	30

4. A correção é somada à previsão anterior.

nova previsão=previsão anterior +taxa de aprendizado×correção

Observação	Previsão anterior	Correção aprendida	Taxa de aprendizado	Nova previsão
1	90	10	0,5	95
2	90	-10	0,5	85
3	90	30	0,5	105



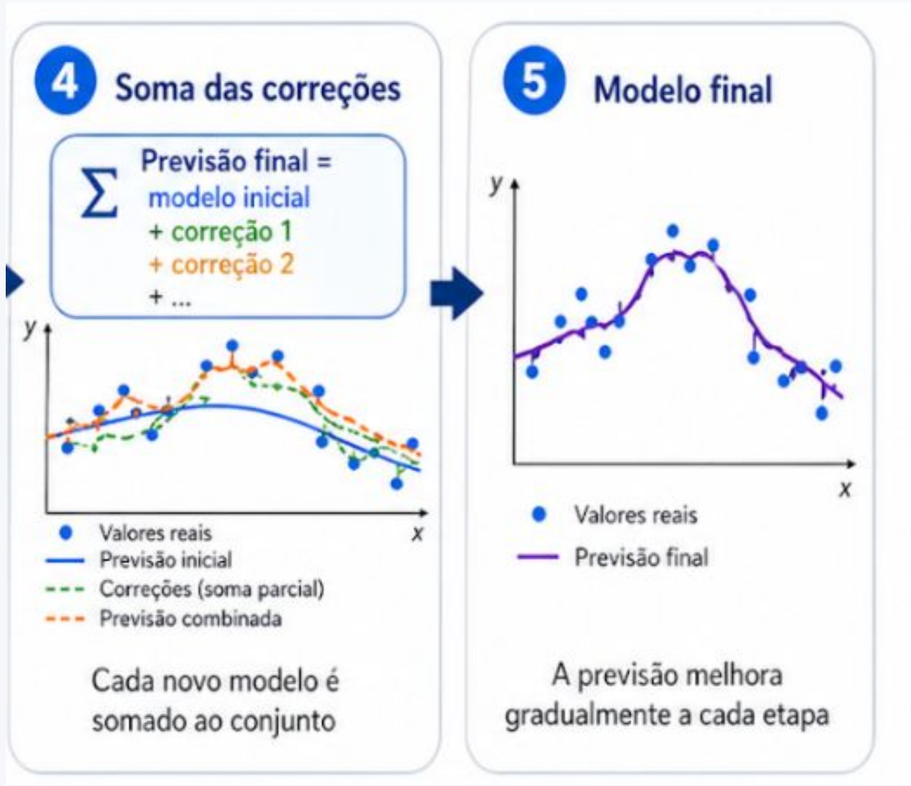
5. O processo se repete várias vezes, onde a cada etapa:

1. o modelo atual faz previsões;
2. os erros são calculados;
3. uma nova árvore aprende parte desses erros;
4. essa nova correção é somada ao modelo anterior.

Ao final, temos um modelo formado com

F(x)=modelo inicial+correção_1 + correão_2 + …+correção _M

O resultado é um modelo mais flexível e geralmente mais preciso.



Gradient Boosting geralmente utiliza árvores de decisão, gerando uma sequência de pequenas árvores (árvores rasa) que corrigem os erros do modelo anterior.

O que é XGBoost?

Implementação altamente otimizada e regularizada do Gradient Boosting para árvores de decisão

- XGBoost significa Extreme Gradient Boosting.
- Tornou-se popular pela combinação de velocidade, desempenho e robustez.
- A predição é normalmente descrita como soma de árvores.

XGBoost penaliza tanto árvores com muitas folhas quanto folhas com pesos muito agressivos. Isso ajuda a controlar complexidade e overfitting.

A regularização é definida como

$$\Omega(f) = \gamma T + \frac{1}{2}\lambda \sum_{j=1}^{T} w_j^2,$$

T é o número de folhas da árvore e w_j são os pesos das folhas.

A predição é normalmente descrita como soma de árvores: $\hat{y}_i = \sum_{k=1}^{K} f_k(x_i), \quad f_k \in \mathcal{F}$

Busca-se uma nova árvore f na iteração que minimize

$$\mathcal{L}^{(t)} = \sum_{i=1}^{n} l\left(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)\right) + \Omega(f_t).$$

Vantagens e Desvantagens

Vantagens

- Alto desempenho preditivo em problemas de regressão e classificação.
- Captura relações não lineares e interações entre atributos.
- Flexibilidade, pois permite diferentes funções de perda.
- Bom controle do aprendizado, usando hiperparâmetros como taxa de aprendizado e número de árvores.
- Permite estimar importância de atributos, ajudando na interpretação global do modelo.

Desvantagens

- Maior risco de overfitting se o modelo for muito complexo ou tiver muitas iterações.
- Treinamento sequencial, o que pode torná-lo mais lento que métodos paralelos como Random Forest.
- Mais sensível a hiperparâmetros, como: número de árvores; profundidade das árvores; taxa de aprendizado; tamanho mínimo das folhas; regularização.
- Menor interpretabilidade do que uma única árvore de decisão.
- Pode ser sensível a ruídos e outliers, dependendo da função de perda utilizada.

OpAIoT
Optimization • AI • IoT

Universidade de São Paulo

Referências

- Faceli, Katti, et al. "Inteligência artificial: uma abordagem de aprendizado de máquina." (2021).
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). An Introduction to Statistical Learning. Springer
- Scikit-learn Documentation: https://scikit-learn.org/stable/modules/linear_model.html





Obrigado!

opaiot@icmc.usp.br
+55 (16) 99962-7637

PROFESSOR

Dr. Cláudio Fabiano Motta Toledo

OpAIoT
Optimization • AI • IoT